

2026 학년도 1학기 중간과제물(온라인 제출용)

교과목명	데이터마이닝
학번	202334-153257
성명	양희석
연락처	010-4340-2326
과제유형 (공통형/지정형)	공통형

목차

- [문제 1. 생성형 AI 시대 데이터마이닝의 영향과 전문가 생존 전략](#)
- [문제 2. iris 데이터를 이용한 선형회귀와 로지스틱 회귀 비교](#)
- [문제 3. 지니지수 기반 분류의사결정나무 — 분할표로부터의 원형 데이터 복원](#)
- [문제 4. 배깅·부스팅·랜덤포레스트의 수식 비교](#)

문제 1. 생성형 AI 시대 데이터마이닝의 영향과 전문가 생존 전략

생성형 AI는 자연어 지시만으로 텍스트·코드·이미지·표를 산출할 수 있는 범용 도구로 자리잡았으며, 데이터 분석을 업으로 하는 전문가의 작업 환경을 빠르게 재편하고 있다. 통계적 학습 또는 기계학습 방법을 활용하는 데이터마이닝 전문가의 입장에서, 이러한 변화가 가져올 영향과 그에 대응하는 생존 전략을 다음과 같이 정리한다.

1-1. 데이터마이닝 영역에 미칠 영향

첫째, 데이터 전처리·탐색적 분석(EDA)의 자동화가 가속된다. 결측치 처리, 변수 인코딩, 기술통계, 분포 시각화, 변수 간 관계 탐색 등 분석 초반의 반복적 작업은 LLM 기반 도구가 빠르게 흡수하고 있다. 자연어 지시만으로 R/Python 코드와 시각화를 산출하고 결과를 해석할 수 있게 되면서, 단순 분석 업무의 진입 장벽이 크게 낮아졌다. 이는 입문자에게는 기회이지만, 코드 작성 능력 자체에 의존해 온 분석가에게는 직접적 위협이다.

둘째, 모델 선택과 하이퍼파라미터 튜닝(AutoML)이 LLM과 결합되어 한층 정교해진다. 알고리즘 후보 비교·교차검증·앙상블 구성처럼 SEMMA 또는 CRISP-DM 절차의 상당 부분을 LLM이 보조하거나 대체할 수 있게 되었다. 그 결과 전문가가 차별화할 수 있는 영역은 절차의 수행이 아니라 절차의 설계로 이동한다. 어떤 변수를 목표로 두고, 어떤 손실 함수와 평가 지표로 성공을 정의할지를 결정하는 일은 여전히 사람의 판단을 요구한다.

셋째, 데이터마이닝의 본질은 대체되지 않는다. 데이터마이닝은 단순히 패턴을 찾는 일이 아니라 현실의 의사결정을 이끌어내기 위한 통계적·인과적 추론을 포함한다. LLM은 학습 분포 안에서 그럴듯한 답을 생성할 뿐, 인과 식별·교란 변수 통제·표본 편향 진단·과적합 해석처럼 통계적 엄밀성을 요구하는 작업에서는 한계를 드러낸다. 또한 의료·금융·법률처럼 해석가능성과 책임 소재가 중요한 영역에서는 블랙박스의 산출물을 그대로 채택할 수 없다. 따라서 생성형 AI는 데이터마이닝을 대체하는 것이 아니라 그 무게 중심을 이동시킨다고 보는 편이 정확하다.

1-2. AI 시대 데이터 분석 전문가의 생존 전략

첫째, 문제 정의 능력을 길러야 한다. LLM에게 "분석을 해 달라"고 지시하는 것과, 검증 가능한 가설과 성공 지표를 설계해 분석을 의뢰하는 것은 전혀 다른 작업이다. 문제 정의·범위 설정·목표 변수 선택·평가 지표 결정은 도메인을 이해하지 못하는 LLM이 수행할 수 없는 가장 본질적 역학이며, AI 시대에 가장 가치가 높아지는 역량이다.

둘째, 해석가능성과 신뢰도 검증 역량을 강화해야 한다. 모델 산출물을 비판적으로 점검하고, 잔차 분석·교차검증·민감도 분석·SHAP과 같은 설명 도구로 결과의 한계와 적용 범위를 명시하는 일은 분석가만이 책임질 수 있다. 통계적 학습의 가정과 한계를 깊이 이해하는 사람일수록 LLM 산출물의 함정을 잘 식별한다.

셋째, 도메인과의 융합이 결정적이다. 분석 기술 자체는 빠르게 평준화되므로, 의료·제조·금융·교육 등 특정 산업의 데이터 생성 메커니즘과 의사결정 구조를 이해하는 분석가가 더 높은 가치를 갖는다. 도메인 지식은 LLM이 단기간에 모방하기 어려운 차별화 요소다.

넷째, MLOps와 AutoML을 적극 활용해 재현 가능한 분석 파이프라인을 구축해야 한다. 생성형 AI를 협업하는 동료처럼 활용하되, 산출물 검증의 최종 책임은 분석가 본인이 진다는 태도가 필요하다. 코드는 위임할 수 있지만 책임은 위임할 수 없다.

다섯째, **데이터 거버넌스**와 **윤리** 영역의 역량이 중요해진다. 개인정보 보호, 학습 데이터의 편향, 합성 데이터의 적절한 사용, 모델 공정성 등은 기술적 정답이 없고 가치 판단을 요구하는 문제다. 이러한 문제에 대해 명확한 입장을 제시할 수 있는 분석가가 조직에서 신뢰를 얻는다.

결론적으로 생성형 AI는 데이터마ining 전문가의 일을 줄이는 것이 아니라 그 성격을 바꾼다. 절차 수행에서 절차 설계로, 코드 작성에서 결과 해석으로, 모델 학습에서 모델 책임으로 무게중심이 이동하는 흐름 속에서, 통계적 엄밀성과 **도메인 통찰을 함께 갖춘 분석가**만이 지속적으로 가치를 인정받을 것이다.

문제 2. iris 데이터를 이용한 선형회귀와 로지스틱 회귀 비교

① iris2 데이터셋 생성

R에 내장된 iris 데이터(150행 × 5열)에서 Species 값이 setosa 또는 virginica 인 100개 관측치만을 추출하여 새로운 데이터 프레임 iris2 를 만든다. 이때 목적변수 Species 는 **setosa = 1, virginica = 0**의 수치형(0/1) 변수로 재부호화한다. 이는 ②에서 동일한 0/1 변수에 대해 다중선형회귀(lm)와 로지스틱 회귀(glm , family=binomial)를 모두 적합하여 두 모형을 직접 비교하기 위함이다.

```
# iris 내장 데이터 불러오기
data(iris)

# setosa(50개)와 virginica(50개)만 추출하여 iris2 생성
iris2 <- subset(iris, Species %in% c("setosa", "virginica"))

# Species를 수치형 0/1로 변환 (setosa=1, virginica=0)
iris2$Species <- ifelse(iris2$Species == "setosa", 1, 0)

# 구조 확인
str(iris2)
table(iris2$Species)
```

실행 결과

```
> # iris 내장 데이터 불러오기
> data(iris)
>
> # setosa(50개)와 virginica(50개)만 추출하여 iris2 생성
> iris2 <- subset(iris, Species %in% c("setosa", "virginica"))
>
> # Species를 수치형 0/1로 변환 (setosa=1, virginica=0)
> iris2$Species <- ifelse(iris2$Species == "setosa", 1, 0)
>
> # 구조 확인
> str(iris2)
'data.frame': 100 obs. of 5 variables:
 $ Sepal.Length: num 5.1 4.9 4.7 4.6 5 5.4 4.6 5 4.4 4.9 ...
 $ Sepal.Width : num 3.5 3 3.2 3.1 3.6 3.9 3.4 3.4 2.9 3.1 ...
 $ Petal.Length: num 1.4 1.4 1.3 1.5 1.4 1.7 1.4 1.5 1.4 1.5 ...
 $ Petal.Width : num 0.2 0.2 0.2 0.2 0.2 0.4 0.3 0.2 0.2 0.1 ...
 $ Species : num 1 1 1 1 1 1 1 1 1 1 ...
> table(iris2$Species)

 0  1
50 50
>
```

결과 해석:

- `str(iris2)` 출력에서 'data.frame': 100 obs. of 5 variables — 관측치 100개·변수 5개로 정확히 의도한 크기의 데이터 프레임이 만들어졌다.
- 4개 수치형 입력변수(`Sepal.Length` , `Sepal.Width` , `Petal.Length` , `Petal.Width`)는 원본 그대로 `num` 타입을 유지한다.
- `Species` 는 본래 3수준 `factor` 였으나 `ifelse()` 를 거쳐 `num` 타입의 0/1 값으로 변환되었다. 출력 첫 부분에 표시된 `1 1 1 1 1 1 1 1 ...` 은 `subset()` 이 원본 순서를 보존하므로 앞쪽 50개가 모두 `setosa(=1)`임을 확인시켜 준다.
- `table(iris2$Species)` 결과는 0: 50, 1: 50 으로, 두 범주가 정확히 50개씩 **완전히 균형 잡힌 이진분류 데이터**임을 보여 준다. 따라서 이후 회귀 적합에서 클래스 불균형으로 인한 편향은 고려할 필요가 없다.

② 다중선형회귀모형과 로지스틱 회귀모형의 적합

`iris2` 의 0/1 수치형 `Species` 를 종속변수, 4개 수치형 변수(`Sepal.Length` , `Sepal.Width` , `Petal.Length` , `Petal.Width`)를 독립 변수로 하는 두 모형을 차례로 적합한다.

(가) 다중선형회귀모형 (`lm`)

```
# 다중선형회귀: Species ~ 모든 수치형 변수
lm.fit <- lm(Species ~ Sepal.Length + Sepal.Width + Petal.Length + Petal.Width,
             data = iris2)
summary(lm.fit)
```

실행 결과

```
> # 다중선형회귀: Species ~ 모든 수치형 변수
> lm.fit <- lm(Species ~ Sepal.Length + Sepal.Width + Petal.Length + Petal.Width,
+             data = iris2)
> summary(lm.fit)
```

Call:

```
lm(formula = Species ~ Sepal.Length + Sepal.Width + Petal.Length +
    Petal.Width, data = iris2)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-0.156436	-0.045794	0.000438	0.049792	0.222085

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.69848	0.08471	8.245	9.14e-13 ***
Sepal.Length	0.07956	0.02409	3.302	0.00135 **
Sepal.Width	0.06037	0.02592	2.329	0.02200 *
Petal.Length	-0.18341	0.02202	-8.331	6.02e-13 ***
Petal.Width	-0.18462	0.03459	-5.337	6.41e-07 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.07198 on 95 degrees of freedom

Multiple R-squared: 0.9803, Adjusted R-squared: 0.9795

F-statistic: 1183 on 4 and 95 DF, p-value: < 2.2e-16

>

결과 해석 및 특징:

- **회귀계수와 부호** — 4개 회귀계수는 모두 통계적으로 유의하다. `Petal.Length` (-0.18341 , $p \approx 6.0e-13$)와 `Petal.Width` (-0.18462 , $p \approx 6.4e-07$)의 계수가 **음수**라는 점은 도메인 지식과 일치한다. `setosa` = 1, `virginica` = 0으로 부호화했으므로, 꽃잎이 크고 길수록(`virginica`의 특징) 종속변수의 적합값이 0(`virginica`) 쪽으로 끌려가야 하기 때문이다. 반대로 `Sepal.Length` ($+0.07956$, $p = 0.00135$)와 `Sepal.Width` ($+0.06037$, $p = 0.02200$)의 계수는 **양수**로, 꽃받침이 큰 개체일수록 `setosa`일 가능성이 높다는 해석으로 이어진다.
- **모형 적합도** — Multiple $R^2 = 0.9803$, Adjusted $R^2 = 0.9795$ 로 매우 높고, F-통계량 1183($p < 2.2e-16$)로 전체 모형의 유의성도 매우 강하다. 종속변수 분산의 약 98%가 4개 입력변수로 설명된다.

- **잔차 분포** — 잔차의 범위는 $[-0.156, 0.222]$, 중앙값 0.0004로 0 부근에 거의 대칭으로 분포하지만, 종속변수가 0/1만을 갖는 이진 변수이므로 잔차는 본질적으로 **이봉(bimodal) 형태**를 띤다. 이는 선형회귀의 정규성·등분산성 가정과 정면으로 충돌한다.
- **예측값의 [0,1] 이탈 가능성** — 선형회귀의 적합값 $\hat{y} = \hat{\beta}_0 + \hat{\beta}^\top x$ 는 이론적으로 $(-\infty, \infty)$ 의 모든 값을 가질 수 있다. 본 데이터의 적합값은 우연히 대부분 $[0, 1]$ 부근에 머물지만, 일반적인 0/1 분류 문제에서 선형회귀 적합값을 확률로 해석하면 음수나 1 초과와 부적절한 값이 발생한다.
- **결론적 특징** — R^2 와 F-통계량이 외형상 매우 우수해 보이지만, 종속변수가 이항(베르누이) 분포를 따르는 상황에서 선형회귀의 가정(잔차의 정규성·등분산성, 적합값의 실수 전체 영역 적용 가능성)은 위배된다. 따라서 수치적 적합 결과가 좋더라도 추론(t-검정, F-검정, 신뢰구간)의 해석에는 주의가 필요하다.

(나) 로지스틱 회귀모형 (`glm`, `family=binomial`)

동일한 `iris2` 데이터에 로지스틱 회귀모형을 적합한다. 0/1 종속변수에 대해 `glm()` 함수에 `family = binomial` 을 지정하면 로짓 연결함수

$$\log \frac{P(Y = 1 | X)}{1 - P(Y = 1 | X)} = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p$$

가 적합되며, 추정은 최대우도법(MLE)으로 이루어진다.

```
# 로지스틱 회귀: family = binomial
glm.fit <- glm(Species ~ Sepal.Length + Sepal.Width + Petal.Length + Petal.Width,
               data = iris2, family = binomial)
summary(glm.fit)
```

실행 결과

```
>
> # 로지스틱 회귀: family = binomial
> glm.fit <- glm(Species ~ Sepal.Length + Sepal.Width + Petal.Length + Petal.Width,
+               data = iris2, family = binomial)
```

경고메시지(들):

```
1: glm.fit: 알고리즘이 수렴하지 않았습니다
2: glm.fit: 적합된 확률값들이 0 또는 1 입니다
```

```
> summary(glm.fit)
```

Call:

```
glm(formula = Species ~ Sepal.Length + Sepal.Width + Petal.Length +
    Petal.Width, family = binomial, data = iris2)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	15.168	560540.339	0	1
Sepal.Length	3.961	143416.937	0	1
Sepal.Width	4.172	94374.284	0	1
Petal.Length	-11.975	88570.517	0	1
Petal.Width	-9.736	169967.486	0	1

(Dispersion parameter for binomial family taken to be 1)

```
Null deviance: 1.3863e+02 on 99 degrees of freedom
Residual deviance: 8.5827e-10 on 95 degrees of freedom
AIC: 10
```

```
Number of Fisher Scoring iterations: 25
```

```
>
```

결과 해석 및 특징:

- **경고 메시지(완전분리 현상)** — R은 두 가지 경고를 출력한다.

1. `glm.fit`: 알고리즘이 수렴하지 않았습니다
2. `glm.fit`: 적합된 확률값들이 0 또는 1 입니다

이는 *setosa*와 *virginica*가 4개 변수 공간에서 **완전 선형분리(perfect / quasi-complete separation)** 가능하기 때문에 발생한다. 두 클래스를 완벽히 가르는 초평면이 존재하면 우도함수의 최댓값이 유한한 회귀계수에서 형성되지 않고 일부 계수가 $\pm\infty$ 로 발산한다. Fisher Scoring이 25회 반복으로 종료된 점도 같은 현상의 신호이다.

- **회귀계수와 표준오차** — 추정값은 (Intercept) 15.168, Sepal.Length 3.961, Sepal.Width 4.172, **Petal.Length -11.975**, **Petal.Width -9.736**로 출력되었지만, 표준오차가 56만, 14만, 8만 단위로 비정상적으로 거대하다. 이는 우도함수가 평탄해져 계수의 정밀한 추정이 불가능하다는 신호이다. 그 결과 모든 z-값은 0, p-값은 1로 보고되어 **개별 계수의 Wald 검정은 의미가 없다**.
- **계수 부호의 정성적 해석** — 표준오차 문제와 별개로, 계수 부호 자체는 도메인과 일치한다. `Petal.Length` · `Petal.Width`는 음수로, 꽃잎이 길고 넓을수록 *setosa*(=1)일 로그오즈가 감소함을 뜻하며, `Sepal.Length` · `Sepal.Width`는 양수로 꽃받침이 클수록 *setosa*일 로그오즈가 증가함을 뜻한다. 다중선형회귀에서 얻은 부호와 방향이 일치한다.
- **이탈도(deviance)와 AIC** — Null deviance 138.63(자유도 99) → Residual deviance $\approx 8.58 \times 10^{-10}$ (자유도 95)로 잔차 이탈도가 사실상 0에 도달했다. 이는 모형이 100개 관측치 전부를 완전히 분리해 적합했음을 뜻한다. $AIC = 10 = 2 \times (\text{절편} + 4\text{계수})$ 로 별점항만 남아있다.
- **결론적 특징** — (i) 로지스틱 회귀의 적합값은 항상 (0, 1) 사이의 확률로 보장되어 분류 문제에 자연스럽고, (ii) 계수의 부호와 상대적 크기로 변수의 영향 방향을 일관되게 해석할 수 있다. 다만 본 자료처럼 두 클래스가 너무 잘 분리되는 경우 MLE가 수렴하지 않아 표준오차와 p-값이 신뢰할 수 없게 되는 **완전분리 문제**가 발생한다. 이 경우 Firth 보정 로지스틱 회귀(`logistf` 패키지) 등 정칙화 기법을 사용하면 안정적인 추정이 가능하다.

③ 두 모형의 차이점 및 타당성 비교

(가) 두 모형의 구조적 차이

비교 항목	다중선형회귀 (lm)	로지스틱 회귀 (glm, binomial)
반응변수 분포 가정	정규분포 $Y X \sim N(\mu, \sigma^2)$	이항분포 $Y X \sim \text{Bernoulli}(\pi)$
연결함수	항등함수 $\mu = \beta_0 + \beta^\top x$	로짓 $\log \frac{\pi}{1-\pi} = \beta_0 + \beta^\top x$
적합값의 범위	$(-\infty, \infty)$ 의 실수 전체	(0, 1)의 확률
추정 방법	최소제곱법(OLS)	최대우도법(MLE) — 반복적 가중 최소제곱(IRLS)
잔차의 분포 가정	정규성, 등분산성 가정	가정 없음 (deviance 잔차로 진단)
모형 적합도 지표	R^2 , F -통계량	Null/Residual deviance, AIC
계수 해석	X_j 1 단위 변화 → Y 의 평균 변화량	X_j 1 단위 변화 → 로그오즈의 변화량 (오즈비 e^{β_j})
계수 검정	t -검정	Wald z -검정, 우도비 검정

(나) 본 데이터에서의 분석 결과 비교

- **공통점** — 두 모형 모두 4개 입력변수가 종속변수에 영향을 미친다는 결론을 내며, 회귀계수의 부호 방향(*Petal.** 음수, *Sepal.** 양수)이 일치한다. 즉, 두 모형이 포착하는 변수 영향의 *방향*에 대한 정성적 해석은 동일하다.
- **차이점**
 - **다중선형회귀** — $R^2 = 0.9803$, $F = 1183$ ($p < 2.2 \times 10^{-16}$)로 형식상 매우 우수한 적합. 4개 계수 모두 t -검정에서 유의($p < 0.05$). 잔차는 $[-0.156, 0.222]$ 로 0 부근에 분포하지만 종속변수가 0/1뿐이므로 본질적으로 이분 분포를 띠어 정규성·등분산성 가정을 위반한다. 또한 적합값이 이론상 [0, 1]을 벗어날 수 있어 **확률**로 해석할 근거가 없다.
 - **로지스틱 회귀** — 적합값이 항상 (0, 1)의 확률로 해석되어 분류 문제에 자연스럽다. 다만 본 자료에서는 *setosa*와 *virginica*가 입력변수 공간에서 **완전 선형분리** 가능하므로 MLE가 수렴하지 않고("알고리즘이 수렴하지 않았습니다", "적합된 확률값들이 0 또는 1") 표준오차가 폭증해 Wald 검정이 무의미해졌다. 그러나 Residual deviance $\approx 8.58 \times 10^{-10}$ 와 $AIC = 10$ 은 모형이 100개 관측치를 완벽히 분류했음을 보여준다.

(다) 어느 모형이 타당한가 — 결론과 근거

결론: 본 자료의 0/1 이진 종속변수에 대해서는 로지스틱 회귀모형이 타당하다.

근거는 다음과 같다.

1. **확률 모형의 적합성** — 종속변수가 베르누이 분포를 따르는 0/1 변수이므로, 정규분포를 가정하는 선형회귀가 아니라 이항분포를 가정하는 로지스틱 회귀가 데이터 생성 과정과 부합한다. 선형회귀는 정규성·등분산성·선형성 가정을 충족하지 못한 채 적용되어 있어 R^2 와 t -검정의 해석에 신뢰성을 부여하기 어렵다.
2. **적합값의 해석 가능성** — 로지스틱 회귀의 적합값은 자동으로 (0, 1) 범위에 들어와 $P(Y = 1 | X)$ 로 해석되지만, 선형회귀의 적합값은 음수나 1 초과 값을 가질 수 있어 확률로 사용할 수 없다.
3. **계수의 의미 부여** — 로지스틱 회귀의 계수는 e^{β_j} 형태로 오즈비로 해석할 수 있어 변수의 영향력을 정량적으로 설명할 수 있다. 선형회귀에서 평균 변화량 해석은 0/1 종속변수의 맥락에서 직관적이지 않다.
4. **분류 정확도** — 본 자료에서 로지스틱 회귀는 100개 관측치를 100% 정확히 분류한 반면, 선형회귀는 적합값에 임계치(예: 0.5)를 적용해야 비로소 분류 결정을 내릴 수 있다.

다만 본 자료의 완전분리 상황에서 **표준 로지스틱 회귀의 추론(개별 계수의 표준오차·p-값)**은 신뢰할 수 없다는 점은 명시적 한계다. 실무에서는 Firth 보정 로지스틱 회귀(`logistf` 패키지) 등 페널티 기반 정규화 기법을 적용하거나, `virginica` 외에 `versicolor`를 포함시키는 등 두 클래스가 부분적으로 겹치는 자료로 재구성하여 안정적인 추정을 얻는 것이 바람직하다.

문제 3. 지니지수 기반 분류의사결정나무 — 분할표로부터의 원형 데이터 복원

3-0. 분할표 정리

		X1=1	X1=2	X1=3	행합
Y=1	X2=1	0	2	5	7
	X2=2	0	4	6	10
	X2=3	2	0	1	3
Y=2	X2=1	2	0	0	2
	X2=2	3	7	0	10
	X2=3	4	1	2	7

전체 관측치 수: **n = 39** (Y=1: 20, Y=2: 19).

분할표로부터 산출한 X1·X2 주변분포는 다음과 같다.

	X1=1	X1=2	X1=3	합계		X2=1	X2=2	X2=3	합계
Y=1	2	6	12	20		7	10	3	20
Y=2	9	8	2	19		2	10	7	19
합계	11	14	14	39		9	20	10	39

① 원형 데이터

```
X1, X2, Y
2, 1, 1
2, 1, 1
3, 1, 1
3, 1, 1
3, 1, 1
3, 1, 1
3, 1, 1
2, 2, 1
2, 2, 1
2, 2, 1
2, 2, 1
3, 2, 1
3, 2, 1
```

3, 2, 1
 3, 2, 1
 3, 2, 1
 3, 2, 1
 1, 3, 1
 1, 3, 1
 3, 3, 1
 1, 1, 2
 1, 1, 2
 1, 2, 2
 1, 2, 2
 1, 2, 2
 2, 2, 2
 2, 2, 2
 2, 2, 2
 2, 2, 2
 2, 2, 2
 2, 2, 2
 1, 3, 2
 1, 3, 2
 1, 3, 2
 1, 3, 2
 2, 3, 2
 3, 3, 2
 3, 3, 2

② 최적 분리점 (지니지수)

뿌리노드의 지니지수

전체 39개 관측치 중 Y=1이 20개, Y=2가 19개이므로

$$Gini(\text{root}) = 1 - \left(\frac{20}{39}\right)^2 - \left(\frac{19}{39}\right)^2 = 1 - \frac{400 + 361}{1521} = \frac{760}{1521} \approx 0.4997$$

분할 후보별 가중 지니지수 계산

각 입력변수 X_j 의 값 하나를 한쪽으로, 나머지 두 값을 다른 쪽으로 묶는 *one-vs-rest* 이분 분할 6가지에 대해 가중 지니지수

$$Gini_{\text{split}} = \frac{n_L}{n} Gini(L) + \frac{n_R}{n} Gini(R)$$

를 계산한다.

(a) **X1 = 1 vs {2, 3}** 좌측: $n=11, Y1=2, Y2=9 \rightarrow Gini_L = 1 - (2/11)^2 - (9/11)^2 = 36/121 \approx 0.2975$ 우측: $n=28, Y1=18, Y2=10 \rightarrow Gini_R = 1 - (18/28)^2 - (10/28)^2 = 360/784 \approx 0.4592$ 가중 지니 = $(11/39)(0.2975) + (28/39)(0.4592) \approx 0.4136$

(b) **X1 = 2 vs {1, 3}** 좌측: $n=14, Y1=6, Y2=8 \rightarrow Gini_L = 1 - (6/14)^2 - (8/14)^2 = 96/196 \approx 0.4898$ 우측: $n=25, Y1=14, Y2=11 \rightarrow Gini_R = 1 - (14/25)^2 - (11/25)^2 = 308/625 \approx 0.4928$ 가중 지니 $\approx (14/39)(0.4898) + (25/39)(0.4928) \approx 0.4917$

(c) **X1 = 3 vs {1, 2}** (★ 최적) 좌측: $n=14, Y1=12, Y2=2 \rightarrow Gini_L = 1 - (12/14)^2 - (2/14)^2 = 48/196 \approx 0.2449$ 우측: $n=25, Y1=8, Y2=17 \rightarrow Gini_R = 1 - (8/25)^2 - (17/25)^2 = 272/625 \approx 0.4352$ 가중 지니 $\approx (14/39)(0.2449) + (25/39)(0.4352) \approx 0.3669$

(d) **X2 = 1 vs {2, 3}** 좌측: $n=9, Y1=7, Y2=2 \rightarrow Gini_L = 1 - (7/9)^2 - (2/9)^2 = 28/81 \approx 0.3457$ 우측: $n=30, Y1=13, Y2=17 \rightarrow Gini_R = 1 - (13/30)^2 - (17/30)^2 = 442/900 \approx 0.4911$ 가중 지니 $\approx (9/39)(0.3457) + (30/39)(0.4911) \approx 0.4576$

(e) **X2 = 2 vs {1, 3}** 좌측: $n=20, Y1=10, Y2=10 \rightarrow Gini_L = 1 - (10/20)^2 - (10/20)^2 = 0.5000$ 우측: $n=19, Y1=10, Y2=9 \rightarrow Gini_R = 1 - (10/19)^2 - (9/19)^2 = 180/361 \approx 0.4986$ 가중 지니 $\approx (20/39)(0.5000) + (19/39)(0.4986) \approx 0.4993$

(f) $X_2 = 3$ vs $\{1, 2\}$ 좌측: $n=10, Y_1=3, Y_2=7 \rightarrow Gini_L = 1 - (3/10)^2 - (7/10)^2 = 0.4200$ 우측: $n=29, Y_1=17, Y_2=12 \rightarrow Gini_R = 1 - (17/29)^2 - (12/29)^2 = 408/841 \approx 0.4852$ 가중 지니 $\approx (10/39)(0.4200) + (29/39)(0.4852) \approx 0.4685$

비교표

후보 분할	좌측 자식 (n, Y=1, Y=2)	우측 자식 (n, Y=1, Y=2)	가중 지니
$X_1 = 1$ vs $\{2, 3\}$	(11, 2, 9)	(28, 18, 10)	0.4136
$X_1 = 2$ vs $\{1, 3\}$	(14, 6, 8)	(25, 14, 11)	0.4917
$X_1 = 3$ vs $\{1, 2\}$ ★	(14, 12, 2)	(25, 8, 17)	0.3669
$X_2 = 1$ vs $\{2, 3\}$	(9, 7, 2)	(30, 13, 17)	0.4576
$X_2 = 2$ vs $\{1, 3\}$	(20, 10, 10)	(19, 10, 9)	0.4993
$X_2 = 3$ vs $\{1, 2\}$	(10, 3, 7)	(29, 17, 12)	0.4685

최적 분리점: $X_1 = 3$ vs $\{X_1 = 1, X_1 = 2\}$ — 가중 지니지수 0.3669로 6개 후보 중 최솟값을 갖는다. 즉 변수 X_1 이 값 3을 갖는지 여부로 데이터를 두 집단으로 가르는 것이 첫 분할에서 가장 큰 불순도 감소를 가져온다.

③ 한 번 분할된 분류의사결정나무

②에서 도출한 최적 분리점 $X_1 = 3$ 을 기준으로 뿌리노드를 한 번 분할한 결과는 다음과 같다.



자식노드의 집단별 빈도:

노드	분기 조건	n	Y=1 빈도	Y=2 빈도	다수 클래스
Left	$X_1 = 3$	14	12	2	Y=1
Right	$X_1 \in \{1, 2\}$	25	8	17	Y=2

좌측 노드는 14개 중 12개(85.7%)가 Y=1로 비교적 순수하게 분리되며, 우측 노드는 25개 중 17개(68.0%)가 Y=2로 분류된다.

④ 불순도 감소분 $\Delta Gini$

$$\begin{aligned}
 \Delta Gini &= Gini(\text{root}) - \left(\frac{n_L}{n} Gini(L) + \frac{n_R}{n} Gini(R) \right) \\
 &= 0.4997 - \left(\frac{14}{39} \cdot 0.2449 + \frac{25}{39} \cdot 0.4352 \right) \\
 &= 0.4997 - 0.3669 \\
 &\approx \mathbf{0.1328}
 \end{aligned}$$

즉, $X_1 = 3$ 분할로 뿌리노드의 지니 불순도가 약 **0.4997** $\rightarrow$ **0.3669**로 감소하여 **0.1328** 만큼 불순도가 감소하였다. 이 값이 6가지 후보 분할 중 최댓값이며, ②에서 가중 지니지수의 최솟값을 갖는 분할과 동치임을 확인할 수 있다.

문제 4. 배깅·부스팅·랜덤포레스트의 수식 비교

① 각 알고리즘의 수식

(가) 배깅 (Bagging — Bootstrap Aggregating)

원자료 $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^n$ 에서 **복원추출**로 동일 크기 부트스트랩 표본 $\mathcal{D}^{*b}$ ($b = 1, \dots, B$)를 B 개 생성하고, 각 표본 위에서 동일한 기저학습기를 학습시켜 $\hat{f}^{*b}$ 를 얻은 뒤 그 결과를 결합한다.

$$\hat{f}_{\text{bag}}(x) = \frac{1}{B} \sum_{b=1}^B \hat{f}^{*b}(x) \quad (\text{회귀}), \quad \hat{C}_{\text{bag}}(x) = \arg \max_k \sum_{b=1}^B 1\{\hat{C}^{*b}(x) = k\} \quad (\text{분류})$$

회귀에서는 단순 평균을, 분류에서는 다수결(majority voting)을 결합 규칙으로 사용한다. 모든 학습기는 서로 **독립적·병렬적**으로 적합되며, 관측치별 가중치는 항상 $1/n$ 로 균등하다. 핵심 효과는 학습기의 **분산(variance) 감소**이다.

(나) 부스팅 (AdaBoost.M1)

관측치 가중치 w_i 를 처음에 $w_i = 1/n$ 으로 초기화한 뒤, 각 단계 $m = 1, \dots, M$ 에서 다음을 반복한다.

- 가중치 w_i 를 반영한 자료에서 약학습기 $G_m(x)$ 를 적합한다.
- 가중 오분류율을 계산:

$$\text{err}_m = \frac{\sum_{i=1}^n w_i 1\{y_i \neq G_m(x_i)\}}{\sum_{i=1}^n w_i}.$$

- 학습기 가중치 $\alpha_m = \log \frac{1 - \text{err}_m}{\text{err}_m}$ 를 계산한다.
- 관측치 가중치를 갱신: $w_i \leftarrow w_i \cdot \exp(\alpha_m \cdot 1\{y_i \neq G_m(x_i)\})$.

최종 분류기는 M 개 약학습기의 **가중합**으로 결합된다.

$$G(x) = \text{sign} \left(\sum_{m=1}^M \alpha_m G_m(x) \right)$$

각 단계의 G_m 은 직전 단계의 가중치를 입력으로 받으므로 학습 과정이 **순차적·중속적**이다. 핵심 효과는 약한 학습기를 점진적으로 결합해 **편향(bias)**을 감소시키는 데 있다.

(다) 랜덤포레스트 (Random Forest)

배깅의 일반화 형태로, 부트스트랩 표본 $\mathcal{D}^{*b}$ 위에서 학습 트리 T_b 를 키울 때 **각 분할마다 p 개 입력변수 중 m 개를 무작위로 선택하여 그중 최적 변수를 분리에 사용한다**(트리 분할마다 후보 변수를 다시 추첨).

$$\hat{f}_{\text{rf}}(x) = \frac{1}{B} \sum_{b=1}^B T_b(x; \Theta_b), \quad \Theta_b = (\text{부트스트랩 표본, 분할 시 } m \text{ 개 변수 무작위 선택})$$

분류에서는 $m \approx \sqrt{p}$, 회귀에서는 $m \approx p/3$ 이 표준 권장값이다. 변수 무작위화는 트리 간 상관(correlation)을 줄여 **단순 배깅보다 분산 감소 효과를 더욱 강화**한다.

② 수식 비교 — 알고리즘별 구별 포인트

항목	배깅	부스팅	랜덤포레스트
표본 추출	부트스트랩	가중치 갱신(오분류 가중)	부트스트랩
변수 사용	모든 변수	모든 변수	분할마다 m 개 변수 무작위 선택
관측치 가중치	없음 (균등 $1/n$)	$w_i \leftarrow w_i \exp(\alpha_m)$ 로 갱신	없음
학습기 가중치	없음 (균등 $1/B$)	$\alpha_m = \log \frac{1 - \text{err}_m}{\text{err}_m}$	없음
학습 방식	병렬·독립	순차·중속	병렬·독립
결합 방식	단순 평균 / 다수결	학습기 가중합 $\sum \alpha_m G_m(x)$	단순 평균 / 다수결
주된 감소 대상	분산	편향	분산 (배깅보다 강함)

수식 기호 수준에서 결정적 차이는 다음 세 가지이다.

1. **결합식의 가중치(α_m)** — 배깅과 랜덤포레스트의 결합식에는 학습기별 가중치가 없는 균등 평균($\frac{1}{B} \sum$)이 등장하지만, 부스팅의 결합식 $\sum_{m=1}^M \alpha_m G_m(x)$ 에는 학습기별 가중치 α_m 이 명시적으로 포함된다. 이는 부스팅이 "좋은 학습기에 더 큰 발언권"을 주는 구조임을 뜻한다.
2. **관측치 가중치 갱신항($w_i \leftarrow w_i \exp(\alpha_m)$)** — 부스팅에만 존재하며, 오분류된 관측치의 가중치를 지수적으로 키운다. 배깅·랜덤포레스트의 부트스트랩 추출은 모든 관측치를 동일한 확률로 다루므로 이 항이 없다.
3. **무작위 변수 선택 메타 파라미터(m)** — 랜덤포레스트의 학습 파라미터 Θ_b 에 들어 있는 *분할 시 m 개 변수 무작위 선택* 항이 결정적 특징이다. 배깅에는 이 단계가 없어 모든 변수를 사용하며, 트리 간 상관이 높아질 위험을 안고 있다.

③ 극단값에 가장 예민한 양상불

결론: **부스팅(Boosting)**이 극단값(이상치, outlier)에 가장 예민하다.

근거:

1. **가중치 갱신식의 지수 폭증** — 부스팅은 매 단계마다 오분류된 관측치의 가중치를 $w_i \leftarrow w_i \cdot \exp(\alpha_m)$ 으로 갱신한다. 극단값·이상치는 일반 패턴과 동떨어져 있어 거의 매 단계 오분류되므로 그 가중치가 **반복마다 곱연산으로 누적**되어 지수적으로 증가한다. M 차례 반복 후 이상치 한 개의 가중치는 $\prod_m \exp(\alpha_m)$ 만큼 부풀어 올라, 약학습기 G_m 이 그 한 점을 맞추기 위해 결정경계를 휘어버리는 *과적합* 현상이 발생한다.
2. **결합식의 가중합** — 최종 분류기 $G(x) = \text{sign}(\sum \alpha_m G_m(x))$ 는 이상치에 반응한 약학습기들이 누적된 산물이므로, 이상치의 영향이 결합 단계에서 희석되지 않고 그대로 누적된다.
3. **배깅·랜덤포레스트의 희석 효과** — 두 방법은 모두 **단순 평균/다수결**로 결합되므로 어떤 한 부트스트랩 표본에서 이상치가 트리를 흔들어도 다른 $B - 1$ 개 트리의 예측에 의해 영향이 평균적으로 $1/B$ 수준으로 줄어든다. 또한 부트스트랩 표본은 약 63%의 원자료만 포함하므로(out-of-bag 비율 $\approx 37\%$) 평균적으로 보면 이상치가 트리에 들어가지 않는 표본도 많아 자연스럽게 영향이 분산된다.

따라서 수식의 *가중치 갱신항* 자체가 이상치에 지수적 가중을 부여하는 부스팅이 극단값에 가장 민감하게 반응하는 양상불 기법이라 결론지을 수 있다.
