

보기

- ④ $\neg, \perp, \sqsubset, \sqsupset$

④ 데이터 웨어하우스

제1장 데이터 마이닝이란 15

3. 다음 중 데이터 마이닝의 관련 분야인 KDD에 대한 설명으로 옳지 않은 것은?

- ① 데이터 마이닝과 유사한 의미로 지식을 추출하는 전 과정을 의미한다.
- ② 컴퓨터와 같은 하드웨어의 구성과 제작법 등을 익히는 과정이다.
- ③ 계획, 자료 획득, 분석, 해석 등의 과정을 주로 거친다.
- ④ OLAP도 넓은 의미에서 KDD의 한 과정으로 볼 수 있다.

정답 ②

해설 KDD는 데이터 마이닝과 가장 유사한 의미로 지식을 추출하는 전 과정을 의미하며, 하드웨어 구성 및 제작법을 익히는 것과는 연관성이 낮다.

4. 다음 중 출력결과가 알려진 자료로부터 입력변수와 출력변수 간의 관계를 결정하는 시스템을 규명하는 학습과정을 의미하는 것은?

- ① 지도학습 ② 자율학습
③ 지시학습 ④ 패턴인식

정답 ①

해설 지도학습은 출력결과가 알려진 자료로부터 입력변수와 출력변수 간의 관계를 결정하는 시스템을 규명하는 학습과정이다.

5. 다음 중 분류에 대한 설명으로 옳지 않은 것은?

- ① 입력변수가 모두 범주형이다.
- ② 나무모형을 이용해서 실행할 수 있다.
- ③ 지도학습에 속한다.
- ④ 목표변수는 반드시 범주형이어야 한다.

정답 ①

해설 입력변수가 반드시 범주형일 필요는 없다.

6. 다음 중 자율학습에 해당되는 것은?

- ① 선형회귀분석 ② 군집분석
③ 회귀나무분석 ④ 로지스틱회귀분석

정답 ②

해설 선형회귀분석, 회귀나무분석 및 로지스틱회귀분석은 지도학습의 예이고, 군집분석은 자율학습의 예이다.

7. 다음 중 목표마케팅, 고객세분화, 교차판매, 장바구니 분석 등의 데이터 마
이닝 응용 사례와 가장 관련이 깊은 분야는?

- [illegible]

정답 ③

해설 고객관계관리의 세부 분야로서 목표마케팅, 고객세분화, 고객성향 변동분석, 교차판매, 장바구니 분석 등을 꼽을 수 있다.

8. 데이터 마이닝 수행 단계를 7단계로 나눌 때, 다음 중 검증 데이터(test data)를 이용하여 가장 좋은 성능을 내는 모델 파라미터를 결정하는 단계로 알맞은 것은?

- ① 데이터 수집 ② 데이터 탐색
③ 모형선택 ④ 성능평가

정답 ③

해설 검증 데이터를 이용하여 가장 좋은 성능을 내는 모델 파라미터를 결정하는 단계는 모형선택단계이다.

- ① 최소제곱법 ② 최대잔차법
③ 잔차제곱법 ④ 가중평균법

해설 최소제공법은 잔차의 제곱합을 최소로하는 회귀직선 추정방법이다.

- ① 로짓 ② 이탈도
③ MAE ④ MSE

해설 이탈도는 최대로그우도(maximized log-likelihood) $\log(L_M)$ 에서 포화모형(saturated model)의 최대로그우도 $\log(L_S)$ 를 뺀 값에 -2 를 곱한 모형적합도의 측도이다.

- ① 로짓 ② 포화모형
③ 최대로그우도 ④ 전진선택법

해설 포화모형이란 각 관측값에 모수를 하나씩 사용한 완벽한 모형을 의미한다.

4. 다음 중 회귀모형에서 변수선택 방법이 아닌 것은?

- ① 전진선택법 ② 후진제거법
③ 단계별 선택법 ④ 부스팅 방법

정답 ④

해설 변수선택 방법으로는 전진선택, 후진제거법, 단계별 선택법 등이 있다.

5. 어느 대학교에서 입학 기준에 따른 학업만족도의 차이를 다양한 배경변수를 통제한 상태에서 비교하기 위해서 다중 선형 회귀분석을 실시하고자 한다. 입학 기준을 4개의 범주(신입, 편입, 복학, 재입학)로 측정한다고 할 때 입학 기준별 차이를 나타내는 가변수를 몇 개 만들어야 하는가?

- ① 1개 ② 2개
③ 3개 ④ 4개

정답 ③

해설 범주의 개수가 k 개인 범주형 변수에 대하여 $k-1$ 개의 가변수를 만든다.

6. 다음 중 아래 분류표와 관련하여 예측정확도를 바르게 계산한 것은?

구분	FALSE(0)	TRUE(1)
0	629	71
1	177	123

$$\begin{array}{ll} \textcircled{1} CCR = \left(\frac{629 + 123}{1,000} \right) \times 100\% & \textcircled{2} CCR = \left(\frac{71 + 177}{1,000} \right) \times 100\% \\ \textcircled{3} CCR = \left(\frac{629}{629 + 71} \right) \times 100\% & \textcircled{4} CCR = \left(\frac{629}{629 + 177} \right) \times 100\% \end{array}$$

정답 ①

구분		그룹 1	그룹 0	행 합계
관측	$Y = 1$	n_{11}	n_{10}	n_{1+}
결과	$Y = 0$	n_{01}	n_{00}	n_{0+}
합계		n_{+1}	n_{+0}	n

분류표가 위와 같을 때 예측정확도(정분류율) CCR은 아래와 같이 계산된다.

$$CCR = \left(\frac{n_{11} + n_{00}}{n} \right) \times 100\%$$

1. 다음 중 의사결정나무(나무모형)에 대한 설명 중 옳은 것은?

- ① 목표변수가 범주형 이항변수일 경우에만 분석이 가능하다.
- ② 이산형 자료의 처리가 불가능하다.
- ③ 과대적합을 방지하여 예측정확도가 높다.
- ④ 계산속도가 빠르다.

정답 ④

해설 의사결정나무는 이해하기 쉽고 이산형 자료도 처리가 가능하다. 다만, 이산형 변수의 수준이 많은 경우 결과가 정확하지 않을 수 있다. 또한 과대적합된 모형이 작성되기 쉬워서 예측력이 낮을 가능성이 높다.

2. 다음 중 아래 산식과 가장 연관성이 높은 불순도 함수의 종류는?

$$-\sum_j p(j|t) \times \log_2 p(j|t)$$

- ① Gini 함수
- ② entropy 함수
- ③ deviance 함수
- ④ geometry 함수

정답 ②

해설 불순도 함수의 종류로는 Gini 함수, entropy 함수, deviance 함수 등이 있는데, 산식은 entropy를 나타내는 수식이다.

3. 다음 중 CART의 편향 현상이 나타나는 이유로서 적절한 것은?

- ① 변수선택과 분할점 선택이 동시에 이루어지기 때문
- ② 변수선택의 단계와 관계없이 별도로 분할점을 선택하기 때문
- ③ 입력변수로서 범주형 변수를 허용하지 않기 때문
- ④ 목표변수로서 연속형 변수를 사용하기 때문

정답 ①

해설 CART의 편향 현상(selection bias)은 변수선택과 분할점 선택이 동시에 이루어지기 때문에 발생할 수 있다.

4. 다음 <보기> 중 의사결정나무의 가지치기와 관련된 사항으로 옳은 것은 모두 몇 개인가?

보기

- ㄱ. 의사결정나무의 크기와 나무모형의 불순도의 합인 cost-complexity를 최소화하는 나무모형의 집합이 결정된다.
- ㄴ. 가지치기의 목적은 의사결정나무의 과도적합을 방지하고 안정된 모형을 구하기 위함이다.
- ㄷ. cost-complexity 모수는 최소제곱법에 의해 추정할 수 있다.
- ㄹ. 의사결정나무의 가지치기 작업은 분할이 충분히 진행된 후 실시된다.

- ① 1개 ② 2개 ③ 3개 ④ 4개

정답 ③

해설 ㄱ, ㄴ, ㄹ이 옳은 설명이다.

5. 다음 중 의사결정나무의 가지치기와 거리가 먼 것을 고르면?

- ① 비용복잡함수(cost-complexity function)
- ② k-fold 교차타당성(cross-validation) 기법
- ③ 오분류율과 나무 크기를 동시에 고려
- ④ CHAID에서 사용하고 있는 방법으로 매 단계에서 분할의 통계적 유의성을 검정

정답 ④

해설 ④번은 분할정지 방법을 의미한다.

6. 다음 중 의사결정나무의 분할법칙과 관련된 설명으로 거리가 먼 것은?

- ① 해당 노드의 구성 클래스가 균등하게 되어 있을 때 불순도 함수값이 가장 작다.
- ② 분할은 분할 후 생성된 새로운 노드의 불순도 함수값의 감소가 가장 크게 일어나도록 진행된다.
- ③ 이산형 및 연속형 변수에 대하여 자료 특징에 맞는 분할 알고리즘이 적용된다.
- ④ 분할 알고리즘은 정렬과 목표변수 클래스의 집계와 같은 단순한 작업으로만 구성되므로 계산속도가 빠르다.

정답 ①

해설 분할기준이 되는 변수와 분할의 위치에 따라 불순도 함수의 값은 달라진다.

7. 의사결정나무의 특정 노드 t 에서의 분할원칙은?

- ① 순수도 함수값의 감소폭이 최대가 되도록 실행한다.
- ② 순수도 함수값의 감소폭이 최소가 되도록 실행한다.
- ③ 불순도 함수값의 감소폭이 최소가 되도록 실행한다.
- ④ 불순도 함수값의 감소폭이 최대가 되도록 실행한다.

정답 ④

해설 의사결정나무에서 분할원칙은 분할 후 불순도 감소 폭이 가장 최대가 되도록 실행하는 것이다.

8. 다음 의사결정나무에 관한 설명 중 옳지 않은 것은?

- ① 회귀나무모형은 분류를 위한 의사결정나무 알고리즘을 응용하여 구현할 수 있다.
- ② 목표변수가 이산형일 경우 데이터 적합이 불가능하다.
- ③ 비교적 이해하기 쉬운 모형이다.
- ④ 변수 간 교호작용 관계를 잘 나타낼 수 있다.

정답 ②

해설 목표변수가 이산형일 경우에도 분류나무모형과 같은 의사결정나무를 적합할 수 있다.

9. 의사결정나무의 가지치기와 관련된 다음의 설명 중 옳지 않은 것은?

- ① 가지치기란 의사결정나무를 최대로 만든 후, 가지가 많은 나무로부터 분류성능 향상에 큰 도움이 되지 못하는 가지를 잘라 내는 것을 의미한다.
- ② 가지치기의 목적은 의사결정나무의 과도적합을 방지하고 안정된 모형을 구하기 위함이다.
- ③ 의사결정나무의 크기와 불순도 합인 비용복잡(cost-complexity)함수를 이용한다.
- ④ cost-complexity의 모수는 최대우도추정법에 의해 추정하는 것이 일반적이다.

정답 ④

해설 cost-complexity의 모수는 k-fold 교차타당성(cross validation) 기법을 이용해 추정된다.

10. 의사결정나무에서 어떤 노드의 구성이 아래와 같이 속성 ■가 6개, ○가 1개였다고 할 때, 지니지수를 이용하여 불순도를 계산하면?



① 0.2449

② 0.7551

③ 0.1224

④ 0.8776

정답 ①

해설 $\frac{6}{7} \times \frac{1}{7} + \frac{1}{7} \times \frac{6}{7} = 0.2449$

11. 다음 중 회귀나무모형에서 사용하는 불순도 함수로 적절한 것은?

① Gini 지수

② entropy 지수

③ 각 노드 목표변수들의 관측값 분산

④ 각 노드 목표변수들의 표본평균

정답 ③

해설 회귀나무모형에서 사용되는 불순도 함수는 각 노드 목표변수들의 관측값 분산이다.

[illegible]

① 군집분석 ② 부스팅(boosting)
③ 배깅(bagging) ④ 랜덤포레스트(random forest)

① 신경망모형 ② 부스팅
③ 배깅 ④ 랜덤포레스트

해설 배깅은 부트스트랩 기법을 이용하고 단순 다수결 방식으로 예측값을 산출한다.

4. 다음 중 배깅 방법과 표본추출 방식의 아다부스트 방법과의 차이점으로 적절한 것은?

- ① 앙상블 방법과 단일모형 방법의 차이
- ② 균등확률 부트스트랩과 가중확률 부트스트랩 방법의 차이
- ③ 목표변수가 이산형인지 연속형인지의 차이
- ④ 자율학습 기법인지 지도학습 기법인지의 차이

정답 ②

해설 표본추출 방식의 아다부스트 방법은 부스팅의 한 가지 방법으로서 배깅은 부트스트랩 방법이 균등확률 방식이며, 표본추출 방식의 아다부스트는 부트스트랩 방법이 가중확률 방식이다.

5. 다음 중 랜덤포레스트 기법과 거리가 먼 것은?

- ① 의사결정나무
- ② 부트스트랩
- ③ 가중치 업데이트
- ④ 단순 다수결 방식

정답 ③

해설 가중치 업데이트는 부스팅 기법과 관계가 있다.

6. 다음 <보기> 중 랜덤포레스트, 배깅, 부스팅 기법에 관해 옳은 설명을 모두 고르면?

보기

- ㄱ. 여러 개의 서로 다른 예측모형을 생성하여 결합하는 방법이다.
- ㄴ. 단일 모형에 비해 계산량이 증가한다.
- ㄷ. 동일 환경하에서 단일 모형에 비해 계산속도가 현저하게 빨라진다.
- ㄹ. 단일 모형에 비해 예측의 정확도가 높아진다.

- ① ㄱ, ㄴ
- ② ㄴ, ㄷ
- ③ ㄱ, ㄴ, ㄷ
- ④ ㄴ, ㄷ, ㄹ

정답 ③

해설 여러 개의 서로 다른 모형을 결합하는 앙상블 기법을 적용하면 예측의 정확도는 높아지지만 계산량이 많아지는 단점이 있다.

7. 다음 중 <보기>의 알고리즘과 가장 관계가 깊은 것은?

보기

- ① 훈련 데이터 $L = \{(x_i, y_i), i = 1, \dots, n\}$ 을 정의. 여기서 x_i 는 입력변수 벡터이고 y_i 는 목표변수
- ② 가중치 $w_i = \frac{1}{n}, i = 1, \dots, n$ 을 초기화
- ③ $b = 1, \dots, B$ 에 대하여 다음의 과정을 반복 수행
 - ㉠ 가중치 w_i 를 이용하여 가중확률 부트스트랩으로 데이터 L_b 를 생성
 - ㉡ L_b 를 이용하여 $T_b(x)$ 를 생성
 - ㉢ $T_b(x)$ 를 L 에 적용하여 각 데이터의 오분류 여부를 판별
 - ㉣ Err_b 를 다음과 같이 계산

$$Err_b = \sum_i^n w_i I[y_i \neq T_b(x_i)]$$

- ㉤ 분류기의 중요도 α_b 를 다음과 같이 계산

$$\alpha_b = \frac{1}{2} \log \frac{1 - Err_b}{Err_b}$$

- ㉦ 가중치 w_i 를 다음과 같이 업데이트

$$w_i = \frac{w_i}{Z} \exp\{\alpha_b I[y_i \neq T_b(x_i)] - \alpha_b I[y_i = T_b(x_i)]\} \quad (\text{단, } i = 1, \dots, n)$$

여기서 Z 는 w_i 의 합이 1이 되도록 만들기 위한 상수

- ④ 위의 ③에서 생성한 B 개의 분류기를 결합하여 최종 예측모형 $\hat{f}(x)$ 를 생성

$$\hat{f}(x) = \arg \max_j \left\{ \sum_{b=1}^B \alpha_b I(T_b(x) = j), j = 1, \dots, J \right\}$$

여기서 x 는 예측하고자 하는 관찰값의 입력변수 벡터값

- ① 가중치 조정방식의 아다부스트(AdaBoost) 방법
- ② 표본추출 방식의 아다부스트(AdaBoost) 방법
- ③ 배깅(bagging)
- ④ 랜덤포레스트(random forest)

정답 ②

해설 보기는 표본추출 방식의 아다부스트 방법이다.

8. 양상불 기법인 배깅을 의사결정나무에 적용할 때 단일 의사결정나무와 비교한 설명 중 바른 것은?

- ① 예측의 정확도가 높아지고 계산량이 많아진다.
- ② 예측의 정확도가 떨어지고 계산량이 많아진다.
- ③ 예측의 정확도가 높아지고 계산량이 적어진다.
- ④ 예측의 정확도가 떨어지고 계산량이 적어진다.

정답 ①

해설 앙상블 기법을 적용하면 예측의 정확도는 높아지지만 계산량이 많아지는 단점이 있다.

9. 다음 중 R의 randomForest 패키지에서 의미 있는 변수를 시각화하기 위해 사용하는 함수로서 가장 적당한 것은?

- ① varImpPlot ② plot
③ predict ④ step

정답 ①

해설 R의 랜덤포레스트 패키지에서 중요변수를 바차트 그래프로 시각화하는 함수는 varImpPlot이다.

- ① 뛰어난 병렬성(parallelism)
- ② 결함 허용(fault tolerance) 능력
- ③ 각 독립적인 과업을 수행하는 뉴런의 연결
- ④ 뉴런이 많은 연결망을 통해 연결되어 있으므로 일부 뉴런의 문제가 발생하면 신경망 전체에 큰 영향을 미침

해설 정보가 많은 연결망을 통해 분산되어 있으므로 일부 뉴런의 문제가 발생하여도 신경망 전체에 큰 영향을 주게 될 가능성이 낮다.

[illegible]

해설 입력정보의 합성값을 출력층 또는 은닉층에 전달하는 함수로서 입력정보의 결합 값을 일정 범위의 값으로 변환해 주는 함수는 활성화함수이다.

- ① 신경망분석은 연산속도가 빠르며 결과를 이해하기 쉽다.
- ② 신경망분석은 분석결과가 어떻게 나왔는지 분석과정을 알 수 없다.
- ③ 입력변수로는 연속형 변수만 이용할 수 있다.
- ④ 출력변수는 항상 0과 1의 이항형의 값을 나타낸다.

해설 신경망분석은 과정이 투명하지 않고 복잡하여 신경망이 분류하더라도 왜 그렇게 분류하였는지 설명하지 못한다는 단점이 있다.

4. 신경망모형의 역전파 알고리즘에 대하여 바르게 기술한 것은?

- ① 활성함수를 선택하는 방법이다.
- ② 은닉층의 마디 수를 설정하는 방법이다.
- ③ 신경망의 가중치를 결정하는 방법이다.
- ④ 활성함수의 역변환 방법이다.

정답 ③

해설 신경망모형의 역전파 알고리즘은 신경망의 가중치를 결정하는 방법이다.

5. 신경망모형에서 1개의 은닉층을 가진 모형을 적합했더니 마디 수가 지나치게 많았다고 한다. 이 경우 최적모형을 찾는 방법으로 다음 중 가장 적절한 것은?

- ① 은닉층을 그대로 유지한 채로 연속형 입력변수를 제거하고 모형을 적합해 본다.
- ② 은닉층을 그대로 유지한 채로 범주형 입력변수를 제거하고 모형을 적합해 본다.
- ③ 은닉층을 생략하고 입력층과 출력층으로만 모형을 적합해 본다.
- ④ 은닉층의 수를 2개로 증가시켜 모형을 적합해 본다.

정답 ④

해설 1개의 은닉층의 마디 수가 지나치게 많아지면, 은닉층의 수를 2개로 증가시켜 신경망을 작성하는 것이 바람직하다.

6. 신경망에서 목적함수를 최적화하는 가중치를 찾고자 한다. 여기서 초기값을 주고 새로 구한 값과 초기값이 비슷해질 때까지 반복하여 그 값이 수렴하면 그 값으로 가중치를 정하는 방법을 무엇이라 하는가?

- ① 지도학습 ② 역전파 알고리즘
③ 자율학습 ④ 앙상블 기법

정답 ②

해설 역전파 알고리즘은 초기값을 주고 새로 구한 값과 초기값이 비슷해질 때까지 반복하여 그 값이 수렴하면 그 값으로 가중치를 정하는 방법이다.

※ [7~8] 다음은 신경망모형을 작성하는 프로그램이다. 물음에 답하라.

```
> install.packages("㊦ ")
> library(㊦ )
> set.seed(130)
> ind1 = 1:100
> ind2 = ind1/100
> cos2 = cos(ind2*4*pi)
> cdat = data.frame(cbind(ind2, cos2))
> cos2.nn = (㊧) (cos2~ind2, data = cdat, hidden = 5, linear.output = T)
> plot(cos2.nn)
> cos.pred = (㊨) (cos2.nn, data.frame(ind2))
> plot(ind1, cos.pred)
> lines(cos2)
```

7. 다음 중 신경망모형을 작성하기 위한 패키지 및 함수로서 ㉠에 들어가야 할 것으로 적절한 것은?

- ① neuralnet
 - ② randomNet
 - ③ neuron
 - ④ randomForest

정답 ①

해설 신경망모형 작성을 위한 패키지 및 함수명은 neuralnet 등이 있다.

8. 다음 중 신경망모형을 바탕으로 새로운 예측값을 예측하기 위해 사용하는 함수로서 ㉠에 들어가야 할 것으로 적절한 것은?

- ① predict ② estimate
③ forecast ④ optimize

정답 ①

해설 neuralnet 패키지에서 작성된 신경망모형을 이용하여 새로운 예에 적용하여 결과를 도출하는 함수는 predict이다.

9. 신경망모형의 연결강도, 즉 가중치를 구하기 위한 방법으로 역전파 알고리즘이 있다. 다음 <보기> 중 역전파 알고리즘의 설명으로 옳은 것을 모두 고르면?

보기

- ㄱ. 첫 단계에서는 초기 가중치와 목표함수를 최적화하는 기준을 정하고 초기 가중치를 바탕으로 출력값을 계산한다.
- ㄴ. 두 번째 단계에서는 실제값과 예측값 사이의 오차를 계산한다.
- ㄷ. 마지막 단계에서는 2단계에서 구한 오차를 은닉층과 입력층에 거꾸로 적용시켜 연결가중치를 새로 조절한다.
- ㄹ. 가중치 조절 단계를 반복 적용하다가 가중치가 일정 수준 이상으로 커지면 반복을 멈추고 그 값으로 가중치를 정하게 되는데, 이 경우 대체로 목표함수의 값이 최대가 된다.

- ① ㄱ, ㄴ
- ② ㄱ, ㄴ, ㄹ
- ③ ㄱ, ㄴ, ㄷ
- ④ ㄱ, ㄴ, ㄷ, ㄹ

정답 ③

해설 ㄹ이 잘못된 설명이다. 단계를 반복하여 가중치가 거의 변하지 않거나 일정해지면 반복을 멈추고 그 값으로 가중치를 정한다.

10. 다음 중 신경망모형과 관련한 설명으로 옳지 않은 것은?

- ① 많은 입력변수를 가지고 있다.
- ② 신경망은 입력층, 복합층, 은닉층 등으로 구성된다.
- ③ 입력변수와 출력변수 간 관계가 복잡한 비선형일 때 유용하다.
- ④ 분석결과가 어떻게 나왔는지 분석과정을 상세하게 알 수 없다.

정답 ②

해설 신경망은 입력층, 출력층, 은닉층으로 구성되어 있다.

11. 연속형 자료를 입력변수값이 0과 1 사이에 있도록 표준화하고자 한다. 적절한 방법은?

$$\textcircled{1} \text{ 조정된 변수값} = \frac{\text{실제값} - \text{평균}}{\text{표준편차}}$$

$$\textcircled{2} \text{ 조정된 변수값} = \frac{\text{실제값} + \text{평균}}{\text{표준편차}}$$

$$\textcircled{3} \text{ 조정된 변수값} = \frac{\text{최댓값} - \text{실제값}}{\text{최댓값} - \text{최솟값}}$$

$$\textcircled{4} \text{ 조정된 변수값} = \frac{\text{실제값} - \text{최솟값}}{\text{최댓값} - \text{최솟값}}$$

정답 ④

해설 실제값에서 최솟값을 빼고, 이 값을 최댓값과 최솟값의 차이로 나누어 표준화하게 된다.

12. 아래 <보기>는 신경망의 불투명성을 완화하기 위한 민감도분석의 3단계 구성이다. () 안에 가장 적당한 것은?

보기

첫째, 입력변수 각각의 ()를(을) 찾는다.

둘째, 입력변수들의 평균값에서 출력변수값을 구한다.

셋째, 각 입력변수값이 변할 때마다 출력변수의 변화를 측정한다.

① 평균

② 최댓값과 최솟값

③ 사분위수

④ 중안값

정답 ①

해설 입력변수 각각의 평균을 찾는 것이 민감도분석의 첫 번째 단계이다.

1. 다음 <보기> 중 목표변수가 연속형일 때와 이항형일 때 사용하는 모형으로 옳게 짝지어진 것은 모두 몇 개인가?

보기

- ㄱ. 연속형-신경망모형
ㄴ. 연속형-회귀나무모형

- ㄷ. 이항형-로지스틱회귀모형
ㄹ. 이항형-랜덤포레스트모형

- ① 1개 ② 2개 ③ 3개 ④ 4개

정답 ④

해설 목표변수의 형태에 관계없이 모두 적용이 가능한 모형이 있는 반면, 특정 형태의 목표변수에 사용이 제한되는 모형도 있다. 위의 보기는 모두 옳다.

2. 다음 중 목표변수가 연속형일 경우, 모형의 성능을 평가하는 지표로 사용될 수 있는 것은?

- ① MSE ② 민감도 ③ 특이도 ④ 향상도

정답 ①

해설 MSE(Mean Squared Error)는 평균제곱오차로 예측력을 나타내는 척도이다.

3. 다음 중 관측값과 예측값의 차이 척도로서 $\sum_{i=1}^n |y_i - \hat{y}_i|/n$ 과 같이 개별 관측값과 예측값 차의 절댓값의 평균으로 모형의 성능을 평가하는 지표는?

- ① MSE ② 민감도 ③ 특이도 ④ MAE

정답 ④

해설 MAE(Mean Absolute Error, 평균절대오차)는 예측력을 나타내는 척도이다.

4. 다음 중 여러 가능한 임계치에 대해 '1-특이도'를 가로축에, 민감도를 세로축에 놓고 그린 그래프를 의미하는 것은?

- 정답** ④

5. 다음 중 목표변수가 연속형인 경우에 사용하는 모형의 예측력 측도로서 가장 적절한 것은?

- 정답** ①

6. 다음 <보기> 중 아래 정오분류표와 관련된 예측력 평가측도로서 옳은 것을 모두 고르면?

구분		예측범주		합계
		1	0	
실제범주	1	n_{11}	n_{10}	n_{1+}
	0	n_{01}	n_{00}	n_{0+}
합계		n_{+1}	n_{+0}	n

$$\begin{aligned} \text{ㄷ. 오분류율} &= Pr(\hat{Y} \neq 0, Y = 1) + Pr(\hat{Y} \neq 1, Y = 0) \\ &= (n_{10} + n_{01})/n \end{aligned}$$

- ② ㄴ, ㄷ
- ④ ㄱ, ㄴ, ㄷ, ㄹ

정답 ③

해설 이항형의 목표변수 예측과 관련하여 예측력을 평가하는 지표로서 민감도, 특이도, 예측정확도, 오분류율 등을 꼽을 수 있다. 2. 오분류율 = $Pr(\hat{Y} \neq 1, Y = 1) + Pr(\hat{Y} \neq 0, Y = 0) = (n_{10} + n_{01})/n$ 로 수정되어야 한다.

7. 패키지 ROCR에서 제공하는 함수 prediction에 관한 설명으로 옳은 것은?

- ① 예측값을 계산할 때 사용된다.
- ② 잔차를 직접적으로 출력할 때 사용된다.
- ③ 나무형 그림을 효과적으로 출력해 준다.
- ④ 중요 변수를 산출할 때 사용된다.

정답 ①

해설 ROCR에서 제공하는 함수 prediction은 예측값을 계산할 때 사용된다.

8. 패키지 ROCR에서 제공하는 함수 performance에 관한 설명으로 옳은 것은?

- ① 예측값을 계산할 때 사용된다.
- ② 잔차를 직접적으로 출력할 때 사용된다.
- ③ 나무형 그림을 효과적으로 출력해 준다.
- ④ 민감도, 특이도, 예측정확도, 오분류율 등을 산출할 때 사용된다.

정답 ④

해설 ROCR에서 제공하는 함수 performance는 예측력을 출력할 때 사용된다.

9. 다음 중 패키지 caret에서 제공하는 함수로서 데이터를 훈련용과 검증용 그룹으로 분할할 때 목표변수의 비율을 고려하여 데이터 분할을 실시해 주는 함수로서 옳은 것은?

- ① sample
- ② createDataPartition
- ③ runif
- ④ randomForest

정답 ②

해설 함수 createDataPartition은 패키지 caret에서 제공하는 함수로서 데이터를 훈련용과 검증용 그룹으로 분할할 때 사용한다.

1. 다음 <보기> 중 군집분석에 대해 옳은 설명을 모두 고르면?

보기

- ㄱ. 계층적 군집분석은 구현이 간단하여 절차를 이해하기 쉽다.
 ㄴ. K-평균 군집화는 초기값의 영향을 받아 결과가 국소최적이 될 수 있다.
 ㄷ. 대용량의 데이터를 가지고 군집분석을 실시할 때에는 비계층적 군집분석보다는 계층적 군집분석 방법을 이용하는 것이 좋다.
 ㄹ. 계층적 군집분석에서는 개체가 잘못된 군집에 속하게 되면 그것을 수정할 기회가 없다.

① ㄱ, ㄴ, ㄷ

② ㄴ, ㄷ, ㄹ

③ ㄱ, ㄴ, ㄹ

④ ㄱ, ㄴ, ㄷ, ㄹ

정답 ③

해설 대용량의 데이터를 가지고 군집분석을 실시할 때에는 비계층적 군집분석 방법인 K-평균 군집분석을 사용한다.

2. 다음의 비유사성 측도 중 두 지점의 단순한 거리뿐만 아니라, 변수의 특성을 나타내는 분산과 공분산이 함께 고려되는 것은?

① 코사인 거리

② 유클리디안 거리

③ 마할라노비스 거리

④ 민코브스키 거리

정답 ③

해설 마할라노비스 거리는 두 지점의 단순한 거리뿐만 아니라, 변수의 특성을 나타내는 분산과 공분산이 함께 고려된다.

3. 계층적 군집분석 방법 중 두 군집 P 와 Q 간의 거리를 P 에 속한 개체와 Q 에 속한 개체 간의 거리 중 가장 먼 거리를 두 군집 간의 거리로 하는 방법은?

① 단일연결법

② 완전연결법

③ 평균연결법

④ 분산연결법

정답 ②

해설 완전연결법은 두 군집 P 와 Q 간의 거리를 P 에 속한 개체와 Q 에 속한 개체 간의 거리 중 가장 먼 거리를 두 군집 간의 거리로 하는 방법이다.

4. 다음 <보기>의 설명 중 완전연결법에 관한 설명으로 옳은 것은 몇 개인가?

보기

- ㄱ. 단일연결법에 비해 대체로 이상치나 잡음의 존재에 영향을 덜 받음
- ㄴ. 관측값이 서로 매우 유사하여 밀집되어 있는 군집을 구별하는 데 적절
- ㄷ. 계층적 군집분석 방법 중 응집분석에서 군집 간 거리를 정의하는 기준
- ㄹ. 완전연결법을 사용할 때 거리의 정의는 '맨해튼 거리'만 허용

- ① 1개 ② 2개 ③ 3개 ④ 4개

정답 ③

해설 ㄱ, ㄴ, ㄷ이 완전연결법에 관해 옳은 설명이다.

5. 비계층적 군집분석 방법으로서 군집 수를 미리 정하고 중심점으로부터 거리를 계산하여 군집을 구하는 방법은?

- ① 응집분석 ② K-분산 군집분석
③ 분할분석 ④ K-평균 군집분석

정답 ④

해설 K-평균 군집분석은 비계층적 군집화에서 군집 수를 미리 정하고 중심점으로부터 거리를 계산하여 군집을 구하는 방법이다.

6. 다음 중 군집분석 방법에서 이상점의 영향을 가장 많이 받는 방법은?

- ① 단일연결법을 이용한 응집분석
② 완전연결법을 이용한 응집분석
③ 분할분석법
④ K-평균 군집분석

정답 ④

해설 K-평균 군집분석은 이상치의 영향을 가장 많이 받는 방법이다.

7. 다음 중 자율학습에 해당되는 것은?

- ① 회귀분석 ② 군집분석
③ 판별분석 ④ 시계열분석

정답 ②

해설 군집분석은 자율학습으로 분류된다.

8. 군집분석에서 두 군집 P 와 Q 간의 거리를 P 에 속한 개체와 Q 에 속한 개체 간의 거리 중 가장 가까운 거리를 두 군집 간의 거리로 하는 방법은?

- ① 단일연결법 ② 완전연결법
③ 평균연결법 ④ 워드연결법

정답 ①

해설 단일연결법은 두 군집 P 와 Q 간의 거리를 P 에 속한 개체와 Q 에 속한 개체 간의 거리 중 가장 가까운 거리를 두 군집 간의 거리로 하는 방법이다.

※ [9~11] 다음과 같이 5개의 개체 간 비유사성 행렬의 하삼각 행렬이 주어졌다고 하자. 다음 물음에 답하라.

$$\begin{matrix} & 1 & 2 & 3 & 4 & 5 \\ \begin{matrix} 1 \\ 2 \\ 3 \\ 4 \\ 5 \end{matrix} & \left(\begin{array}{ccccc} 0 & & & A & \\ 1.0 & 0 & & & \\ 5.0 & 4.0 & 0 & & \\ 8.0 & 7.0 & 3.0 & 0 & \\ 10.5 & 9.5 & 5.5 & 2.5 & 0 \end{array} \right) \end{matrix}$$

9. 비유사성 행렬의 빈 곳을 채워 완성할 경우 A의 값으로 적당한 것은?

- ① 1.0 ② 8.0 ③ 7.0 ④ 10.5

정답 ②

해설 비유사성 행렬은 대칭행렬이므로 1행 4열의 값은 4행 1열의 값과 같다.

10. 단일연결법에 의한 군집분석을 수행할 경우 첫 번째 생성되는 군집으로 가장 적당한 것은?

① {1, 2}

② {4, 5}

③ {3, 4}

④ {1, 5}

정답 ①

해설 가장 가까운 두 개체 1과 2를 합쳐서 최초의 군집 {1, 2}가 생성된다.

11. 완전연결법에 의한 군집분석을 수행할 경우 군집 {1, 2}와 각 개체와의 거리 행렬은 다음과 같이 생성된다. A의 값으로 가장 적당한 것은?

$$\begin{array}{c} \{1,2\} \\ 3 \\ 4 \\ 5 \end{array} \begin{pmatrix} \{1,2\} & 3 & 4 & 5 \\ 0 & A & B & C \\ A & 0 & 3.0 & 5.5 \\ B & 3.0 & 0 & 2.5 \\ C & 5.5 & 2.5 & 0 \end{pmatrix}$$

① 1.0

② 5.0

③ 8.0

④ 10.5

정답 ②

해설 군집 {1, 2}와 군집 {3}과의 완전연결법에 의한 거리는 비유사성 행렬에서 개체 1과 2의 거리(=5)와 개체 2와 3의 거리(=4) 중 큰 것을 선택하면 되므로 5가 된다.

- ① 입력변수가 없는 직관적인 분석으로 이해하기 쉽다.
- ② 대용량 자료분석에 앞서 탐색적 방법으로 활용할 수 있다.
- ③ 알고리즘이 복잡하여 계산속도가 매우 느다.
- ④ 거래가 드문 품목에 대한 분석에 유용하다.

해설 연관규칙은 대용량 자료분석에 앞서 탐색적 방법으로 활용될 수 있다.

① 지지율 ② 신뢰도
③ 오분류율 ④ 향상도

해설 연관규칙의 평가측도로는 지지율, 신뢰도, 향상도가 사용된다.

(ㄱ)	(ㄴ)
① 목표변수	입력변수
② 입력변수	목표변수
③ 종속변수	지니지수
④ 지니지수	종속변수

해설 연관규칙이란 어떤 사건 발생 간의 관계를 표현하는 규칙을 의미하는 것으로 목표변수 없이 개체들의 입력변수만을 가지고 분석한다.

4. A 품목을 구매하는 사건을 S_A , B 품목을 구매하는 사건을 S_B 라고 할 때, 다음 중 확률 개념을 적용한 지지율의 표현방식으로 옳은 것은?

- ① 지지율 = $P(S_A \cap S_B)$ ② 지지율 = $P(S_A | S_B)$
 ③ 지지율 = $P(S_A - S_B)$ ④ 지지율 = $P(S_A^C \cap S_B)$

정답 ①

해설 'A→B'의 지지율 = $P(S_A \cap S_B) = \frac{A와 B를 포함한 거래 수}{전체 거래 수}$ 이다.

※ [5~7] 다음은 어느 식료품점의 거래자료이다. 다음 물음에 답하라.

거래	품목
1	소주, 맥주, 와인
2	소주, 콜라, 와인
3	소주, 오렌지주스, 콜라
4	콜라, 맥주, 와인
5	소주, 콜라, 맥주
6	오렌지주스, 와인

5. 연관규칙 '와인→오렌지주스'에 대한 지지율은?

- ① 16.7% ② 25% ③ 33% ④ 45%

정답 ①

해설 'A→B'의 지지율 = $\frac{A와 B를 포함한 거래 수}{전체 거래 수}$ 이므로 와인과 오렌지주스를 포함한 거래 수를 전체 거래 수로 나누면 $\frac{1}{6} = 0.16666$ 이다.

6. 연관규칙 '와인→오렌지주스'에 대한 신뢰도는?

- ① 0.167 ② 0.25 ③ 33.3 ④ 0.45

정답 ②

해설 'A→B'의 신뢰도 = $\frac{A와 B를 포함한 거래 수}{A를 포함한 거래 수}$ 이므로 와인과 오렌지주스를 포함한 거래 수를 와인을 포함한 거래 수로 나누면 $\frac{1}{4} = 0.25$ 이다.

7. 연관규칙 '와인→오렌지주스'에 대한 향상도는?

① 0.75

② 1

③ 1.25

④ 1.5

정답 ①

해설 'A→B'의 향상도 = $\frac{\text{'A→B'의 신뢰도}}{\text{B를 포함한 거래비율}}$ 이므로 $\frac{0.25}{\frac{2}{6}} = 0.75$ 이다.

※ [8~10] 다음은 어떤 문구점의 순차적 거래자료이다. 다음 물음에 답하라.

거래	구매순서	구매품목
1	1	볼펜
	2	바인더
	3	자
2	1	노트
	2	볼펜
	3	잉크
	4	만년필
3	1	볼펜
	2	만년필
	3	잉크
	4	노트
4	1	볼펜
	2	노트
	3	만년필
	4	자
5	1	바인더
	2	노트
	3	볼펜

8. 시차연관규칙 '노트→만년필'의 지지율을 구하면?

- ① 20% ② 30% ③ 40% ④ 50%

정답 ③

해설 'A→B'의 지지율 = $\frac{A를\ 구매한\ 후\ B를\ 구매한\ 거래\ 수}{전체\ 거래\ 수}$ 이므로 $\frac{2}{5} = 0.4$ 이다.

9. 시차연관규칙 '노트→만년필'의 신뢰도를 구하면?

- ① 0.2 ② 0.30 ③ 0.4 ④ 0.5

정답 ④

해설 'A→B'의 신뢰도 = $\frac{A를\ 구매한\ 후\ B를\ 구매한\ 거래\ 수}{A를\ 포함한\ 거래\ 수}$ 이므로 $\frac{2}{4} = 0.5$ 이다.

10. 시차연관규칙 '노트→만년필'의 향상도를 구하면?

- ① 0.333 ② 0.25 ③ 0.5 ④ 0.833

정답 ④

해설 'A→B'의 향상도 = $\frac{'A→B'의\ 신뢰도}{B를\ 포함한\ 거래비율}$ 이므로 $\frac{0.5}{\frac{3}{5}} = 0.833$ 이다.

11. 연관성분석은 품목 수가 증가할 경우 분석이 어려워지는 단점이 있다. 다음 중 이러한 단점으로서 적절하지 않은 것은?

- ① 계산량이 급격히 늘어나게 된다.
 ② 유사한 품목을 한 범주로 일반화해야 하는데, 적절한 품목 결정이 쉽지 않다.
 ③ 수천 가지의 품목을 모두 분석에 그대로 사용할 경우 수많은 연관규칙이 발견되므로 유용한 규칙을 한정하여 찾기 어렵다는 제약이 있다.
 ④ 거래가 드문 품목의 정보는 손쉽게 이용할 수 있으므로 품목 수가 증가할 경우 드문 품목의 정보만으로 연관규칙을 찾아내야 하는 제약이 있다.

정답 ④

해설 연관성 분석은 일반적으로 거래가 드문 품목에 대한 정보를 찾기 어려운 단점이 있다.