

연습문제

1. 어떤 큰 공장에서 동일한 기계들의 정비기록에 관한 표본자료를 취하였다. 이는 기계의 사용연도(age of machines)와 정비비용(maintenance cost) 간에 어떤 관계가 있는지를 밝혀내기 위한 것이다. 자료는 다음과 같다 (표본의 크기 $n = 14$).

〈ex1-1.csv〉

사용연도 (단위: 년) x	정비비용 (단위: 1,000원) y	사용연도 (단위: 년) x	정비비용 (단위: 1,000원) y
3	39	6	90
1	24	9	140
5	115	3	112
8	105	5	70
1	50	7	186
4	86	2	43
2	67	6	126

- 이 자료의 산점도를 그리고, 회귀직선을 적합시키시오.
 - 결정계수와 상관계수를 구하시오.
 - 분산분석표를 작성하고 회귀직선의 유의 여부를 검정하시오(유의수준 $\alpha = 0.05$ 사용).
 - 사용연도가 4년인 기계의 평균정비비용은 어느 정도일지 추정하시오.
 - 잔차 $e_i = y_i - \hat{y}_i$ 를 구하여 잔차의 합이 0임을 확인하시오.
 - 잔차들의 x_i 에 대한 가중합 $\sum x_i e_i$ 를 구하시오.
 - 잔차들의 $\hat{y}_i$ 에 대한 가중합 $\sum \hat{y}_i e_i$ 를 구하시오.
2. 자동차의 무게가 무거우면 이를 움직이는 데 더 많은 연료가 소모된다는 것은 알려진 사실이다. 자동차의 무게와 자동차를 1km 움직이는 데 필요한 에너지의 양과의 함수관계를 정확히 판단하기 위하여 A자동차회사는 다음의 자료를 실험을 통하여 얻었다. 실험비용이 많이 드는 관계로 9번만 실험하였다.

<ex1-2.csv>

무게 (단위: 1,000kg) x	에너지 소모량 (단위: 1,000Btu) y	무게 (단위: 1,000kg) x	에너지 소모량 (단위: 1,000Btu) y
0.9	2.0	1.7	3.2
1.3	2.6	0.7	1.8
2.1	4.3	1.2	2.3
2.5	5.8	1.6	3.0
2.4	5.1		

- 1) x 에 대한 y 의 회귀직선을 구하시오. 이 자료의 산점도를 그리고, 회귀직선을 산점도 위에 그려 넣으시오.
 - 2) 분산분석표를 작성하고 회귀직선의 유의 여부를 검정하시오(유의수준 $\alpha = 0.05$ 사용).
 - 3) 무게가 3,000kg이 되는 차량의 에너지 소모량은 어느 정도일지 추정하시오.
3. 어떤 회사의 과거 10년간 판매실적은 다음과 같다. 변환된 x_i 의 값은 연도를 표시한다. 즉, $x_i = 0$ 은 1983년을 상징한다.

<ex1-3.csv>

연도	1983	1984	1985	1986	1987	1988	1989	1990	1991	1992
x_i	0	1	2	3	4	5	6	7	8	9
y_i	120	135	162	181	215	234	277	313	374	422

(y 의 단위: 억 원)

- 1) 회귀방정식을 구하고, 분산분석표를 작성하시오.
 - 2) 각 x_i 에서 $\hat{y}_i$ 와 잔차 $y_i - \hat{y}_i$ 를 구하고 잔차그림을 그리시오. 잔차가 가장 큰 연도는 언제인가?
4. 다음은 소득과 행복지수의 관계를 알기 위한 가상자료이다. 반응변수를 happiness로 한 단순회귀모형을 적합하고, 결과를 설명하시오.

<income_data.csv>

	income	happiness
1	3.862647	2.314489
2	4.979381	3.43349
3	4.923957	4.599373
4	3.214372	2.791114
5	7.196409	5.596398
...		

자료출처: <https://www.scribbr.com/statistics/simple-linear-regression/>

5. 다음은 1950년대 미국의 각 주별 피부암 사망자(number of deaths per 10 million people) 관련 자료의 일부이다. 반응변수는 Mort, 독립변수는 latitude인 단순회귀모형을 적합하고, 결과를 해석하시오.

<skincancer.txt>

State	Lat	Mort	Ocean	Long
Alabama	33.0	219	1	87.0
Arizona	34.5	160	0	112.0
Arkansas	35.0	170	0	92.5
California	37.5	182	1	119.5
Colorado	39.0	149	0	105.5
...				

자료출처: <https://online.stat.psu.edu/stat462/node/91/>

※ 참고: 자료파일은 다음과 같이 읽으면 된다.

```
> skin = read.table("c:/data/reg/skincancer.txt", header=T)
> head(skin)

  State Lat Mort Ocean Long
1 Alabama 33.0 219    1  87.0
2 Arizona 34.5 160    0 112.0
3 Arkansas 35.0 170    0  92.5
4 California 37.5 182    1 119.5
5 Colorado 39.0 149    0 105.5
6 Connecticut 41.8 159    1  72.8
```

6. 다음 자료는 유명한 1877년 Galton data이다.

X = Parent (pea diameter in inches of parent plant)

Y = Progeny (average pea diameter in inches of up to 10 plants grown from seeds of the parent plant).

SD = standard deviations of the offspring peas grown from each parent.

<galton.csv>

Parent	Progeny	SD
0.21	0.1726	0.01988
0.2	0.1707	0.01938
0.19	0.1637	0.01896
0.18	0.164	0.02037
0.17	0.1613	0.01654
0.16	0.1617	0.01594
0.15	0.1598	0.01763

자료출처: <https://online.stat.psu.edu/stat501/lesson/13/13.1>

- 1) 단순회귀직선을 적합하시오.
- 2) 가중값 $w_i = 1/sd_i^2$ 으로 하여 가중회귀직선을 적합하시오.
- 3) 두 변수의 산점도에 적합된 회귀선 및 가중회귀직선을 그리고, 두 회귀선을 비교하여 설명하시오.

연습문제

1. 어떤 공장에서 나오는 제품의 강도(kg/cm^2)가 그 공정의 온도와 압력에 어떠한 영향을 받는지를 조사하기 위하여 다음의 자료를 얻었다.

<ex2-1.csv>

공정온도(X_1) (단위: $^{\circ}\text{C}$)	공정압력(X_2) (단위: psi)	강도(Y) (단위: kg/cm^2)
195	57	81.4
179	61	122.0
205	60	101.7
204	62	175.6
201	61	150.3
184	54	64.8
210	58	92.1
209	61	113.8

- 1) 선형회귀모형 $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \epsilon$ 이 성립된다고 가정하고 자료로부터 회귀모형을 추정하고, 모형을 해석하시오.
- 2) 오차분산 σ^2 을 MSE 로 추정하고, $Var(\hat{\beta}_0)$, $Var(\hat{\beta}_1)$, $Var(\hat{\beta}_2)$ 의 추정값을 구하시오.
- 3) $X_1 = 200^{\circ}\text{C}$ 이고 $X_2 = 59\text{psi}$ 에서 평균 제품의 강도의 추정값 $\hat{Y}$ 은 얼마인가? 이 $\hat{Y}$ 의 분산을 추정하시오.
- 4) 분산분석표를 작성하고 F -검정 결과를 해석하시오.
- 5) X_1 , X_2 , Y 의 표준화된 중회귀방정식을 구하고, 결과를 해석하시오.

2. 어떤 공장에서 물의 소비량을 조사하기 위하여 매달의 물소비량(Y), 평균온도(X_1), 작업일수(X_2)와 작업량(X_3)에 관한 자료를 얻었다.

<ex2-2.csv>

물소비량(Y) (단위: 1,000톤)	평균온도(X_1) (단위: °C)	작업일수(X_2) (단위: 일)	작업량(X_3) (단위: 1,000톤)
2.8	10	27	64
3.9	24	26	72
3.9	25	28	80
4.4	28	26	88
3.1	15	30	81
3.1	18	24	45
3.5	22	27	46
3.6	22	25	69
3.0	12	27	54
3.3	15	25	39

- 1) 자료로부터 회귀방정식 $\hat{Y} = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3$ 를 구하고, 이를 해석하시오.
- 2) 분산분석표를 작성하고, 결정계수 R^2 을 구하시오.
- 3) $X_1 = 20$, $X_2 = 27$, $X_3 = 60$ 에서 평균 물소비량을 추정하시오.

3. <표 2-4> 화학공장 자료에 대하여 다음 질문에 답하시오.

- 1) β_1 의 95% 신뢰구간을 구하고, 그 의미를 해석하시오.
- 2) $X_1 = 55$, $X_2 = 25$ 에서 $E(Y)$ 의 95% 신뢰구간을 구하고, 그 의미를 해석하시오.
- 3) 잔차 $e_i = Y_i - \hat{Y}_i = Y - \beta_0 - \beta_1 X_{i1} - \beta_2 X_{i2}$ 를 종축으로 하고 다음을 횡축으로 하여 산점도를 그리고, 특징이 있으면 이를 설명하시오.
 - a) $\hat{Y}_i$ 에 대하여
 - b) X_{i1} 에 대하여
 - c) X_{i2} 에 대하여
- 4) 다음의 결과를 R 함수를 이용하여 밝히시오.
 - a) $\sum e_i = 0$
 - b) $\sum \hat{Y}_i e_i = 0$
 - c) $\sum X_{i1} e_i = 0$
 - d) $\sum X_{i2} e_i = 0$

4. 다음은 어시장에서 파는 7가지 종류의 어류에 대한 자료의 일부이다. Weight를 반응변수로 하고, 다른 변수를 이용하여 추정하고자 한다. 각 어류 종류별(Species)로 회귀모형식을 적합하고 결과를 설명하시오.

〈Fish.csv〉

Species	Weight	Length1	Length2	Length3	Height	Width
Bream	242	23.2	25.4	30	11.52	4.02
Bream	290	24	26.3	31.2	12.48	4.3056
Bream	340	23.9	26.5	31.1	12.3778	4.6961
Bream	363	26.3	29	33.5	12.73	4.4555
...	..	...	...	...	...	...

자료출처: <https://www.kaggle.com/aungpyaeap/fish-market>

5. 다음은 거래된 집값에 대한 자료의 일부이다. 독립변수 (X_2, X_3, X_4)를 이용하여 집값 Y 를 추정하고자 한다. 회귀모형식을 적합하고 결과를 설명하시오.

X1 transaction date

X2 house age

X3 distance to the nearest MRT station

X4 number of convenience stores

X5 latitude

X6 longitude

Y house price of unit area

〈Real_estate.csv〉

No	X1	X2	X3	X4	X5	X6	Y
1	2012.917	32	84.87882	10	24.98298	121.5402	37.9
2	2012.917	19.5	306.5947	9	24.98034	121.5395	42.2
3	2013.583	13.3	561.9845	5	24.98746	121.5439	47.3
4	2013.5	13.3	561.9845	5	24.98746	121.5439	54.8
5	2012.833	5	390.5684	5	24.97937	121.5425	43.1
...	...	...	...	...	...	...	...

자료출처: <https://www.kaggle.com/datasets/quantbruce/real-estate-price-prediction>

6. 다음은 포르투갈 레드와인과 화이트와인 자료의 일부이다. 각 와인 종류별로 회귀모형을 적합하고 결과를 설명하시오.

Input variables

- 1 - fixed acidity
- 2 - volatile acidity
- 3 - citric acid
- 4 - residual sugar
- 5 - chlorides
- 6 - free sulfur dioxide
- 7 - total sulfur dioxide
- 8 - density
- 9 - pH
- 10 - sulphates
- 11 - alcohol

Output variable (based on sensory data):

- 12 - quality (score between 0 and 10)

<winequality-red.csv>

```
"fixed acidity";"volatile acidity";"citric acid";"residual
sugar";"chlorides";"free sulfur dioxide";"total sulfur
dioxide";"density";"pH";"sulphates";"alcohol";"quality"
7;0.27;0.36;20.7;0.045;45;170;1.001;3;0.45;8.8;6
6.3;0.3;0.34;1.6;0.049;14;132;0.994;3.3;0.49;9.5;6
8.1;0.28;0.4;6.9;0.05;30;97;0.9951;3.26;0.44;10.1;6
7.2;0.23;0.32;8.5;0.058;47;186;0.9956;3.19;0.4;9.9;6
```

자료출처: <https://archive.ics.uci.edu/ml/datasets/wine+quality>

참고: 이 자료를 읽을 때는 다음과 같이 하면 된다.

```
> red = read.csv("c:/data/reg/winequality-red.csv", sep=";")
```

```
> head(red, 3)
```

	fixed.acidity	volatile.acidity	citric.acid	residual.sugar	chlorides
1	7.4	0.70	0.00	1.9	0.076
2	7.8	0.88	0.00	2.6	0.098
3	7.8	0.76	0.04	2.3	0.092

	free.sulfur.dioxide	total.sulfur.dioxide	density	pH	sulphates	alcohol
1	11	34	0.9978	3.51	0.56	9.4
2	25	67	0.9968	3.20	0.68	9.8
3	15	54	0.9970	3.26	0.65	9.8

quality

1	5
2	5
3	5

연습문제

1. 다음의 자료는 토양으로부터 증발되는 수분의 양이 토양의 온도와 대기 온도와 어떠한 관계가 있는지를 알아보려고 수집한 것이다(ex3-1.csv).

MAXST : 토양 내 최고온도

MINST : 토양 내 최저온도

AVST : 토양 내 평균온도

MAXAT : 최고기온

MINAT : 최저기온

AVAT : 평균기온

EVAP : 증발되는 수분의 양

DAY	MAXST	MINST	AVST	MAXAT	MINAT	AVAT	EVAP
6	84	65	147	85	59	151	30
7	84	65	149	86	61	159	34
8	79	66	142	83	64	152	33
9	81	67	147	83	65	158	26
10	84	68	167	88	69	180	41
11	74	66	131	77	67	147	4
12	73	66	131	78	69	159	5
13	75	67	134	84	68	159	20
14	84	68	161	89	71	195	31
15	86	72	169	91	76	206	38
16	88	73	178	91	76	208	43
17	90	74	187	94	76	211	47
18	88	72	171	94	75	211	45
19	88	72	171	92	70	201	45
20	81	69	154	87	68	167	11
21	79	68	149	83	68	162	10
22	84	69	160	87	66	173	30
23	84	70	160	87	68	177	29
24	84	70	168	88	70	169	23
25	77	67	147	83	66	170	16
26	87	67	166	92	67	196	37
27	89	69	171	92	72	199	50
28	89	72	180	94	72	204	36
29	93	72	186	92	73	201	54
30	93	74	188	93	72	206	44

- 1) 설명변수 간의 표본상관행렬을 구하시오. 이 행렬에서 설명변수들의 다중공선성을 말할 수 있는가?
- 2) 분산팽창인자를 계산하시오.

2. 다음은 Webster, Gunst와 Mason(1974)에 의해 생성된 자료이다(ex3-2.csv).

Y	X_1	X_2	X_3	X_4	X_5	X_6
10.006	8.000	1.000	1.000	1.000	0.541	-0.099
9.737	8.000	1.000	1.000	0.000	0.130	0.070
15.087	8.000	1.000	1.000	0.000	2.116	0.115
8.422	0.000	0.000	9.000	1.000	-2.397	0.252
8.625	0.000	0.000	9.000	1.000	-0.046	0.017
16.289	0.000	0.000	9.000	1.000	0.365	1.504
5.958	2.000	7.000	0.000	1.000	1.996	-0.865
9.313	2.000	7.000	0.000	1.000	0.228	-0.055
12.960	2.000	7.000	0.000	1.000	1.380	0.502
5.541	0.000	0.000	0.000	10.000	-0.798	-0.399
8.756	0.000	0.000	0.000	10.000	0.257	0.101
10.937	0.000	0.000	0.000	10.000	0.440	0.432

- 1) 설명변수 간의 표본상관행렬을 구하시오. 이 행렬에서 설명변수들의 선형종속관계를 말할 수 있는가?
- 2) 분산팽창인자를 이용하여 다중공선성의 존재를 파악하시오.

3. 다음은 교통사고의 원인을 알아보기 위하여 1973년 미국 미네소타주의 도로 39개 구간에서 자동차 주행거리 100만 마일당 사고의 횟수를 반응변수로 하고 사고의 원인이 될 수 있을 것으로 예상되는 13개의 설명변수를 얻은 자료이다(ex3-3.csv).

Y : 100만 마일의 자동차 주행거리당 사고의 횟수

X_1 : 구간의 길이(miles)

X_2 : 일 평균 통과 자동차 수(천 대)

X_3 : 트럭의 비율

X_4 : 제한속도(mile/hour)

X_5 : 차선의 폭(feet)

X_6 : 갓길의 폭(feet)

X_7 : 1마일당 고속도로 진입로의 수

X_8 : 1마일당 신호등이 있는 교차로의 수

X_9 : 1마일당 진입로의 수

X_{10} : 차선의 수

X_{11} : 1: 연방고속도로, 0: 기타

X_{12} : 1: principal arterial highway, 0: 기타

X_{13} : 1: major arterial highway, 0: 기타

Y	X_1	X_2	X_3	X_4	X_5	X_6	X_7	X_8	X_9	X_{10}	X_{11}	X_{12}	X_{13}
4.58	4.99	69	8	55	12	10	1.20	0	4.60	8	1	0	0
2.86	16.11	73	8	60	12	10	1.43	0	4.40	4	1	0	0
3.02	9.75	49	10	60	12	10	1.54	0	4.70	4	1	0	0
2.29	10.65	61	13	65	12	10	0.94	0	3.80	6	1	0	0
1.61	20.01	28	12	70	12	10	0.65	0	2.20	4	1	0	0
6.87	5.97	30	6	55	12	10	0.34	1.84	24.80	4	0	1	0
3.85	8.57	46	8	55	12	8	0.47	0.70	11.00	4	0	1	0
6.12	5.24	25	9	55	12	10	0.38	0.38	18.50	4	0	1	0
3.29	15.79	43	12	50	12	4	0.95	1.39	7.50	4	0	1	0
5.88	8.26	23	7	50	12	5	0.12	1.21	8.20	4	0	1	0
4.20	7.03	23	6	60	12	10	0.29	1.85	5.40	4	0	1	0
4.61	13.28	20	9	50	12	2	0.15	1.21	11.20	4	0	1	0
4.80	5.40	18	14	50	12	8	0	0.56	15.20	2	0	1	0
3.85	2.96	21	8	60	12	10	0.34	0	5.40	4	0	1	0
2.69	11.75	27	7	55	12	10	0.26	0.60	7.90	4	0	1	0
1.99	8.86	22	9	60	12	10	0.68	0	3.20	4	0	1	0
2.01	9.78	19	9	60	12	10	0.20	0.10	11.00	4	0	1	0
4.22	5.49	9	11	50	12	6	0.18	0.18	8.90	2	0	1	0
2.76	8.63	12	8	55	13	6	0.14	0	12.40	2	0	1	0
2.55	20.31	12	7	60	12	10	0.05	0.99	7.80	4	0	1	0
1.89	40.09	15	13	55	12	8	0.05	0.12	9.60	4	0	1	0
2.34	11.81	8	8	60	12	10	0	0	4.30	2	0	1	0
2.83	11.39	5	9	50	12	8	0	0.09	11.10	2	0	1	0
1.81	22.00	5	15	60	12	7	0	0	6.80	2	0	1	0
9.23	3.58	23	6	40	12	2	0.56	2.51	53.00	4	0	0	1
8.60	3.23	13	6	45	12	2	0.31	0.93	17.30	2	0	0	1
8.21	7.73	7	8	55	12	8	0.13	0.52	27.30	2	0	0	1
2.93	14.41	10	10	55	12	6	0	0.07	18.00	2	0	0	1

7.48	11.54	12	7	45	12	3	0.09	0.09	30.20	2	0	0	1
2.57	11.10	9	8	60	12	7	0	0	10.30	2	0	0	1
5.77	22.09	4	8	45	11	3	0	0.14	18.20	2	0	0	1
2.90	9.39	5	10	55	13	1	0	0	12.30	2	0	0	1
2.97	19.49	4	13	55	12	4	0	0	7.10	2	0	0	1
1.84	21.01	5	12	55	10	8	0	0.10	14.00	2	0	0	1
3.78	27.16	2	10	55	12	3	0.04	0.04	11.30	2	0	0	1
2.76	14.03	3	8	50	12	4	0.07	0	16.30	2	0	0	1
4.27	20.63	1	11	55	11	4	0	0	9.60	2	0	0	1
3.05	20.06	3	11	60	12	8	0	0	9.00	2	0	0	0
4.12	12.91	1	10	55	12	3	0	0	10.40	2	0	0	0

- 1) 앞으로부터 선택법을 이용하여 모형을 선택하시오.
- 2) 뒤로부터 제거법을 이용하여 모형을 선택하시오.
- 3) 단계별 회귀방법을 이용하여 모형을 선택하시오.
- 4) 모든 회귀방법을 이용하여 모형을 선택하시오.
- 5) 위의 네 가지 방법에 의하여 선택된 모형을 비교하시오.

4. 다음은 자동차들의 연비(1갤런당 주행마일)를 알아보기 위하여 예상되는 10개의 설명변수를 얻은 자료이다(ex3-4.csv).

- Y : 연비(mile/gallon)
 X_1 : 실린더의 수
 X_2 : 배기량
 X_3 : 마력
 X_4 : 최종구동장치비(최종기어비)
 X_5 : 자동차 무게
 X_6 : 순간가속도
 X_7 : 엔진형태(0: V자형, 1: 직선형)
 X_8 : 기어의 종류(0: 자동, 1: 수동)
 X_9 : 기어속도의 수
 X_{10} : 기화기의 수

Y	X ₁	X ₂	X ₃	X ₄	X ₅	X ₆	X ₇	X ₈	X ₉	X ₁₀
21.0	6	160.0	110	3.90	2.620	16.46	0	1	4	4
21.0	6	160.0	110	3.90	2.875	17.02	0	1	4	4
22.8	4	108.0	93	3.85	2.320	18.61	1	1	4	1
21.4	6	258.0	110	3.08	3.215	19.44	1	0	3	1
18.7	8	360.0	175	3.15	3.440	17.02	0	0	3	2
18.1	6	225.0	105	2.76	3.460	20.22	1	0	3	1
14.3	8	360.0	245	3.21	3.570	15.84	0	0	3	4
24.4	4	146.7	62	3.69	3.190	20.00	1	0	4	2
22.8	4	140.8	95	3.92	3.150	22.90	1	0	4	2
19.2	6	167.6	123	3.92	3.440	18.30	1	0	4	4
17.8	6	167.6	123	3.92	3.440	18.90	1	0	4	4
16.4	8	275.8	180	3.07	4.070	17.40	0	0	3	3
17.3	8	275.8	180	3.07	3.730	17.60	0	0	3	3
15.2	8	275.8	180	3.07	3.780	18.00	0	0	3	3
10.4	8	472.0	205	2.93	5.250	17.98	0	0	3	4
10.4	8	460.0	215	3.00	5.424	17.82	0	0	3	4
14.7	8	440.0	230	3.23	5.345	17.42	0	0	3	4
32.4	4	78.7	66	4.08	2.200	19.47	1	1	4	1
30.4	4	75.7	52	4.93	1.615	18.52	1	1	4	2
33.9	4	71.1	65	4.22	1.835	19.90	1	1	4	1
21.5	4	120.1	97	3.70	2.465	20.01	1	0	3	1
15.5	8	318.0	150	2.76	3.520	16.87	0	0	3	2
15.2	8	304.0	150	3.15	3.435	17.30	0	0	3	2
13.3	8	350.0	245	3.73	3.840	15.41	0	0	3	4
19.2	8	400.0	175	3.08	3.845	17.05	0	0	3	2
27.3	4	79.0	66	4.08	1.935	18.90	1	1	4	1
26.0	4	120.3	91	4.43	2.140	16.70	0	1	5	2
30.4	4	95.1	113	3.77	1.513	16.90	1	1	5	2
15.8	8	351.0	264	4.22	3.170	14.50	0	1	5	4
19.7	6	145.0	175	3.62	2.770	15.50	0	1	5	6
15.0	8	301.0	335	3.54	3.570	14.60	0	1	5	8
21.4	4	121.0	109	4.11	2.780	18.60	1	1	4	2

- 1) 앞으로부터 선택법을 이용하여 모형을 선택하시오.
- 2) 뒤로부터 제거법을 이용하여 모형을 선택하시오.
- 3) 단계별 회귀방법을 이용하여 모형을 선택하시오.
- 4) 모든 회귀방법을 이용하여 모형을 선택하시오.
- 5) 위의 네 가지 방법에 의하여 선택된 모형을 비교하시오.

연습문제

1. <표 4-2>의 도쿄국제마라톤대회 자료를 이용하여 각 연도별로 다음의 3차 다항회귀모형을 적합하여 보시오. 이 경우에는 구간별 편차가 다르기 때문에 가중최소제곱법을 적용하는 것이 좋을 것이다.

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \beta_3 X^3 + \epsilon$$

2. 토양에 녹아 있는 붕소(boron)의 양(Y)은 토양의 진흙의 비중(X_1)과 토양의 pH(X_2)에 관련되어 있다고 한다. 다음 자료는 20가지의 토양을 조사하여 붕소의 양, 진흙의 비중, pH를 기록한 것이다(ex4-2.csv).

순서	Y (ppm)	X_1 (wt%)	X_2 (pH)	순서	Y (ppm)	X_1 (wt%)	X_2 (pH)
1	0.62	37	5.3	11	0.74	29	6.0
2	0.69	37	5.3	12	0.63	29	6.0
3	0.63	37	5.5	13	0.52	27	5.5
4	0.61	37	5.7	14	0.47	27	5.6
5	0.28	29	5.6	15	0.45	27	5.6
6	0.33	29	5.7	16	0.42	27	5.7
7	0.31	29	5.7	17	0.41	27	5.5
8	0.37	29	5.9	18	0.42	27	5.5
9	0.66	29	6.0	19	0.42	27	5.5
10	0.70	29	6.3	20	0.41	27	5.5

- 1) 2차 다항회귀모형 $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_{11} X_1^2 + \beta_{22} X_2^2 + \beta_{12} X_1 X_2 + \epsilon$ 을 적합시키고, 그 적합성을 검토하시오.

- 2) 가설 $H_0 : \beta_{12} = 0$, $H_1 : \beta_{12} \neq 0$ 을 유의수준 5%에서 검정하시오.

3. 다음 자료는 미국 와이오밍주에 있는 스네이크강(Snake River)에서 매년 4월 1일의 눈에 포함된 수분량(X)과 4월부터 7월까지의 강수량(Y , 단위: 인치)을 17년(1919~1935) 동안 측정한 것이다(ex4-3.csv).

X	Y	X	Y
23.1	10.5	37.9	22.8
32.8	16.7	30.5	14.1
31.8	18.2	25.1	12.9
32.0	17.0	12.4	8.8
30.4	16.3	35.1	17.4
24.0	10.5	31.5	14.9
39.5	23.1	21.1	10.5
24.2	12.4	27.6	16.1
52.5	24.9		

- 1) X 와 Y 의 산점도를 그리시오.
- 2) $X_i - \bar{X}$ 를 이용하여 반응변수 Y 에 대한 1차, 2차, 3차 다항회귀모형을 구하시오.
- 3) 문항 2)에서 구한 3개의 다항회귀모형들 중에서 관측된 자료에 가장 적절한 다항회귀모형은 무엇인가?

4. 다음은 미국 경제자료로서 1940년부터 1950년까지의 가처분소득(disposable income, Y)과 가계소비지출액(personal consumption, X) 내용이다. 제2차 세계대전(1940~1945) 동안의 기간을 1, 그 외의 기간을 0으로 하여 가처분소득과 가계소비지출액의 관계를 알아보시오(ex4-4.csv).

연도	처분소득	소비지출액	연도	처분소득	소비지출액
1940	244.0	299.9	1946	332.7	301.0
1941	277.9	243.6	1947	318.8	305.8
1942	317.5	241.1	1948	335.8	312.2
1943	332.1	248.2	1949	336.8	319.3
1944	343.6	255.2	1950	362.8	337.3
1945	338.1	270.9			

5. 한 대학교에서 성별에 따라 교수들의 월급에 차이가 있는지를 보기 위하여 교수들의 월급액(SL), 직위(RK), 근속연수(YR), 최종학위(DG)를 조사한 결과가 다음과 같다. 단, 직위변수에서는 1=조교수, 2=부교수, 3=정교수로, 최종학위변수에서는 0=석사, 1=박사로, 성별(SX)변수에서는 1=여자, 0=남자로 기록하였다(ex4-5.csv).

순서	SX	RK	YR	DG	YD	SL	순서	SX	RK	YR	DG	YD	SL
1	0	3	25	1	35	36350	27	0	2	11	1	14	24800
2	0	3	13	1	22	35350	28	1	3	5	1	16	25500
3	0	3	10	1	23	28200	29	0	2	3	0	7	26182
4	1	3	7	1	27	26775	30	0	2	3	0	17	23725
5	0	3	19	0	30	33696	31	1	1	10	0	15	21600
6	0	3	16	1	21	28516	32	0	2	11	0	31	23300
7	1	3	0	0	32	24900	33	0	1	9	0	14	23713
8	0	3	16	1	18	31909	34	1	2	4	0	33	20690
9	0	3	13	0	30	31850	35	1	2	6	0	29	22450
10	0	3	13	0	31	32850	36	0	2	1	1	9	20850
11	0	3	12	1	22	27025	37	1	1	8	1	14	18304
12	0	2	15	1	19	24750	38	0	1	4	1	4	17095
13	0	3	9	1	17	28200	39	0	1	4	1	5	16700
14	0	2	9	0	27	23712	40	0	1	4	1	4	17600
15	0	3	9	1	24	25748	41	0	1	3	1	4	18075
16	0	3	7	1	15	29342	42	0	1	3	0	11	18000
17	0	3	13	1	20	31114	43	0	2	0	1	7	20999
18	0	2	11	0	14	24742	44	1	1	3	1	3	17250
19	0	2	10	0	15	22906	45	0	1	2	1	3	16500
20	0	3	6	0	21	24450	46	0	1	2	1	1	16094
21	0	1	16	0	23	19175	47	1	1	2	1	6	16150
22	0	2	8	0	31	20525	48	1	1	2	1	2	15350
23	0	3	7	1	13	27959	49	0	1	1	1	1	16244
24	1	3	8	1	24	38045	50	1	1	1	1	1	16686
25	0	2	9	1	12	24832	51	1	1	1	1	1	15000
26	0	3	5	1	18	25400	52	1	1	0	1	2	20300

- 1) 성별을 나타내는 기호를 이용하여 월급액과 근속연수의 산점도를 그리시오.
- 2) 월급액을 반응변수로 하고 근속연수와 성별을 설명변수로 하는 회귀모형을 구하시오.
- 3) 문항 2)의 결과에 의하면 성별에 따라 월급액과 근속연수의 관계가 다르다고 할 수 있는지를 설명하시오.
- 4) 월급액에 대한 근속연수의 회귀모형에 성별, 직위, 최종학력을 포함시킨 경우와 포함시키지 않은 경우를 비교하는 검정을 실시하시오.
- 5) 월급액을 반응변수로 하는 최적모형을 유도하고 성별에 의한 월급액의 차이가 있는지 여부를 판단하시오.

연습문제

1. 다음 자료에서 Y 를 반응변수로 하고 X 를 설명변수로 한 회귀방정식을 추정하고 각 관측값에 대한 잔차, h_{ii} , 스튜던트화 잔차, 그리고 Cook의 D 통계량 값을 구하고, 특이점과 영향력 있는 관측값으로 분류될 수 있는 관측값을 찾으시오.

관측값	A	B	C	D	E	F	G	H	I	J
X	2	3	4	5	5	6	7	8	9	10
Y	30	40	40	50	80	60	60	60	70	120

2. 다음은 어느 헬스클럽에 등록한 30명을 대상으로 기록한 건강자료이다. 다음 정의된 변수들을 참조하여 물음에 답하시오(ex5-2.csv).

X_1 : 몸무게(파운드)

X_2 : 분당 정지 맥박수

X_3 : 근력(들어 올릴 수 있는 최대의 무게: 파운드)

X_4 : 1/4마일 시험주행속도(초)

Y : 1마일 주행속도(초)

번호	X_1	X_2	X_3	X_4	Y	번호	X_1	X_2	X_3	X_4	Y
1	217	67	260	91	481	16	138	70	180	62	267
2	141	52	190	66	292	17	147	54	150	75	404
3	152	58	203	68	338	18	197	76	228	88	442
4	153	56	183	70	357	19	165	59	188	70	368
5	180	66	170	77	396	20	125	58	160	66	295
6	193	71	178	82	429	21	161	52	190	69	391
7	162	65	160	74	345	22	132	62	163	59	264
8	180	80	170	84	469	23	257	64	313	96	487
9	205	77	188	83	425	24	236	72	225	84	481
10	168	74	170	79	358	25	149	57	173	68	374
11	232	65	220	72	393	26	161	57	173	65	309
12	146	68	158	68	346	27	198	59	220	62	367
13	173	51	243	56	279	28	245	70	218	69	469
14	155	64	198	59	311	29	141	63	193	60	252
15	212	66	220	77	401	30	177	53	183	75	338

- 1) 스튜던트화 잔차와 예측값에 대한 산점도를 그리고 이를 논하시오.
- 2) 문항 1)의 잔차산점도에서 특이점으로 의심되는 관측값이 발견될 것이다. 이 관측값에 대한 특이점 검정을 수행하시오.

3. <표 5-3> 가솔린 자료를 이용하여 다음 질문에 답하시오.

- 1) 4개의 설명변수를 모두 포함한 회귀식을 구하고 이 모형에 대해 논하시오.
- 2) 잔차산점도 분석 및 영향력 측정통계량 계산을 통하여 관측값 11번과 32번이 회귀식에 미치는 영향에 대해 논하시오.
- 3) 11번 관측값의 설명변수값 중 하나가 잘못 기재되었다고 한다. 어느 변수일 가능성이 가장 높은지 짐작해 보시오.

4. <표 5-5> 토양침식 자료에 대해 다음 질문에 답하시오.

- 1) 잔차분석 및 영향력 측정통계량 계산을 통하여 관측값 7번과 10번이 회귀식에 미치는 영향에 대해 논하시오.
- 2) 7번 관측값을 제거한 후 회귀식을 추정하고 자료진단을 하시오.
- 3) 10번 관측값을 제거한 후 회귀식을 추정하고 자료진단을 하시오. 7번 관측값을 제거했을 때와의 차이는 무엇인지 논하시오.

5. 다음은 과학자 Robert Boyle이 어느 gas의 Volume(Height)와 Pressure의 관계를 알기 위해 높이를 조절할 때, 압력을 측정한 자료이다. 이 자료를 이용하여 잔차분석을 포함하여 회귀분석을 실시하고 결과를 설명하시오 (자료: ex5-5.csv).

Height	Pressure
48	29.1
46	30.6
44	31.9
42	33.2
40	35.3
38	37
36	39.3
34	41.6
32	44.2

30	47.5
28	50.3
26	54.3
24	58.8
23	61.3
22	64.5
21	67.1
20	70.7
19	74.1
18	77.9
17	82.75
16	87.9
15	93.1
14	100.4
13	107.8
12	117.6

자료출처: <https://dasl.datadescription.com/datafile/boyle/>

6. 다음은 담배 브랜드별로 측정한 Nicotine, Tar, CO 자료의 일부이다. Nicotine과 (Tar, CO)의 관계를 알기 위한 회귀분석을 실시하고, 어느 브랜드의 니코틴이 특별히 높고 낮은지 잔차분석을 통하여 살펴보시오(자료: ex5-6.csv).

Nicotine	Tar	CO	Brand
0.04	8	12	QUEST
0.05	4	7	QUEST
0.1	1	1	Carlton
0.1	1	1	Carlton
0.1	1	1	Carlton
0.1	1	2	Carlton
0.1	1	3	MERIT
...	...	...	

자료출처: <https://dasl.datadescription.com/datafile/cigarettes/>

연습문제

1. <표 6-1> 자료에서 관측값 B에 의한 기러기 수를 설명변수로 하는 단순 회귀에서 등분산 가정 여부를 진단할 수 있는 스코어 검정을 실시하시오.
2. <표 6-2> 자료에서 다음의 물음에 답하시오.
 - 1) 잔차산점도 분석 및 스코어 검정을 실시하시오.
 - 2) 반응변수에 대해 Box-Cox의 변환방법을 적용시켜 보시오.
 - 3) 변환한 후의 모형에 대해 잔차산점도 분석을 하고 변수변환의 효과를 논하시오.
3. 다음 표는 62종의 동물에 대한 평균 두뇌무게와 몸무게를 나타낸다. 우리의 관심은 두뇌무게를 몸무게의 함수로 보고 함수관계를 찾고자 하는 것이다(ex6-3.csv).

번호	동물이름	몸무게(kg)	두뇌무게(g)
1	Arctic fox	3.385	44.5
2	Owl monkey	0.48	15.5
3	Mountain beaver	1.35	8.1
4	Cow	465	423
5	Gray wolf	36.33	119.5
6	Goat	27.66	115
7	Roe deer	14.83	98.2
8	Guinea pig	1.04	5.5
9	Vervet	4.19	58
10	Chinchilla	0.425	6.4
11	Ground squirrel	0.101	4
12	Arctic ground squirrel	0.92	5.7
13	African giant pouched rat	1	6.6
14	Lesser short-tailed shrew	0.005	0.14
15	Star-nosed mole	0.06	1
16	Nine-banded armadillo	3.5	10.8
17	Tree hyrax	2	12.3
18	N. American opossum	1.7	6.3
19	Asian elephant	2547	4603
20	Big brown bat	0.023	0.3

21	Donkey	187.1	419
22	Horse	521	655
23	European hedgehog	0.785	3.5
24	Patas monkey	10	115
25	Cat	3.3	25.6
26	Galago	0.2	5
27	Genet	1.41	17.5
28	Giraffe	529	680
29	Gorilla	207	406
30	Gray seal	85	325
31	Rock hyrax(a)	0.75	12.3
32	Human	62	1320
33	African elephant	6654	5712
34	Water opossum	3.5	3.9
35	Rhesus monkey	6.8	179
36	Kangaroo	35	56
37	Yellow-bellied marmot	4.05	17
38	Golden hamster	0.12	1
39	Mouse	0.023	0.4
40	Little brown bat	0.01	0.25
41	Slow loris	1.4	12.5
42	Okapi	250	490.
43	Rabbit	2.5	12.1
44	Sheep	55.5	175
45	Jaguar	100	157
46	Chimpanzee	52.16	440
47	Baboon	10.55	179.5
48	Desert hedgehog	0.55	2.4
49	Giant armadillo	60	81
50	Rock hyrax(b)	3.6	21
51	Raccoon	4.288	39.2
52	Rat	0.28	1.9
53	Eastern Amercian mole	0.075	1.2
54	Mole cat	0.122	3
55	Musuk shrew	0.048	0.33
56	Pig	192	180
57	Echidna	3	25
58	Brazilian tapir	160	169
59	Tenrec	0.9	2.6
60	Phalanger	1.62	11.4
61	Tree shrew	0.104	2.5
62	Red fox	4.235	50.4

(a): Heterohyrax brucci

(b): procavia habessinica

- 1) 두뇌무게를 Y 로 놓고 몸무게를 X 로 하여 Y 와 X 의 산점도와 잔차산점도를 그리고 이를 논하시오. 변수에 대한 변환이 필요한지, 그리고 필요하면 그 이유는 무엇인지 논하시오.
 - 2) X 에 대한 Y 의 회귀식을 구하고 특이점 검정, 영향력 있는 관측값 검토 등의 자료진단과 각종 가정의 만족 여부 등의 모형진단을 실시하시오.
 - 3) 반응변수와 설명변수에 자연로그변환을 취한 후 회귀진단을 행하여 문항 2)의 답과 비교하시오.
4. 다음 표는 영국에 있는 25개의 중세기 교회의 둘레(단위: 미터)와 면적(단위: 제곱미터)을 나타낸다. 교회의 크기와 형태가 매우 다양함을 알 수 있으나 건축재료로 쓰이는 돌에 대한 제약 때문에 교회 건물의 각 부분에 대한 크기 또는 길이는 서로 밀접한 관계를 갖고 있는 것으로 추측되었다(ex6-4.csv).
- 1) Y 와 둘레 X 사이에 산점도와 잔차산점도를 그리고 이에 대해 논하시오.
 - 2) 반응변수에 대해 Box-Cox의 변환방법을 적용시켜 보시오.

교회	둘레(m)	면적(m ²)	교회	둘레(m)	면적(m ²)
1	348	3883	14	314	3427
2	369	4392	15	204	1761
3	143	914	16	177	1337
4	205	1666	17	59	204
5	305	3616	18	69	222
6	419	3866	19	50	146
7	243	1774	20	69	192
8	240	1946	21	63	186
9	272	2300	22	58	169
10	299	2975	23	86	331
11	478	5119	24	41	113
12	133	660	25	123	674
13	167	904			

연습문제

1. 일반화선형모형의 세 가지 구성성분에 대해 설명하시오.
2. 다음 표는 1990년부터 2021년까지의 우리나라의 인구수, 국내총생산, 에너지 소비량, 이산화탄소 배출량에 대한 자료이다(ex7-2.csv).

연도	인구 (천 명)	국내총생산량 (십억 원)	에너지 소비량 (백만 톤: mil.toe)	이산화탄소 배출량 (백만 톤: mil.t-CO ₂ eq.)
1990	42,869.28	454,145.90	71.15	231.81
1991	43,295.70	503,094.00	80.18	255.83
1992	43,747.96	534,279.00	89.97	275.92
1993	44,194.63	571,023.90	99.40	302.90
1994	44,641.54	623,950.20	109.32	327.44
1995	45,092.99	683,940.30	116.51	357.31
1996	45,524.68	737,908.00	125.59	381.68
1997	45,953.58	783,441.00	134.49	402.32
1998	46,286.50	743,254.80	122.03	343.69
1999	46,616.68	828,483.40	133.01	378.16
2000	47,008.11	903,550.90	140.96	422.48
2001	47,370.16	947,394.80	143.59	431.00
2002	47,644.74	1,020,582.40	150.38	433.89
2003	47,892.33	1,052,703.10	153.97	435.99
2004	48,082.52	1,107,416.20	155.68	459.79
2005	48,184.56	1,155,129.70	158.48	457.67
2006	48,438.29	1,215,939.50	162.53	464.71
2007	48,683.64	1,286,458.50	167.23	477.41
2008	49,054.71	1,325,219.30	168.47	488.84
2009	49,307.84	1,335,724.30	169.57	502.09
2010	49,554.11	1,426,618.00	184.58	550.92
2011	49,936.64	1,479,198.40	193.73	573.76
2012	50,199.85	1,514,736.60	193.77	575.47
2013	50,428.89	1,562,673.60	195.29	574.55
2014	50,746.66	1,612,717.50	195.89	562.68
2015	51,014.95	1,658,020.40	199.35	582.05
2016	51,217.80	1,706,880.30	207.55	588.77
2017	51,361.91	1,760,811.50	212.43	599.83

2018	51,585.06	1,812,005.40	214.00	605.49
2019	51,764.82	1,852,666.40	211.73	587.20
2020	51,836.24	1,839,523.30	203.75	546.81
2021	51,744.88	1,915,777.50	215.66	581.94

자료출처(KESIS): https://www.ksesis.net/sub/sub_0001.jsp?M_MENU_ID=M_M_001&S_MENU_ID=S_M_008

- 1) 이산화탄소 배출량을 반응변수로 하고 나머지 변수들을 설명변수로 하는 선형회귀모형으로 분석하고자 한다. 분석모형을 일반화선형모형의 세 가지 구성성분으로 제시하시오.
- 2) R의 glm() 함수를 사용하여 분석하고 적합된 모형을 기술하시오.
- 3) 모형의 유의성 검정을 위한 귀무가설과 대립가설을 설정하고 이탈도를 사용하여 유의수준 5%에서 가능도비 검정을 실시하시오.
- 4) R의 stepAIC() 함수를 사용하여 변수를 선택하고 각 설명변수가 이산화탄소 배출량 평균에 미치는 영향에 해석을 시도하시오. 이때 기술과 설명의 용이성을 위하여 인구수와 국내총생산량 값은 1/1,000배로 변환하여 사용하고, 변수선택 방향은 'both'로 설정한다.

3. [예제 7.1] 자료에 모형 (7.5)를 적합시키시오.

- 1) 구획의 크기가 120km일 때 이 구획에서 Sugar Glider가 출현할 확률과 95% 신뢰구간을 추정하시오.
- 2) 8, 13, 45번째 자료를 하나씩 제거할 때 회귀계수 추정값의 변화를 검토하고 분석에 미치는 이들 관측값의 특성을 설명하시오.

4. 다음은 아스피린의 심근경색 예방효과를 규명하기 위해 실시한 임상시험 결과*이다.

집단(x)	심근경색 발병(Y)		전체
	No(= 0)	Yes(= 1)	
가짜약(= 0)	10,845	189	11,034
아스피린(= 1)	10,993	104	11,037

* Preliminary Report: Findings from the Aspirin Component of the Ongoing Physician' Health Study. New Engl. J. Med., 318: 262-264, 1988.

- 1) $\pi_0 = P(Y=1|x=0)$, $\pi_1 = P(Y=1|x=1)$ 일 때 표본비율을 사용하여 가짜약에 대한 아스피린에서의 심근경색 발생 승산비를 추정하고 해석하시오.
- 2) glm() 함수를 사용하여 로지스틱회귀모형으로 분석하고 적합한 모형을 기술하시오.
- 3) 로지스틱회귀모형에 x 가 1단위 변할 때, 즉 가짜약 대신에 아스피린을 복용할 때 심근경색 발생 승산비와 95% 신뢰구간을 추정하고 문항 1)에서 추정한 승산비와 비교하시오.

5. [예제 7.1] 자료에서 Sugar Glider의 출현확률을 구획의 크기(x)와 프로빗모형으로 적합시키시오. $x = 120\text{km}$ 일 때 출현확률과 이에 대한 95% 신뢰구간을 추정하고, 연습문제 3번 문항 1)의 결과와 비교하시오.

6. 다음 표는 미국에서 결혼한 여성들의 직업 종사 여부와 관련 변수들을 조사한 자료로서 R의 car library에 Mroz 이름으로 탑재되어 있다.

```
> install.packages("car")
> library(car)
> head(Mroz, 5)
```

번호	lfp	k5	k618	age	wc	hc	lwg	inc
1	yes	1	0	32	no	no	1.2101647	10.910
2	yes	0	2	30	no	no	0.3285041	19.500
3	yes	1	3	35	no	no	1.5141279	12.040
4	yes	0	3	34	no	no	0.0921151	6.800
5	yes	1	2	31	yes	no	1.5242802	20.100
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
753	no	0	3	39	no	no	0.8532125	28.363

변수명과 입력내용			입력형태
변수명	입력내용		
lfp	직업 종사 여부		yes; no
k5	5세 이하의 자녀 수		명
k618	6세 이상 18세 이하의 자녀 수		명
age	나이		년

wc	여성의 대학진학 여부	yes; no
hc	남편의 대학진학 여부	yes; no
lwg	기대 임금의 로그 값	직업이 없는 경우; 회귀분석에 의한 추정값
inc	여성의 수입을 제외한 가족의 수입	

자료출처: Mroz, T. A. (1987). The sensitivity of an empirical model of married women's hours of work to economic and statistical assumptions. *Econometrica* 55, 765-799.

- 1) 여성의 직업 종사 여부를 반응변수로 하고 나머지 변수들을 설명변수로 하는 로지스틱회귀모형을 설정하고 분석하시오.
- 2) 모형의 유의성 검정을 위한 귀무가설과 대립가설을 제시하고 가능도비 검정통계량으로 유의수준 5%에서 검정하시오.
- 3) R의 stepAIC() 함수를 사용하여 변수를 선택하고 선택된 모형을 제시하시오. 단, 변수선택 방향은 'both'로 설정한다.
- 4) 선택된 모형에서 k5(=5세 이하의 자녀 수)가 1명 증가할 때 여성이 직업에 종사할 오즈비의 추정값과 95% 신뢰구간을 제시하고 해석하시오.
- 5) 선택된 모형에서 wc(=여성의 대학진학 여부)가 1 증가할 때, 즉 여성이 대학을 진학하는 경우 여성이 직업에 종사할 오즈비의 추정값과 95% 신뢰구간을 제시하고 해석하시오.
- 6) R의 mfx() 함수를 사용하여 각 설명변수가 여성의 직업 종사율에 미치는 평균변화량을 제시하고 문항 5)의 해석 결과와 비교하면서 설명하시오.
- 7) 문항 3)에서 선택된 변수를 사용하여 프로빗모형을 적합시키고 추정식을 제시하시오.

7. $y_i \sim \text{Bernoulli}(\pi)$, $i = 1, 2, \dots, n$, 확률표본일 때 이탈도를 구하시오.

연습문제

- 다음은 음주량과 식도암의 발병과의 연관성을 연구하기 위하여 환자-대조군 연구로 수집한 자료이다.

구분		식도암 여부(Y)	
		대조군($Y=0$)	환자군($Y=1$)
음주량(X)	$0-79(X=0)$	770	104
(단위: 그램/일)	$80+(X=1)$	205	96
계		975	200

자료출처: esoph data in datasets library of R package.

- 반응변수와 설명변수는 무엇인가?
- 자료를 수집할 때 음주량(X)과 식도암 여부(Y) 중 어느 것이 확률적으로 관측되는가?
- $P(Y=1|X=1)$ 은 추정 가능한가? 가능하지 않다면 어떤 정보가 더 필요한가? (힌트: Bayes 정리)
- 대조군($Y=0$)에서 음주량이 80 이상($X=1$)일 승산에 대한 환자군($Y=1$)에서 음주량이 80 이상($X=1$)일 다음 승산비를 추정하시오.

$$OR = \frac{P(X=1|Y=1)/P(X=0|Y=1)}{P(X=1|Y=0)/P(X=0|Y=0)}$$

- 문항 4)에서 추정한 승산비를 음주량이 80 미만일 때 식도암이 발생할 승산에 대한 음주량이 80 이상일 때 식도암이 발생할 승산비로 해석할 수 있음을 보이시오. 이 승산비를 상대위험도로 해석할 수 있는 조건은 무엇인가?
- Y 는 이항분포를 따르고 설명변수는 X 인 로지스틱회귀모형을 적합시키시오. e^β 의 추정량을 구하고 문항 4)에서 구한 OR 추정량과 비교하시오.

- R의 carData 라이브러리에 탑재되어 있는 'BEPS' 자료는 1997~2001년 사이에 실시된 영국 선거에서 유권자들의 투표 성향에 대한 패널 연구자료이다. 다음은 수집한 10개의 변수 중 투표한 정당(vote: 'Conservative',

‘Labour’, ‘Liberal Democrat’), 나이(age: year), 성별(gender: ‘male’, ‘female’)에 대해 요약한 것이다.

```
> library(carData); data(BEPS)
> ex.d <- BEPS[c(1,2,10)]; head(ex.d, 3)
      vote age gender
1 Liberal Democrat 43 female
2      Labour    36  male
3      Labour    35  male
> summary(ex.d[c(1,3)])
      vote      gender
Conservative :462 female:812
Labour       :720  male :713
Liberal Democrat:343
> fivenum(ex.d[,2])
[1] 24 41 53 67 93
```

- 1) vote를 반응변수(Y)로 하고 age(x_1)와 gender(x_2)를 설명변수로 하는 기준범주 다항로짓모형을 적합시키시오. 이때 Y 의 기준범주는 ‘Labour’로 설정한다.
- 2) 추정된 로짓함수와 각 정당에 투표하는 확률추정식을 제시하시오.
- 3) 유권자들의 나이가 평균 나이일 때 여성과 비교하여 남성의 투표 성향을 해석하시오.
- 4) 성별로 나이가 증가함에 따라 각 정당에 투표할 확률의 추정곡선을 그리고 해석하시오.

3. 다음은 200명의 고등학생을 대상으로 학기 중 상을 받은 횟수(nw), 수학 성적(mt), 참여한 학습 프로그램(pg: 1=general, 2=academic, 3=vocation)을 조사한 자료이다(ex8-3.csv).

- 1) 반응변수를 상을 받은 횟수(nw)로 하고 나머지 두 변수를 설명변수로 하는 로그선형모형으로 자료를 분석하고자 한다. 일반화선형모형의 세 가지 구성성분으로 분석모형을 구축하시오. 여기서 학습 프로그램(pg)은 범주형 변수이다.
- 2) 구축한 모형을 적합시키시오. 모형의 유의성 검정을 위한 가설을 모형식으로 제시하고 유의수준 5%에서 검정하시오.

- 3) 각 변수의 유의성에 대한 검정을 유의수준 5%에서 실시하시오.
- 4) stepAIC() 함수를 사용하여 변수를 선택하시오. 선택된 변수를 사용하여 재분석하시오.
- 5) 잔차 이탈도를 해석하고 적합결여검정을 실시하시오.
- 6) 회귀계수(β_i) 추정값으로부터 e^{β_i} 에 대한 추정값과 이에 대한 95% 신뢰 구간을 추정하고 해석하시오.
- 7) plot() 함수를 사용하여 잔차그림을 제시하고 해석하시오.

nw	pg	mt	nw	pg	mt	nw	pg	mt	nw	pg	mt	nw	pg	mt
0	3	40	1	2	45	0	2	59	0	3	53	2	2	72
0	3	33	0	3	55	1	2	65	3	2	58	0	3	40
0	2	48	0	2	43	0	3	41	1	1	56	3	2	64
1	2	41	0	3	45	0	1	54	1	3	41	0	3	46
1	2	43	0	3	41	0	1	57	1	2	58	0	3	54
0	2	46	0	2	44	0	1	54	0	1	57	0	2	53
1	2	59	0	2	49	0	1	46	3	2	57	0	1	35
0	2	52	0	2	52	1	2	64	0	2	38	0	2	57
0	3	52	0	3	39	0	3	40	0	1	46	1	1	63
1	1	49	0	1	42	2	2	50	0	1	55	1	2	61
0	2	45	0	1	42	0	3	56	0	2	57	3	2	60
0	3	45	0	2	53	0	1	57	3	2	73	1	2	57
0	3	39	0	3	46	2	2	62	0	3	40	0	1	61
1	2	54	0	1	46	1	2	61	0	1	39	2	2	71
0	3	44	0	2	49	5	2	71	2	2	65	1	1	42
0	3	44	0	3	46	5	2	61	4	2	70	0	2	41
0	2	48	0	2	72	0	2	58	3	2	65	0	2	62
0	3	49	0	3	40	1	3	51	1	3	40	0	3	57
0	1	43	1	2	63	0	1	56	1	2	61	1	2	60
0	2	57	0	2	51	2	2	71	1	3	40	0	2	69
0	1	61	1	2	60	0	2	67	0	3	47	0	2	45
1	3	39	0	1	48	0	2	51	0	3	52	0	2	43
3	2	64	0	1	60	0	2	64	2	3	75	0	2	49
0	2	66	0	3	45	1	2	57	1	1	58	0	3	53
0	1	42	2	2	66	0	2	45	0	3	38	0	2	55
4	2	62	2	3	56	0	3	37	1	2	64	1	2	63
1	2	61	0	3	42	0	3	47	1	2	53	0	1	57
0	1	54	1	2	71	0	1	41	1	3	51	0	2	56
0	1	49	0	3	40	0	1	42	0	1	49	0	2	63
0	2	42	0	1	41	0	3	50	0	3	57	1	2	54

0	1	52	0	1	56	0	1	39	1	3	52	0	2	43
0	3	66	0	3	47	0	2	48	1	2	56	2	2	63
2	2	72	1	2	53	0	2	51	0	3	40	1	2	48
3	2	57	0	2	50	0	2	62	1	2	66	6	2	69
0	1	50	1	3	51	0	1	43	1	1	46	0	1	60
1	1	44	1	2	51	0	2	54	1	2	53	0	2	49
0	3	40	0	2	49	0	3	39	0	1	58	0	2	50
3	2	50	0	2	54	1	1	58	1	1	55	0	2	51
2	2	67	2	2	49	0	1	45	1	2	54	1	2	50
0	1	43	1	2	68	0	2	54	0	2	55	1	2	75

자료출처: https://stats.idre.ucla.edu/stat/data/poisson_sim.csv

4. $y_i \sim \text{poisson}(\mu)$, $i = 1, 2, \dots, n$, 확률표본일 때 이탈도를 구하시오.