



연습문제

1. $Y_i = \beta_0 + \beta_1 X_i + \epsilon_i$ 에서 절편과 기울기의 추정식은?

답 기울기 $\hat{\beta}_1 = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sum (X_i - \bar{X})^2}$

절편 $\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$

2. 다음은 R을 이용한 회귀적합 결과의 일부이다. 추정된 회귀식은?

```
> market_lm = lm(Y ~ X, data=market)
> summary(market_lm)
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   0.3282      1.4302   0.229   0.822
X              2.1497      0.1548  13.889 3.55e-09 ***
```

답 $\hat{Y} = 0.3282 + 2.1497X$

3. 산점도 위에 회귀직선을 그리고자 한다. R 함수 (a)는?

```
> plot(market$X, market$Y, xlab="인테리어비", ylab="총판매액", pch=19)
> (a)(market_lm)
```

답 `abline`

4. 다음은 분산분석 결과이다. (b) 값을 구하는 식은?

```
> anova(market_lm)
Analysis of Variance Table

Response: Y
      Df Sum Sq Mean Sq F value    Pr(>F)
X       1  485.57   485.57    (b) 3.554e-09 ***
Residuals 13   32.72     2.52
```

답 $(b) = 485.57/2.52$

5. 4번 분산분석 결과에서 오차분산 σ^2 의 추정값은?

답 $\hat{\sigma}^2 = 2.52$

6. 4번 분산분석 결과에서 결정계수를 구하면?

답 $R^2 = 485.57 / (485.57 + 32.72) = 485.57 / 518.29 = 0.9369$

7. 4번 분산분석 결과에서 귀무가설 $H_0 : \beta_1 = 0$ 의 검정 결과는(유의수준 0.05 기준)?

답 p 값 $= 3.55 \times 10^{-9} < 0.05$ 이므로 $H_0 : \beta_1 = 0$ 을 기각한다.

8. 주어진 X 에서 신뢰구간을 구하고자 한다. 기댓값의 신뢰구간을 구하기 위한 옵션 (f)는?

```
> pred_frame = data.frame(X=seq(3.5, 14.5, 0.2))  
> pc = predict(market_lm, (f), newdata=pred_frame)
```

답 int="c" (또는 interval="confidence")

9. 주어진 X 에서 신뢰구간을 구하고자 한다. 새로운 예측값의 신뢰구간을 구하기 위한 옵션 (g)는?

```
> pred_frame = data.frame(X=seq(3.5, 14.5, 0.2))  
> pp = predict(market_lm, (g), newdata=pred_frame)
```

답 int="p" (또는 interval="prediction")

10. 주어진 X 에서 구해진 신뢰구간을 이용하여 신뢰대를 그리고자 한다. R 함수 (h)는?

```
> pred_X = pred_frame$X  
> plot(market$X, market$Y, ylim=range(market$Y, pp))  
> (h)(pred_X, pc, lty=c(1,2,2), col="BLUE")  
> (h)(pred_X, pp, lty=c(1,3,3), col="RED")
```

답 matlines

11. ggplot2를 이용하여 신뢰대를 그리고자 한다. R 명령 (i)는?

```
> library(ggplot2)
> ggplot(all_data, aes(x=X, y=Y)) + # (,x, y) 변수 정의
  (i) + # 산점도 그리기
  stat_smooth(method=lm) + # confidence band 그리기
  geom_line(aes(y = lwr), col = "coral2", linetype = "dashed") +
  geom_line(aes(y = upr), col = "coral2", linetype = "dashed")
```

답 geom_point()



연습문제

1. 중회귀모형 $Y = X\beta + \epsilon$ 에서 β 의 최소제곱추정량 $\hat{\beta}$ 는?

답 $\hat{\beta} = (X'X)^{-1}X'Y$

2. 행렬 X 의 치환행렬과의 곱 $X'X$ 를 구하는 R 명령은?

> $XTX = (a)$

답 $t(X) \%*\% X$

3. 행렬 $X'X$ 의 역행렬을 구하는 R 함수는?

> $XTXI = (b)(XTX)$

답 solve

4. 총제곱합 SST 를 행렬식으로 표현하면?

답 $SST = Y' \left(I - \frac{J}{n} \right) Y$

5. 잔차제곱합 SSE 를 행렬식으로 표현하면?

답 $SSE = Y'(I - H)Y$

여기서 $H = X(X'X)^{-1}X'$

6. 다음은 중회귀모형을 적합한 결과이다. 물음에 답하시오.

```
> market2_lm = lm(Y ~ X1+X2, data=market2)
> summary(market2_lm)
```

Call:

```
lm(formula = Y ~ X1 + X2, data = market2)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-1.30465	-0.69561	-0.01755	0.69003	1.53127

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.85041	0.84624	1.005	0.334770
X1	1.55811	0.14793	10.532	2.04e-07 ***
X2	0.42736	0.08431	5.069	0.000276 ***

 Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.9318 on 12 degrees of freedom
 Multiple R-squared: 0.9799, Adjusted R-squared: 0.9765
 F-statistic: 292.5 on 2 and 12 DF, p-value: 6.597e-11

- (1) 회귀분석 결과에서 적합된 회귀식은?
- (2) 적합된 회귀모형에 대한 결정계수는?
- (3) 귀무가설 $H_0 : \beta_1 = \beta_2 = 0$ 에 대한 검정 결과는? (유의수준 0.05 기준)

- 답** (1) $\hat{Y} = 0.8504 + 1.5581X_1 + 0.4274X_2$
- (2) 0.9799
- (3) 유의확률 p 값 = 6.597×10^{-11} 로써 매우 작아 귀무가설을 기각한다.

7. 다음은 분산분석 결과이다. 아래의 분산분석표 빈칸을 완성하시오.

<pre>> anova(market2_lm)</pre>				
Analysis of Variance Table				
Response: Y				
	Df	Sum Sq	Mean Sq	F value Pr(>F)
X1	1	485.57	485.57	559.283 1.955e-11 ***
X2	1	22.30	22.30	25.691 0.0002758 ***
Residuals	12	10.42	0.87	

요인	자유도	제곱합	평균제곱	F_0
회귀	()	507.87	()	()
잔차	12	()	0.87	
계	14	518.29		

요인	자유도	제곱합	평균제곱	F_0
회귀	2	507.87	253.94	292
잔차	12	10.42	0.87	
계	14	518.29		

8. 7번 분산분석표 결과에서 결정계수를 구하면?

답 $R^2 = 507.87/518.29 = 0.9799$

9. $Y = X\beta + \epsilon$, $\epsilon \sim N(0, I\sigma^2)$ 에서 추정량 $\hat{\beta}$ 의 분산을 구하면?

답 $Var(\hat{\beta}) = (X'X)^{-1}\sigma^2$

10. $y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \epsilon$ 을 적합시켰을 때, $x_1 = 10$, $x_2 = 10$ 에서 $E(Y)$ 를 95% 신뢰구간으로 추정하고자 한다. R 함수 (a)는?

```
> pred_x = data.frame(X1=10, X2=10)
> pc = (a)(market2_lm, int="c", newdata=pred_x)
> pc
      fit      lwr      upr
1 20.70503 19.95796 21.45209
```

답 predict

11. 다음은 추가제곱합을 구하기 위한 R 분석 결과이다. 물음에 답하시오.

```
> h3_lm = lm(Y ~ X1+X3+X4, data=health)
> h4_lm = lm(Y ~ X1+X2+X3+X4, data=health)
> anova(h3_lm, h4_lm)
Analysis of Variance Table

Model 1: Y ~ X1 + X3 + X4
Model 2: Y ~ X1 + X2 + X3 + X4
  Res.Df  RSS Df Sum of Sq    F Pr(>F)
1     26 20856
2     25 20551  1    304.62 0.3706 0.5482
```

(1) (X_1, X_3, X_4) 인 모형에 X_2 을 추가하는 경우의 증가되는 추가회귀제

곱합은?

- (2) 유의수준 0.05에서 검정할 때, 변수 X_2 는 (X_1 , X_3 , X_4) 모형에 유의한 변수인지 검정하시오.

답 (1) 304.62

- (2) p 값 = 0.5482 > 0.05이므로 귀무가설을 받아들인다. 즉, 변수 X_2 는 유의하지 않다.

12. 추가변수그림을 그리고자 한다. R 패키지 car에서 이용하는 함수 (b)는?

```
> library(car)
> h4_lm = lm(Y ~ X1+X2+X3+X4, data=health)
> (b)(h4_lm)
```

답 avPlots



연습문제

1. 분산팽창인자를 계산하고자 한다. R 함수 (a)는?

```
> install.packages("fmsb")
> library(fmsb)
> (a)(lm(X1~X2+X3+X4+X5, data=hospital))
[1] 9597.571
```

답 VIF

2. 1번 결과에서 볼 때, 다중공선성이 존재한다고 할 수 있는가?

답 VIF 값=9597로 매우 크므로 다중공선성이 존재한다.

3. 다음은 모든 가능한 회귀를 위한 R 결과이다. 물음에 답하시오.

```
> library(a)
> all_lm = regsubsets(Y ~. , data=hald)
> (rs=summary(all_lm))
Subset selection object
Call: regsubsets.formula(Y ~ ., data = hald)
4 Variables (and intercept)
  Forced in Forced out
X1    FALSE    FALSE
X2    FALSE    FALSE
X3    FALSE    FALSE
X4    FALSE    FALSE
1 subsets of each size up to 4
Selection Algorithm: exhaustive
      X1 X2 X3 X4
1 ( 1 ) " " " " "*"
2 ( 1 ) "*" "*" " " "
3 ( 1 ) "*" "*" " " "*"
4 ( 1 ) "*" "*" "*" "*"

> names(rs)
[1] "which" "rsq" "rss" "adjr2" "cp" "bic" "outmat" "obj"
```



```
> round(rs$rsq, 3)
[1] 0.675 0.979 0.982 0.982
> round(rs$adjr2, 3)
[1] 0.645 0.974 0.976 0.974
> round(rs$cp, 3)
[1] 138.731 2.678 3.018 5.000
```

- (1) 모든 가능한 회귀를 위한 R 패키지 (a)는?
- (2) 변수가 하나인 경우 최적으로 채택되는 변수는?
- (3) 변수가 둘인 경우 최적으로 채택되는 변수는?
- (4) 수정결정계수 기준으로 볼 때 최적으로 채택되는 변수는?
- (5) C_p 를 판정기준으로 할 경우에 채택되는 두 후보군을 고르면?

- 답** (1) leaps
 (2) X4
 (3) (X1, X2)
 (4) (X1, X2, X4)
 (5) (X1, X2) (X1, X2, X4)

4. 앞으로부터 선택법을 이용하여 변수선택을 하고자 한다. 옵션 (b)는?

```
> start_lm = lm(Y~1, data=hald)
> full_lm = lm(Y~ . , data=hald)
> step(start_lm, scope=list(lower=start_lm,upper=full_lm), direction="(b)")
```

- 답** forward

5. 뒤로부터 제거법을 이용하여 변수선택을 하고자 한다. 옵션 (c)는?

```
> step(full_lm, data=hald, direction="(c)")
```

- 답** backward

6. 단계별 회귀방법을 이용하여 변수선택을 하고자 한다. 옵션 (d)는?

```
> step(start_lm, scope=list(upper=full_lm), data=hald, direction="(d)")
```

- 답** both

7. 다음은 R 패키지 `olsrr`을 이용한 단계별 회귀선택 결과이다. 선택된 독립 변수는?

```
> library(olsrr)
> model = lm(Y ~ X1+X2+X3+X4, data=hald)
> ols_step_both_p(model)
```

Stepwise Selection Summary

Step	Variable	Added/ Removed	R-Square	Adj. R-Square	C(p)	AIC	RMSE
1	X4	addition	0.675	0.645	138.7310	97.7440	8.9639
2	X1	addition	0.972	0.967	5.4960	67.6341	2.7343
3	X2	addition	0.982	0.976	3.0180	63.8663	2.3087


답 (X4, X1, X2)



연습문제

1. 두 변수의 산점도가 다음과 같다. maraton 자료에서 m1990을 반응변수로, sect를 설명변수로 한 3차 다항회귀모형을 적합하고자 한다. (a)에 들어갈 R 명령은?

```
> plot(maraton$sect, maraton$m1990, pch=19)
```



```
> maraton_lm = lm(a)
```

답 $m1990 \sim \text{sect} + I(\text{sect}^2) + I(\text{sect}^3)$, data = maraton

2. 3차 다항회귀모형 적합 결과가 다음과 같다. 모형적합식은?

```
> summary(maraton_lm)
```

...

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	917.592857	8.083355	113.516	3.61e-08	***
sect	13.785281	1.462847	9.424	0.000707	***
I(sect^2)	-0.683225	0.073387	-9.310	0.000741	***
I(sect^3)	0.012248	0.001077	11.375	0.000341	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.281 on 4 degrees of freedom

Multiple R-squared: 0.9983, Adjusted R-squared: 0.9969

F-statistic: 761.4 on 3 and 4 DF, p-value: 5.726e-06

답 $\widehat{m}_{1990} = 917.593 + 13.785 \times \text{sec } t - 0.683 \times \text{sec } t^2 + 0.012 \times \text{sec } t^3$

3. 2번 3차 다항회귀모형 적합 결과에서 결정계수는?

답 0.9983

4. 다음과 같은 soup 자료에서 변수 D의 0="Line0" 1="Line2"로 범주화하려고 한다. R 함수 (b)는?


```
> soup = read.csv("c:/data/reg/soup.csv")
> soup[c(1,15,16,27),]
  Y   X D
1 218 100 1
15 367 265 1
16 140 105 0
27 410 295 0

> soup$D = (b)(soup$D, levels=c(0,1), label=c("Line0", "Line1"))
```

답 factor

5. 다음과 같이 그룹을 구분화하여 산점도를 그리고자 한다. R 함수 (d)는?

```
> plot(soup$X, soup$Y, type="n")
> (d)(soup$X[soup$D=="Line1"], soup$Y[soup$D=="Line1"], pch=17, col="BLUE")
> (d)(soup$X[soup$D=="Line0"], soup$Y[soup$D=="Line0"], pch=19, col="RED")
> legend("bottomright", legend=levels(soup$D), pch=c(19,17),
  col=c("RED", "BLUE"))
```



답 points

6. 5번 산점도를 보고, 다음과 같이 생산라인을 고려한 회귀모형을 적합하였다. 적합된 모형식은?

```
> soup_lm = lm(Y ~ X+D, data=soup)
> summary(soup_lm)
...
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  27.28179   15.40701   1.771  0.0893 .
X             1.23074    0.06555  18.775 7.48e-16 ***
DLine1       53.12920    8.21003   6.471 1.08e-06 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 21.13 on 24 degrees of freedom
Multiple R-squared:  0.9402,    Adjusted R-squared:  0.9352
F-statistic: 188.6 on 2 and 24 DF,  p-value: 2.104e-15
```

답 $\hat{Y} = 27.282 + 1.231X + 53.129D$

7. 6번 회귀적합 결과에서 생산라인 0과 1의 절편의 차이는?

답 Line1이 Line0보다 53.129 높다.

연습문제

1. 잔차벡터 e 와 $H = X(X'X)^{-1}X'$ 와의 관계식은?

답 $e = (I - H)Y$

2. 표준화 잔차(standardized residual) 식은?

답 $r_i = \frac{e_i}{\sqrt{MSE(1 - h_{ii})}}$

3. 스튜던트화 잔차(studentized residuals) 식은?

답 $t_i = \frac{e_i}{\sqrt{MSE_{(i)}(1 - h_{ii})}}$

4. 스튜던트화 잔차 t_i 와 표준화 잔차 r_i 와의 관계식은?

답 $t_i = r_i \left(\frac{n - k - 2}{n - k - 1 - r_i^2} \right)^{1/2}$

5. 잔차분석을 하고자 한다. R 함수 (a)는?

```
> forbes_res = (a)(forbes_lm)
> names(forbes_res)
[1] "std.dev"      "hat"          "std.res"      "stud.res"     "cooks"
[6] "dfits"        "correlation"  "std.err"      "cov.scaled"   "cov.unscaled"
```

답 ls.diag

6. 5번 결과에서 hat 값을 저장한 변수 (b)는?

```
> hat_value = (b)
```

답 forbes_res\$hat

7. 회귀적합모형의 분산분석 결과가 다음과 같다.

```
> anova(forbes_lm)
Analysis of Variance Table

Response: Lpress
      Df Sum Sq Mean Sq F value    Pr(>F)
temp    1  425.76   425.76  2961.5 < 2.2e-16 ***
Residuals 15    2.16    0.14
```

12번째 관측값의 스튜던트화 잔차는 12.3740이다. 이 관측점의 Bonferroni 보정 유의확률 p 값을 계산하는 R 식 (a)는?

```
> bon_pvalue = (a)
```

답 $2*17*(1-pt(12.374, 14))$

8. 특이점 검정을 위해서는 R 패키지 car의 함수를 이용하고자 한다. R 함수 (b)는?

```
> install.packages("car")
> library(car)
> (b)(forbes_lm)
      rstudent unadjusted p-value Bonferonni p
12 12.37386          6.3025e-09  1.0714e-07
```

답 outlierTest

9. 다음과 같은 모형적합 결과 soil_lm에서 Cook의 거리를 구하고자 한다. R 함수 (c)는?

```
> soil_lm = lm(SL ~ SG+LOBS+PGC, data=soil)
> Di = (c)(soil_lm)
> round(Di,3)
      1      2      3      4      5      6      7      8      9     10     11
0.117 0.029 0.000 0.000 0.002 0.000 1.227 0.041 0.171 0.289 0.022
```

답 cooks.distance

10. 9번 결과에서 영향력 있는 관측점으로 판별되는 관측점은?

답 7번



연습문제

1. 오차의 등분산성을 검정하고자 한다. R 함수 (a)는?

```
> install.packages("car")
> library(car)
> (a)(goose_lm)
Non-constant Variance Score Test
Variance formula: ~ fitted.values
Chisquare = 81.41318, Df = 1, p = 1.831324e-19
```


답 ncvTest

2. 1번 결과에서 등분산 가정에 대한 검정 결과는? (단, 유의수준 0.05 기준)

답 유의확률 p 값 = 1.83×10^{-19} 이 0.05보다 작으므로 등분산 가정을 기각한다.

3. 다음과 같은 잔차산점도를 그렸다. 가장 뚜렷하게 의심되는 모형의 가정은?

```
> tree_lm = lm(V ~ D+H, data=tree)
> plot(tree$D, tree_lm$resid, pch=19)
```



답 모형의 선형성

4. 3번 잔차산점도에서 모형에 새로 포함시키는 것이 요구되는 변수항은?

답 D^2

5. 오차의 정규성을 검정할 때, 정규확률그림을 그리기 위한 R 함수 (d)는?

```
> library(ggplot2)
> library(qqplotr)
> goose_lm = lm(photo ~ obsA, data=goose)
> rstandard_values = rstandard(goose_lm)
> (d)(mapping = aes(sample = rstandard_values)) +
  stat_qq_point(size = 2, color = "red") +
  stat_qq_line(color="black") +
  xlab("theoretical") + ylab("rstandard")
>
```

답 ggplot

6. Shapiro-Wilk의 정규성 검정을 실시하고자 한다. R 함수 (e)는?

```
> install.packages("mvnrmtest")
> library(mvnrmtest)
> goose_rstandard = rstandard(goose_lm)
> (e)(goose_rstandard)
```

Shapiro-Wilk normality test

data: goose.rstandard

W = 0.79132, p-value = 1.541e-06


답 shapiro.test

7. 6번 결과에서 정규성 검정 결과는? (단, 유의수준 0.05 기준)

답 p 값 = $1.541 \times 10^{-6} < 0.05$ 이므로 정규분포를 따른다는 가설을 기각한다.

8. 다음은 Box-Cox 변환 결과이다. 적절한 Y 변수의 변환은?

```
> install.packages("MASS")
> library(MASS)
> bc = boxcox(energy_lm)
> str(bc)
List of 2
 $ x: num [1:100] -2 -1.96 -1.92 -1.88 -1.84 ...
 $ y: num [1:100] -232 -228 -224 -220 -216 ...
> bc_lambda = bc$x[which.max(bc$y)]
> bc_lambda
[1] 0.4646465
```



답 $\sqrt{}$ (제곱근) 변수변환



연습문제

1. 일반화선형모형의 세 가지 구성성분은?

답 반응변수의 분포, 선형예측자, 연결함수

2. 반응변수가 베르누이분포인 경우, 정준연결 함수는?

답 $g(\mu) = \log\left(\frac{\mu}{1-\mu}\right)$

3. 반응변수가 포아송분포인 경우, 정준연결 함수는?

답 $g(\mu) = \log(\mu)$

4. 다음 자료에서 occur을 반응변수(1=yes, 0=no)로 하여 로지스틱회귀모형을 적합하고자 한다. (a)에 들어갈 옵션은?

```
> head(glider, 3)
  p_no occur con_metric p_size_km
1    1     1    0.650    130.9
2    2     0    0.610    104.1
3    3     0    0.744    132.3
> #모형적합
> logit_m1 <- glm(occur~p_size_km+con_metric, family=(a)(link=logit),
                  data=glider)
```

답 binomial

5. 다음은 4번 logit_m1의 결과이다. 물음에 답하시오.

```
> summary(logit_m1)
Call:
glm(formula = occur ~ p_size_km+con_metric, family = binomial(link =
  logit), data = glider)
Deviance Residuals:
```

	Min	1Q	Median	3Q	Max
	-1.4969	-0.8829	-0.3884	0.8766	2.0515

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-3.606207	1.436391	-2.511	0.01205 *
p_size_km	0.023566	0.007462	3.158	0.00159 **
con_metric	1.631800	1.642758	0.993	0.32055

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 68.994 on 49 degrees of freedom

Residual deviance: 54.661 on 47 degrees of freedom

AIC: 60.661

Number of Fisher Scoring iterations: 4

- (1) 적합된 로지스틱회귀식을 쓰시오.
- (2) 유의수준 0.05에서 검정할 때, 두 독립변수(con_metric, p_size_km) 중 유의한 변수를 고르면?
- (3) 이탈도(Residual deviance)에 근거하여 모형의 적합도에 대하여 평가하시오.
- (4) 다음에서 두 모형의 분산분석 결과를 비교하기 위한 R 함수 (b)는?

```
> logit_m1 <- glm(occurr~p_size_km+con_metric, family=(a)(link=logit),
  data=glider)
> logit_m2 <- glm(occurr ~ p_size_km, family=binomial(link=logit),
  data=glider)
> (b)(logit_m2, logit_m1, test='Chisq')
```

Analysis of Deviance Table

	Model 1: occur ~ p_size_km	Model 2: occur ~ p_size_km + con_metric
Resid. Df	48	47
Resid. Dev	55.716	54.661
Df		1
Deviance		1.0546
Pr(>Chi)		0.3045

- (5) 위 (4)번 결과에서 변수 con_metric를 추가하는 것이 유의한지 검정 결과는? (단, 유의수준 0.05 기준)
- (6) 두 모형의 AIC 결과가 다음과 같다. 두 모형 중에서 더 적합한 모형은?

```
> AIC(logit_m2, logit_m1)
      df      AIC
logit_m2 2 59.71577
logit_m1 3 60.66120
```

(7) AIC 값을 기준으로 가장 적합한 모델을 자동으로 선택하고자 한다. R 명령 (c)는?

```
> library(MASS)
> (c)(logit_m1, direction='both')
```

답 (1) $\log\left(\frac{\hat{\pi}}{1-\hat{\pi}}\right) = -3.606 + 0.024x_1 + 1.632x_2$

(2) p_size_km

(3) $54.661/47 = 1.163$ 으로 1에 가까워 모형적합도가 있다고 판단한다.

(4) anova

(5) p 값 = 0.305 > 0.05이므로 유의하지 않다.

(6) logit_m2

(7) stepAIC

6. 다음 자료에서 occur를 반응변수(1=yes, 0=no)로 하고, p_size_km을 설명변수로 하여 로지스틱회귀모형을 적합하였다. 이 결과에서 p_size_km이 1km 증가할 때 Sugar Glider가 출현할 승산은 몇 배 증가할 것으로 추정되는가? (소수점 이하 3자리)

```
> head(glider, 3)
  p_no occur con_metric p_size_km
1    1     1      0.650      130.9
2    2     0      0.610      104.1
3    3     0      0.744      132.3
> logit_m2 <- glm(occur~p_size_km, family=(a)(link=logit), data=glider)
> exp(coef(logit_m2))
(Intercept)  p_size_km
0.07979473  1.02196464
```

답 1.022배

7. 다음 모형 적합에서 p_size_km=150인 경우, Sugar Glider가 출현할 확률을 구하고자 한다. R 명령 (a)는?

```
> logit_m2 <- glm(occurr~p_size_km, family=(a)(link=logit), data=glider)
> x <- 150
> (a)(logit_m2, list(p_size_km=x), type="response")
0.6749669
```

 predict



연습문제

1. 다음 2×2 분할표의 확률분포에서 X 값에 대한 승산비(odds ratio)는?

구분		Y	
		1	0
X	1	π_1	$1 - \pi_1$
	2	π_2	$1 - \pi_2$

답 $OR = \frac{\pi_1(1 - \pi_2)}{\pi_2(1 - \pi_1)}$

2. 1번 분할표에서 상대위험도(relative risk)는?

답 $RR = \frac{\pi_1}{\pi_2}$

3. 다음은 다항로짓모형 적용 결과이다. (a) 함수는?

```
> install.packages("nnet")
> library(nnet)
> ml.prog1 <- (a)(program ~ ses + write, data = prg.d)
> summary(ml.prog1)
...
Coefficients:
              (Intercept) sesmiddle  seshigh    write
academic      0.205    0.533    1.163    0.549
vocation     -0.572    0.824    0.180   -0.528
```

답 multinom

4. 3번의 결과에서 $\log \left[\frac{\hat{P}(Y = \text{academic})}{\hat{P}(Y = \text{general})} \right]$ 의 추정식은? (단, Y 의 세 범주는 academic, general, vocation임)

답 $\log \left[\frac{\hat{P}(Y = \text{academic})}{\hat{P}(Y = \text{general})} \right] = 0.205 + 0.533x_1 + 1.163x_2 + 0.549x_3$

5. 3번 결과에서 승산비 추정값을 다음과 같이 구하였다. 사회경제적 상태 (x_1 , x_2)가 주어졌을 때, 쓰기 점수(x_3)가 1 증가하면 'general' 학습 프로그램보다 'academic'을 선택할 승산은?

```
> exp(coef(ml.prog1))
      (Intercept) sesmiddle seshigh      write
academic  1.2275077  1.704530  3.198976  1.7316510
vocation   0.5642881  2.281154  1.197388  0.5899568
```

답 승산은 $e^{0.549} = 1.732$ 배 증가한다.

6. 다음은 고속도로 속도제한 여부와 교통사고 발생건수 자료의 일부이다. 고속도로의 속도제한이 평균 교통사고 발생건수에 어떤 영향을 주는지를 분석하고자 한다. R 명령 (a)는?

year	day	limit	y	year	day	limit	y
1961	1	no	9	1962	1	no	9
1961	2	no	11	1962	2	no	20
1961	3	no	9	1962	3	no	15
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮

```
> # day와 year를 factor 변수로 바꾸기
> day <- as.factor(day); year <- as.factor(year)
> log_m1 <- glm(y~limit+day, (a))
> summary(log_m1)
```

답 family = poisson(link = log)

7. 다음은 6번 결과의 일부이다. 모형의 적합검정 결과는?

```
> summary(log_m1)
...
Coefficients:
      Estimate Std. Error z value Pr(>|z|)
(Intercept)  2.19722    0.23570   9.322 < 2e-16 ***
limityes     -0.29627    0.03978  -7.448 9.46e-14 ***
day2         0.54362    0.29633   1.834 0.066584 .
⋮             ⋮           ⋮         ⋮
day92        0.64803    0.29862   2.170 0.030004 *
```



```

Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
(Dispersion parameter for poisson family taken to be 1)
    Null deviance: 625.25  on 183  degrees of freedom
Residual deviance: 107.64  on  91  degrees of freedom
AIC: 1183.6
> 1-pchisq(107.64,91)
[1] 0.1123525

```

답 잔차 이탈도와 잔차 자유도를 비교하면 $107.64/91 = 1.18$ 로 1에 가깝고 적합결여검정 결과 유의확률이 0.112(>0.05)로 모형의 적합결여는 통계적으로 유의하지 않다.

8. 6번에서 $\exp(\beta)$ 의 추정값이 다음과 같다. 고속도로에서 속도제한을 했을 때의 평균 교통사고 발생건수를 속도제한을 하지 않았을 때의 평균 교통사고 발생건수와 비교하면?

```

> exp(coef(log_m1))
(Intercept)    limityes      day2      day3      day4      day5
  9.0000000    0.7435897    1.7222222    1.3333333    1.8888889    3.3888889
...

```

답 74.4% 수준으로 감소한다.