


2026년 1학기

회귀모형 - 출석수업

단순회귀모형과 중회귀모형

통계·데이터과학과 박준희



출석수업안내

- 1 강의자료: 박준희교수 홈페이지자료실
- 2 질문: 박준희교수 홈페이지상담게시판
- 3 강의범위: 교재 1~2장

01

단순회귀모형

1

단순회귀모형

- 회귀분석(regression analysis)이란?
 - 독립변수와 종속변수 사이의 함수 관계를 규명
 - 일반적으로 상관관계를 파악하며, 인과관계를 보장하지 않음
 - 보통 $Y = f(X)$ 로 표현, 가장 기본적인 형태는 선형 회귀모형

용어정리

- X: 독립변수, 설명변수, 회귀변수, 피쳐(features)
- Y: 종속변수, 반응변수, 결과변수, 레이블/타겟(label/target)
- 상관관계: X가 증가했을 때, (X 때문인지는 모르지만) Y가 증가/감소
- 인과관계: X를 증가시키면, (X 때문에) Y가 증가/감소

1

단순회귀모형

● 회귀분석의 유래

■ Galton (1822~1911):

부모와 자녀의 키 상관관계 연구 중,

극단적인 키는 자식 세대에서 평균에 가까워지는 현상 발견

→ 이를 “회귀(regression)”라 명명

■ 이후 Karl Pearson (1857~1936) 등 많은 통계학자들이 방법론을 체계적으로 발전

■ 현대 통계학에서의 회귀:

‘원래 자리로 돌아간다’는 의미보다는,

한 변수가 다른 변수에 미치는 영향을 추정하는 통계 기법을 통칭하는 용어로 사용

1

단순회귀모형

● 단순선형회귀모형 (Simple Linear Regression Model)

- 한 개의 독립변수 X 와 한 개의 종속변수 Y 간의 선형관계를 모형화한 것

$$Y_i = \beta_0 + \beta_1 X_i + \epsilon_i,$$

여기서

- Y_i : 관측된 종속변수 값 (반응값)
- X_i : 관측된 독립변수 값 (설명변수)
- β_0 : 절편(Intercept)
- β_1 : 기울기(Slope)
- ϵ_i : 오차항(에러, Error term)


1 단순회귀모형

● 단순선형회귀모형 (Simple Linear Regression Model)

- Note : 회귀모형의 X 는 확률변수가 아닌 고정된 상수이다!
- Review : 확률변수 X 란?

(확률변수 자체는 대문자로, 확률변수의 실현값은 소문자로 표기)

예 1) $X_1, X_2, \dots, X_5 \sim \text{iid } N(0, 1)$ 일 때 해당 확률변수들과 그 관측치



$x_1 = 0.256285$ $x_2 = 0.738751$ $x_3 = -0.210766$ $x_4 = -0.553941$ $x_5 = 0.076406$

$E[X_1] = 0$, $\text{Var}[X_2] = 1$, $\text{SD}[X_3] = 1$, $P(X_4 \leq 1.96) = 0.975$, $P(X_5 \leq 0) = 0.5$

(“회귀모형”에서는 과목 성격상 이러한 대소문자 notation 구분을 엄격하게 적용하지 않음)

1

단순회귀모형

● 단순회귀모형에서 사용되는 가정

- 선형성 (Linearity): Y 와 X 가 선형관계를 이룬다.
- 독립성 (Independence): 관측된 오차항 ϵ_i 들이 서로 독립이다.
- 등분산성 (Homoscedasticity): 오차항 ϵ_i 의 분산이 일정하다 (즉, $\text{Var}(\epsilon_i) = \sigma^2$ 는 모든 i 에 대해 동일).
- 정규성 (Normality): 오차항 ϵ_i 가 정규분포를 따른다($\epsilon_i \sim N(0, \sigma^2)$).


1 단순회귀모형

● 데이터 시각화: 산점도 (Scatter Plot)

- 두 변수 X와 Y의 관계가 정말 선형적인지(또는 어떤 형태인지)를 가장 먼저 파악하는 방법은 산점도를 그려보는 것
- 산점도를 통해 직관적으로 두 변수 사이의 상관관계를 확인할 수 있음

산점도의예 (교재 6페이지 그림 1-1)

- X:인테리어비
- Y:총판매액
- 두 변수간양의상관관계가있음을직관적으로확인 가능



1

단순회귀모형

● 회귀선의 추정 - 최소제곱법 (Least Squares Method)

- 다음의 오차제곱합을 **최소화**하는 β_0 와 β_1 값을 찾는 방법

$$S = \sum_{i=1}^n (Y_i - (\beta_0 + \beta_1 X_i))^2$$

- 이를 편미분하여 0이 되게 하는 **정규방정식**(Normal equations)을 풀면, 아래와 같은 결과를 얻음

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2}, \quad \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X},$$

여기서

- $\bar{X}, \bar{Y}$ 는 각각 X, Y 의 평균

1 단순회귀모형

- 벡터-행렬 표기를 이용한 추정 (LSE와 MLE)
 - 정규분포가정하에서는 최소제곱추정량(Least Squares Estimator, LSE)과 최대우도추정량(Maximum Likelihood Estimator, MLE)이 일치

$$Y_i = \beta_0 + \beta_1 X_i + \epsilon_i, \quad \epsilon_i \sim N(0, \sigma^2), \quad i = 1, \dots, n$$

위 식을 **벡터-행렬** 형태로 한 번에 표현하면,

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim N_n(0, \sigma^2 \mathbf{I}_n),$$

여기서

$$\mathbf{Y} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix}, \quad \mathbf{X} = \begin{pmatrix} 1 & X_1 \\ \vdots & \vdots \\ 1 & X_n \end{pmatrix}, \quad \boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix}, \quad \boldsymbol{\epsilon} = \begin{pmatrix} \epsilon_1 \\ \vdots \\ \epsilon_n \end{pmatrix}.$$

1

단순회귀모형

● 벡터-행렬 표기를 이용한 추정 (LSE와 MLE)

즉, $\epsilon_i \sim N(0, \sigma^2)$ 라는 정규분포 가정 하에서는

$$\mathbf{Y} \sim N_n(\mathbf{X}\boldsymbol{\beta}, \sigma^2 I_n),$$

이 되고, 그에 따른 우도함수 $L(\boldsymbol{\beta}, \sigma^2)$ 및 로그우도 $l(\boldsymbol{\beta}, \sigma^2)$ 는

$$L(\boldsymbol{\beta}, \sigma^2) = (2\pi\sigma^2)^{\frac{n}{2}} \exp\left(-\frac{1}{2}(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})^\top (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})\right),$$

$$l(\boldsymbol{\beta}, \sigma^2) = -\frac{n}{2}\ln(2\pi) - \frac{n}{2}\ln(\sigma^2) - \frac{1}{2\sigma^2}(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})^\top (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}).$$

여기서, **잔차제곱합** $(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})^\top (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})$ 이 등장하며, $l(\boldsymbol{\beta}, \sigma^2)$ 를 $\boldsymbol{\beta}$ 에 대한 최대화, 즉, 벡터 미분 계산 과정은 잔차제곱합 항을 최소화하는 과정과 같음.

1

단순회귀모형

● 벡터-행렬 표기를 이용한 추정 (LSE와 MLE)

참고: 행렬/벡터 미분

$$\begin{aligned}
 (\mathbf{Y} - \mathbf{X}\beta)^\top (\mathbf{Y} - \mathbf{X}\beta) &= \mathbf{Y}^\top \mathbf{Y} - \beta^\top \mathbf{X}^\top \mathbf{Y} - \mathbf{Y}^\top \mathbf{X}\beta + \beta^\top \mathbf{X}^\top \mathbf{X}\beta \\
 \frac{\partial ((\mathbf{Y} - \mathbf{X}\beta)^\top (\mathbf{Y} - \mathbf{X}\beta))}{\partial \beta} &= \frac{\partial(\mathbf{Y}^\top \mathbf{Y})}{\partial \beta} - \frac{\partial(\beta^\top \mathbf{X}^\top \mathbf{Y})}{\partial \beta} - \frac{\partial(\mathbf{Y}^\top \mathbf{X}\beta)}{\partial \beta} + \frac{\partial(\beta^\top \mathbf{X}^\top \mathbf{X}\beta)}{\partial \beta} \\
 &= -\mathbf{X}^\top \mathbf{Y} - \mathbf{X}^\top \mathbf{Y} + 2\mathbf{X}^\top \mathbf{X}\beta \\
 &= -2\mathbf{X}^\top \mathbf{Y} + 2\mathbf{X}^\top \mathbf{X}\beta
 \end{aligned}$$

1

단순회귀모형

- 벡터-행렬 표기를 이용한 추정 (LSE와 MLE)

$l(\beta, \sigma^2)$ 를 β 로 미분하여 **0** 나오는 조건을 정리하면:

$$\frac{\partial l}{\partial \beta} = \frac{1}{\sigma^2} (\mathbf{X}^\top \mathbf{Y} - \mathbf{X}^\top \mathbf{X} \beta) = \mathbf{0}$$

$$\mathbf{X}^\top \mathbf{X} \hat{\beta} = \mathbf{X}^\top \mathbf{Y} \quad \Longrightarrow \quad \hat{\beta} = \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \end{pmatrix} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}.$$

1 단순회귀모형

● 단순회귀모형의 적합과 결과 해석

- 예시데이터(교재 5페이지 표 1-1, market-1.csv)를 가지고 R로 단순회귀분석실행

- ID:상점번호

- X:인테리어비

(단위: 1,000만 원)

- Y:총판매액

(단위: 10,000만 원)

ID	X	Y
1	4.2	9.3
2	8.5	18.5
3	9.3	22.8
4	7.5	17.7
5	6.3	14.6
6	12.2	27.9
7	6.5	12.5
8	10.4	25.2
9	5.8	10.8
10	9.2	20.5
11	7.2	14.9
12	8.5	19.2
13	10.6	22.5
14	13.9	28.4
15	12.7	25.6

R 코드:

```
market = read.csv("market-1.csv")
market_lm = lm(Y ~ X, data = market)
summary(market_lm)
```

출력:

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.3282	1.4302	0.229	0.822
X	2.1497	0.1548	13.889	3.55e-09 ***

1

단순회귀모형

● 단순회귀모형의 적합과 결과 해석

따라서 추정된 회귀식은

$$\hat{Y} = 0.3282 + 2.1497 X$$

여기서 t-검정 결과를 보면, $\hat{\beta}_1$ 에 대한 p-값이 매우 작으므로(3.55×10^{-9}), 기울기가 0이 아니다(즉, X 가 Y 에 유의한 영향을 준다)라고 판단할 수 있다.

1

단순회귀모형

- 분산분석표에 의한 F -검정
 - 분산분석표를 통한 모형의 유의성평가

$$SST = \sum_{i=1}^n (Y_i - \bar{Y})^2, \quad SSE = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2, \quad SSR = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2$$

- 여기서
 - SST: 총편차 제곱합(total sum of squares), 자유도는 $n - 1$
 - SSE: 오차(residual) 제곱합(sum of squares due to error), 자유도는 $n - 2$
 - SSR: 회귀(regression) 제곱합(sum of squares due to regression), 자유도는 1 (독립변수의 수)

1

단순회귀모형

● 분산분석표에 의한 F -검정

- 분산분석표(ANOVA table)에서 F -값은 다음과 같이 계산된다.

$$F_0 = \frac{MSR}{MSE} = \frac{SSR/1}{SSE/(n-2)}.$$

- R에서 `anova(market_lm)` 같은 함수를 통해 ANOVA 표를 얻을 수 있으며, p -값을 통해 **회귀모형이 유의미한지**(즉, $\beta_1 \neq 0$)를 판단할 수 있다.

Analysis of Variance Table

Response: Y

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
X	1	485.57	485.57	192.9	<u>3.554e-09</u> ***
Residuals	13	32.72	2.52		

1

단순회귀모형

- 결정계수(R^2)와 모형의 설명력

- 결정계수(R^2): 전체 변동(SST) 중에서 회귀직선에 의해 설명되는 비율(SSR)

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}.$$

- R^2 값은 0부터 1 사이에 있으며, 1에 가까울수록 **모형이 데이터의 변동을 잘 설명**
- 예를 들어, R 코드의 `summary(market_lm)` 결과에서 **Multiple R-squared: 0.9369** 라면, **93.69%** 정도의 변동을 X 로 설명할 수 있다고 해석

1

단순회귀모형

- 추정값의 표준오차 (Residual Standard Error)

- 표준오차: 추정량(Estimator)의 표준편차
- 추정량(Estimator)이란 무엇인가?

모수를 '추정'하기 위하여 만든, 표본들로 이루어진 함수 (통계량, Statistic)
무엇을 추정하는지에 따라 다양한 표준오차가 존재

예: 회귀계수($\hat{\beta}$)의 표준오차, X_h 에서 Y 의 기대값($\hat{Y}_h$)의 표준오차 등

- 추정치(Estimate)란 무엇인가?

추정량의 실현값 (즉, 추정치는 상수)

즉, 추정량은 같은 대상(통계량)을 확률변수의 관점에서 보는 것이고,
추정치는 해당 확률변수 실현값의 관점으로 보는 것

1

단순회귀모형

- 추정값의 표준오차 (Residual Standard Error)

- MSE의제곱근(Root MSE, RMSE) : $\sqrt{MSE}$

추정값의 표준오차(Standard Error of Estimate),
잔차표준오차(Residual Standard Error) 등 '표준오차'로 불리지만,
실제로는 특정 통계량의 표준오차를 의미하기보다는
모델상의 σ 에 대한 불편추정량으로 해석하는 것이 일반적
 σ : 모형의 예측오차가 어느 정도인지 반영하는 모수

1 단순회귀모형

● 단순회귀에서의 추정과 검정

■ 관심모수: β_1

■ β_1 의 추정량:
$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

■ β_1 의 표준오차:
$$SE[\hat{\beta}_1] = \frac{\sigma}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2}}$$

■ β_1 의 표준오차의 추정치:
$$\hat{SE}[\hat{\beta}_1] = \sqrt{\frac{MSE}{\sum_{i=1}^n (X_i - \bar{X})^2}}$$

1

단순회귀모형

● 신뢰구간과 예측구간

- 모수: 추정(및 검정)대상 / 확률변수: 예측대상

특정 X_{new} 에서의 반응 Y_{new} 에 대해,

- Y_{new} 의 기대값 :

$$E[Y_{\text{new}}] = \beta_0 + \beta_1 X_{\text{new}}$$

- Y_{new} 의 기대값에 대한 추정량 :

$$\hat{Y}_{\text{new}} = \hat{\beta}_0 + \hat{\beta}_1 X_{\text{new}}$$

- $\hat{Y}_{\text{new}}$ 의 기대값 :

$$E[\hat{Y}_{\text{new}}] = \beta_0 + \beta_1 X_{\text{new}}$$

- $\hat{Y}_{\text{new}}$ 의 표준오차 :

$$SE[\hat{Y}_{\text{new}}] = \sigma \sqrt{\frac{1}{n} + \frac{(X_{\text{new}} - \bar{X})^2}{\sum_{i=1}^n (X_i - \bar{X})^2}}$$

- $\hat{Y}_{\text{new}}$ 의 표준오차의 추정치 :

$$\begin{aligned} \hat{SE}[\hat{Y}_{\text{new}}] &= \hat{\sigma} \sqrt{\frac{1}{n} + \frac{(X_{\text{new}} - \bar{X})^2}{\sum_{i=1}^n (X_i - \bar{X})^2}} \\ &= \sqrt{MSE \left(\frac{1}{n} + \frac{(X_{\text{new}} - \bar{X})^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \right)} \end{aligned}$$

1

단순회귀모형

● 신뢰구간과 예측구간

■ 모수: 추정(및 검정)대상 / 확률변수: 예측대상

- $\hat{Y}_{\text{new}}$ 의 신뢰구간 (Confidence Interval) : Y_{new} 의 기대값에 대한 불확실성 반영

$$\hat{Y}_{\text{new}} \pm t_{n-2, \alpha/2} \hat{SE} [\hat{Y}_{\text{new}}]$$

- Y_{new} 에 대한 개별 예측 : Y_{new} 를 모형에서의 확률변수 그대로 보는 것

$$Y_{\text{new}} = \beta_0 + \beta_1 X_{\text{new}} + \epsilon_{\text{new}} \sim \mathcal{N}(\beta_0 + \beta_1 X_{\text{new}}, \sigma^2)$$

- Y_{new} 의 예측구간 (Prediction Interval) : Y_{new} 의 확률변수 측면에 대한 불확실성 반영

$$\hat{Y}_{\text{new}} \pm t_{n-2, \alpha/2} \sqrt{MSE \left(1 + \frac{1}{n} + \frac{(X_{\text{new}} - \bar{X})^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \right)}$$

1

단순회귀모형

● 신뢰구간과 예측구간

- 모수: 추정(및 검정)대상 / 확률변수: 예측대상

```
> pred_frame = data.frame(X = c(5, 6, 10)) # 예측 원하는 X값
> predict(market_lm, newdata = pred_frame, interval = "confidence")
      fit      lwr      upr
1 11.07659  9.51348 12.63970
2 13.22626 11.92493 14.52760
3 21.82496 20.86048 22.78944
> predict(market_lm, newdata = pred_frame, interval = "prediction")
      fit      lwr      upr
1 11.07659  7.309431 14.84375
2 13.22626  9.559979 16.89255
3 21.82496 18.264287 25.38563
```

02

중회귀모형

2

중회귀모형

- 중회귀모형 (multiple regression model)
 - 종속변수 Y 의 변화를 설명하기 위해 두 개 이상의 독립변수($X_1, X_2, \dots, X_k$)를 사용하는 선형회귀모형

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \dots + \beta_k X_{ik} + \epsilon_i, \quad i = 1, 2, \dots, n$$

- 여기서
 - β_0 : 절편(intercept)
 - β_j : 독립변수 X_j 의 회귀계수(regression coefficient)
 - ϵ_i : 오차항(error term), $\epsilon_i \sim N(0, \sigma^2)$ 로 가정

2 중회귀모형

● 행렬을 이용한 중회귀모형

- n 개의 관측값에 대해,

$$\mathbf{Y} = \begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix}, \quad \mathbf{X} = \begin{pmatrix} 1 & X_{11} & X_{12} & \cdots & X_{1k} \\ 1 & X_{21} & X_{22} & \cdots & X_{2k} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & X_{n1} & X_{n2} & \cdots & X_{nk} \end{pmatrix}, \quad \boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \vdots \\ \beta_k \end{pmatrix}, \quad \boldsymbol{\epsilon} = \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{pmatrix}.$$

- 이를 이용하면 모형은

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}_n(0, \sigma^2 \mathbf{I}).$$

- 이 때

- $\mathbf{X}$: $n \times (k+1)$ 행렬(첫 번째 열은 모두 1, 나머지 열이 설명변수)
- $\boldsymbol{\beta}$: $(k+1) \times 1$ 벡터

2

중회귀모형

● 중회귀모형의 추정

- 최소제곱법(OLS): 중회귀모형에서 β 의 추정치 $\hat{\beta}$ 는, 다음과 같이 오차제곱합 S 을 최소화하는 문제를 통해 구한다

$$S = \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 X_{i1} - \cdots - \beta_k X_{ik})^2$$

- 행렬 표기로는

$$S = \epsilon^T \epsilon = (\mathbf{Y} - \mathbf{X}\beta)^T (\mathbf{Y} - \mathbf{X}\beta).$$

- 미분을 통해 정규방정식(normal equations)을 풀면, 다음과 같은 해를 얻을 수 있다

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}.$$

2

중회귀모형

● 중회귀모형의 추정

- 교재 51 페이지 표 2-1 “표본상점의 총판매액자료”(market-2.csv)

- ID: 상점번호

- X1: 인테리어비

(단위: 1,000만 원)

- X2: 상점의 크기

(단위: $10m^2$)

- Y: 총판매액

(단위: 10,000만 원)

ID	X1	X2	Y
1	4.2	4.5	9.3
2	8.5	12.0	18.5
3	9.3	15.0	22.8
4	7.5	8.5	17.7
5	6.3	7.4	14.6
6	12.2	18.5	27.9
7	6.5	5.5	12.5
8	10.4	16.5	25.2
9	5.8	3.7	10.8
10	9.2	13.5	20.5
11	7.2	5.2	14.9
12	8.5	15.0	19.2
13	10.6	14.4	22.5
14	13.9	13.3	28.4
15	12.7	12.5	25.6

2

중회귀모형

- 중회귀모형의 추정
 - 정규방정식의 해와 중회귀모형 적합 결과 비교

```
market2 = read.csv("market-2.csv")
```

```
X = market2[,c(2:3)]
```

```
X = cbind(1, X)
```

```
Y = market2[,4]
```

```
X = as.matrix(X) # design matrix
```

```
Y = as.matrix(Y)
```

```
hat_beta = solve(t(X) %*% X) %*% t(X) %*% Y
```

```
hat_beta
```

```
> hat_beta
```

```
      [,1]
1  0.8504051
X1 1.5581063
X2 0.4273559
```

```
# 중 회 귀 분 석
```

```
market2_lm = lm(Y ~ X1+X2, data=market2)
```

```
summary(market2_lm)
```

```
Coefficients:
```

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	0.85041	0.84624	1.005	0.334770	
X1	1.55811	0.14793	10.532	2.04e-07 ***	
X2	0.42736	0.08431	5.069	0.000276 ***	

2 중회귀모형

● 잔차의 성질

- 잔차(residual)는 추정된 회귀식의 예측값 $\hat{Y}_i$ 와 실제 관측값 Y_i 의 차이:

$$e_i = Y_i - \hat{Y}_i$$

- 행렬/벡터 형태로 쓰면,

$$\mathbf{e} = \mathbf{Y} - \hat{\mathbf{Y}} = \mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}} = (\mathbf{I} - \mathbf{H})\mathbf{Y}$$

여기서 $\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$ 는 흔히 "hat matrix"라고 부른다.

- 잔차 벡터 $\mathbf{e}$ 는 다음과 같은 성질을 가짐
 - $\sum e_i = 0$
 - $\sum X_{ij}e_i = 0$ (각 설명변수와 잔차의 곱의 합은 0)
 - $\sum \hat{Y}_i e_i = 0$
 - $E[\mathbf{e}] = \mathbf{0}$
 - $Var[\mathbf{e}] = (\mathbf{I} - \mathbf{H})\sigma^2$: 일반적으로 대각원소가 0이 아님 (잔차들 간 공분산 존재)

2

중회귀모형

● 중회귀모형 분산분석

- 전체 변동을 회귀(regression) 변동과 오차(residual) 변동으로 분할하여, 모형이 유의한지를 확인하는 데 사용

$$SST = \mathbf{Y}^T \left(I - \frac{J}{n} \right) \mathbf{Y}, \quad SSE = \mathbf{Y}^T (I - H) \mathbf{Y}, \quad SSR = \mathbf{Y}^T \left(H - \frac{J}{n} \right) \mathbf{Y},$$

(단, J 는 모든 원소가 1인 행렬)

여기서

- SST (Total Sum of Squares): 총변동
- SSE (Sum of Squares due to Error): 잔차(residual) 변동
- SSR (Sum of Squares due to Regression): 회귀(regression) 변동

2

중회귀모형

● 중회귀모형 분산분석

$$SST = \sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum_{i=1}^n (Y_i^2 - 2\bar{Y}Y_i + \bar{Y}^2) = \sum_{i=1}^n Y_i^2 - 2\bar{Y}(n\bar{Y}) + n\bar{Y}^2 = \boxed{\sum_{i=1}^n Y_i^2 - n\bar{Y}^2}$$

$$= (\mathbf{Y} - \bar{\mathbf{Y}})^T (\mathbf{Y} - \bar{\mathbf{Y}})$$

$$= \mathbf{Y}^T \left(I - \frac{J}{n} \right) \mathbf{Y}$$

$$= \underbrace{\mathbf{Y}^T \mathbf{Y}}_{\boxed{\sum_{i=1}^n Y_i^2}} - [\underbrace{Y_1 \ Y_2 \ \dots \ Y_n}] \begin{bmatrix} \frac{1}{n} & \frac{1}{n} & \dots & \frac{1}{n} \\ \frac{1}{n} & \frac{1}{n} & \dots & \frac{1}{n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{1}{n} & \frac{1}{n} & \dots & \frac{1}{n} \end{bmatrix} \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix} = \boxed{\sum_{i=1}^n Y_i^2 - n\bar{Y}^2}$$

$$SSE = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

$$= \mathbf{e}^T \mathbf{e}$$

$$= \mathbf{Y}^T (I - H)^T (I - H) \mathbf{Y} \quad (\mathbf{e} = (I - H) \mathbf{Y})$$

$$= \mathbf{Y}^T (I - H)(I - H) \mathbf{Y} \quad (\because I^T = I, H^T = H)$$

$$= \mathbf{Y}^T (I^2 - 2H + H^2) \mathbf{Y}$$

$$= \mathbf{Y}^T (I - H) \mathbf{Y}$$

$$\begin{bmatrix} \bar{Y} & \bar{Y} & \dots & \bar{Y} \end{bmatrix} \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix} = \bar{Y} (Y_1 + Y_2 + \dots + Y_n) = \bar{Y} (n\bar{Y}) = \boxed{n\bar{Y}^2}$$

2 중회귀모형

● 중회귀모형 분산분석

$$\begin{aligned}
 SSR &= \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2, \\
 &= (\hat{\mathbf{Y}} - \bar{\mathbf{Y}})^\top (\hat{\mathbf{Y}} - \bar{\mathbf{Y}}) \\
 &= \left(H\mathbf{Y} - \frac{J}{n}\mathbf{Y} \right)^\top \left(H\mathbf{Y} - \frac{J}{n}\mathbf{Y} \right) \quad \left(\hat{\mathbf{Y}} - \bar{\mathbf{Y}} = H\mathbf{Y} - \frac{J}{n}\mathbf{Y} \right) \\
 &= \mathbf{Y}^\top \left(H - \frac{J}{n} \right)^\top \left(H - \frac{J}{n} \right) \mathbf{Y} \\
 &= \mathbf{Y}^\top \left(H - \frac{J}{n} \right) \left(H - \frac{J}{n} \right) \mathbf{Y} \quad (\because H^\top = H, J^\top = J) \\
 &= \mathbf{Y}^\top \left(H^2 - \frac{1}{n}HJ - \frac{1}{n}JH + \frac{1}{n^2}J^2 \right) \mathbf{Y} \\
 &= \mathbf{Y}^\top \left(H - \frac{2}{n}J + \frac{1}{n^2}nJ \right) \mathbf{Y} \quad (\because \text{절편이 있는 회귀모형의 경우, } HJ = JH = J \text{ 성립}) \\
 &= \mathbf{Y}^\top \left(H - \frac{J}{n} \right) \mathbf{Y}.
 \end{aligned}$$

최종 요약

$$SST = \mathbf{Y}^\top \left(I - \frac{J}{n} \right) \mathbf{Y}, \quad SSE = \mathbf{Y}^\top (I - H) \mathbf{Y}, \quad SSR = \mathbf{Y}^\top \left(H - \frac{J}{n} \right) \mathbf{Y},$$

$$SST = SSR + SSE.$$

2

중회귀모형

● 중회귀모형 분산분석

- 절편이 있는 회귀모형에서 $HJ = J$ 증명

$J = \mathbf{X}A$ (A 는 첫 번째 행은 전부 1이고, 나머지 행은 전부 0인 $(k+1) \times n$ 행렬)

$H = \mathbf{X}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T$ 이므로,

$$\begin{aligned} HJ &= \mathbf{X}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{X}A \\ &= \mathbf{X}A \\ &= J \end{aligned}$$

2

중회귀모형

● 중회귀모형 분산분석

구분	자유도(df)	제곱합	평균제곱	F_0
회귀	k	SSR	$MSR=SSR/k$	$F_0 = \frac{MSR}{MSE}$
잔차	$n - k - 1$	SSE	$MSE=SSE/(n - k - 1)$	
계	$n - 1$	SST		

- 귀무가설: $H_0 : \beta_1 = \beta_2 = \dots = \beta_k = 0$
- 대립가설: H_1 : 적어도 하나의 β_j 는 0이 아니다.
- F_0 가 임계값보다 크거나, p -값이 매우 작다면, **모형이 유의**하다고 결론내릴 수 있다

2

중회귀모형

- 중회귀모형 분산분석
 - R을 이용한 분산분석 결과

```
# 중 회 귀 분 석
```

```
market2_lm = lm(Y ~ X1+X2, data=market2)
```

```
> summary(market2_lm)
```

```
Call:
```

```
lm(formula = Y ~ X1 + X2, data = market2)
```

```
Residuals:
```

```
      Min       1Q   Median       3Q      Max
-1.30465 -0.69561 -0.01755  0.69003  1.53127
```

```
Coefficients:
```

```
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.85041    0.84624   1.005 0.334770
X1           1.55811    0.14793  10.532 2.04e-07 ***
X2           0.42736    0.08431   5.069 0.000276 ***
```

```
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 0.9318 on 12 degrees of freedom
```

```
Multiple R-squared:  0.9799,    Adjusted R-squared:  0.9765
```

```
F-statistic: 292.5 on 2 and 12 DF,  p-value: 6.597e-11
```

2

중회귀모형

● 중회귀모형 분산분석

■ R을 이용한 분산분석 결과

```
# 중회귀모형 분산분석
fit0 <- lm(Y ~ 1, data = market2)
fit1 <- lm(Y ~ X1, data = market2)
fit12 <- lm(Y ~ X1+X2, data = market2)
> anova(fit0, fit1, fit12)
Analysis of Variance Table
```

```
Model 1: Y ~ 1
Model 2: Y ~ X1
Model 3: Y ~ X1 + X2
```

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	14	518.30				
2	13	32.72	<u>1</u>	<u>485.57</u>	559.283	1.955e-11 ***
3	12	10.42	<u>1</u>	<u>22.30</u>	25.691	0.0002758 ***

■ 결과해석

$$SS(X1) = 485.57$$

$$SS(X2|X1) = 22.30$$

$SS(X2|X1)$: 변수 $X1$ 적합 후, 변수 $X2$ 가 추가되었을 때의 추가제곱합

2

중회귀모형

● 중회귀모형 분산분석

▪ R을 이용한 분산분석 결과

```
# 중회귀모형 분산분석
fit0 <- lm(Y ~ 1, data = market2)
fit1 <- lm(Y ~ X1, data = market2)
fit12 <- lm(Y ~ X1+X2, data = market2)
> anova(fit0, fit12)
Analysis of Variance Table
```

Model 1: Y ~ 1

Model 2: Y ~ X1 + X2

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	14	518.30				
2	<u>12</u>	<u>10.42</u>	<u>2</u>	<u>507.88</u>	<u>292.49</u>	<u>6.597e-11 ***</u>

▪ 결과해석

회귀제곱합

$$SS(X1, X2) = SS(X1) + SS(X2|X1) = 507.88$$

2 중회귀모형

● 중회귀모형 분산분석

■ R을 이용한 분산분석 결과

```
# 중회귀모형 분산분석
fit0 <- lm(Y ~ 1, data = market2)
fit1 <- lm(Y ~ X1, data = market2)
fit12 <- lm(Y ~ X1+X2, data = market2)
> anova(fit12)
Analysis of Variance Table
```

```
Response: Y
      Df Sum Sq Mean Sq F value    Pr(>F)
X1      1  485.57   485.57  559.283 1.955e-11 ***
X2      1   22.30    22.30   25.691 0.0002758 ***
Residuals 12   10.42     0.87
```

■ 분산분석표

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
회귀	2	507.88	253.94	292.49	6.597×10^{-11}
잔차	12	10.42	0.87		
총합	14	518.30			

2 중회귀모형

● 결정계수

- 전체 변동(SST) 중에서 회귀모형으로 설명할 수 있는 비율(SSR)

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}.$$

- R^2 이 1에 가까울수록 "모형이 데이터를 잘 설명한다"는 의미
- 중상관계수(multiple correlation coefficient): 결정계수의 제곱근 $\sqrt{R^2}$

```
> cor(market2$Y, market2_lm$fitted.values)
```

```
[1] 0.9898983
```

```
> cor(market2$Y, market2_lm$fitted.values)^2
```

```
[1] 0.9798986
```

Residual standard error: 0.9318 on 12 degrees of freedom

Multiple R-squared: 0.9799, Adjusted R-squared: 0.9765

F-statistic: 292.5 on 2 and 12 DF, p-value: 6.597e-11

2 중회귀모형

● 수정결정계수 (Adjusted R^2)

- 독립변수를 추가할수록 결정계수(R^2)는 증가
 - 총제곱합(SST)은 고정되어 있는 반면, 독립변수를 추가할수록 잔차제곱합(SSE)이 줄어들기 때문
- 즉, 변수를 추가할수록 과적합이 우려되므로 모형 개발 과정에서 서로 다른 모형을 비교할 때는 과적합을 보정한 수정결정계수(R_{adj}^2)를 활용

$$R_{adj}^2 = 1 - \frac{SSE/(n - k - 1)}{SST/(n - 1)}.$$

- 즉, 결정계수(R^2)에서 SSE 대신 MSE 를, SST 대신 MST 를 쓴 것으로 볼 수 있음

Residual standard error: 0.9318 on 12 degrees of freedom
 Multiple R-squared: 0.9799, Adjusted R-squared: 0.9765
 F-statistic: 292.5 on 2 and 12 DF, p-value: 6.597e-11

2 중회귀모형

● 잔차평균제곱(MSE)

- MSE는 잔차(residual) 제곱합 SSE를 자유도($n - k - 1$)로 나눈 값:

$$MSE = \frac{SSE}{n - k - 1}.$$

- $\sqrt{MSE}$ 는 잔차표준오차(Residual Standard Error)로, σ 의 불편추정량이 되며, 예측값과 실제값 간의 차이가 평균적으로 어느 정도인지 나타내는 역할을 한다

Residual standard error: 0.9318 on 12 degrees of freedom

Multiple R-squared: 0.9799, Adjusted R-squared: 0.9765

F-statistic: 292.5 on 2 and 12 DF, p-value: 6.597e-11

2

중회귀모형

● 표준화된 중회귀분석

- **변수 표준화**: 중회귀모형에서 각 설명변수가 갖는 척도가 다를 때, 회귀계수의 크기만으로 어느 설명변수가 더 중요한지를 직관적으로 비교하기 어려울 수 있음
- 이를 보완하기 위해 **표준화**(standardization)를 적용
 - $Z_{ij} = \frac{X_{ij} - \bar{X}_j}{s_j}$ ($\bar{X}_j, s_j$: j 번째 독립변수의 평균과 표준편차) 처럼 각 독립변수의 평균을 0, 분산을 1로 변환하여 **표준화된 변수**를 얻음
 - 종속변수도 동일한 방식으로 표준화 ($Y_i \rightarrow Y_i^*$) 하면, 모형은

$$Y_i^* = a_1 Z_{i1} + a_2 Z_{i2} + \cdots + a_k Z_{ik} + \varepsilon_i$$

으로 표현되며 회귀계수 a_j 들을 “표준화 회귀계수”라고 부름 (표준화로 인해 모형에 절편이 없어짐)

- 표준화를 하면 회귀계수의 스케일이 각 변수의 표준편차로 변할 뿐, 변수 간의 상대적인 관계나 통계적 유의성에는 영향을 주지 않음 (즉, p-value는 변하지 않음)

2

중회귀모형

● 표준화된 중회귀분석

```
# 표준화된 중회귀분석
install.packages("lm.beta")
library(lm.beta)

market2_beta = lm.beta(market2_lm)
summary(market2_beta)
```

Coefficients:

	Estimate	Standardized	Std. Error	t value	Pr(> t)	
(Intercept)	0.85041	NA	0.84624	1.005	0.334770	
X1	1.55811	0.70156	0.14793	10.532	2.04e-07	***
X2	0.42736	0.33761	0.08431	5.069	0.000276	***

2 중회귀모형

● 추정과 검정

• $\hat{\beta}$ 의 기대값

$$\begin{aligned}
 E[\hat{\beta}] &= E[(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}] \\
 &= (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top E[\mathbf{Y}] \\
 &= (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{X} \beta \\
 &= \beta
 \end{aligned}$$

• $\hat{\beta}$ 의 분산

$$\begin{aligned}
 \text{Var}[\hat{\beta}] &= \text{Var}[(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}] \\
 &= (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \text{Var}[\mathbf{Y}] \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} \\
 &= (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \sigma^2 I \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} \\
 &= \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}
 \end{aligned}$$

2

중회귀모형

● 구간추정

- 독립변수들의 값이 $\mathbf{x} = (x_1, x_2, \dots, x_k)$ 일 때, 해당 지점에서의 평균 반응 $E[Y]$ 에 대한 구간추정이 가능하다.

$$\begin{aligned}\hat{E}[Y] &= \hat{Y} = \mathbf{x}^\top \hat{\boldsymbol{\beta}} \\ \text{Var}[\hat{Y}] &= \sigma^2 \mathbf{x}^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}\end{aligned}$$

- $E[Y]$ 에 대한 $100(1-\alpha)\%$ 신뢰구간

$$\hat{Y} \pm t_{(n-k-1, \alpha/2)} \sqrt{\text{MSE} \cdot \mathbf{x}^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}}$$

2 중회귀모형

● 회귀계수 가설검정

- 개별 회귀계수 β_j 에 대해서

$$H_0 : \beta_j = \beta_{j0}, \quad H_1 : \beta_j \neq \beta_{j0}$$

와 같은 형태의 **t-검정**을 수행할 수 있다

- 검정통계량

$$\begin{aligned} t_0 &= \frac{\hat{\beta}_j - \beta_{j0}}{\sqrt{\text{Var}(\hat{\beta}_j)}} \\ &= \frac{\hat{\beta}_j - \beta_{j0}}{\sqrt{c_{jj} \cdot \text{MSE}}} \sim t_{n-k-1} \end{aligned}$$

(단, c_{jj} 는 $(\mathbf{X}^\top \mathbf{X})^{-1}$ 행렬의 대각원소)

2 중회귀모형

● R을 이용한 추정과 검정

- 앞의마켓데이터(market-2.csv)에 중회귀모형 $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \epsilon$ 적합시

1) $x_1 = 10, x_2 = 10$ 에서 $E[Y]$ 에 대한 95%, 99% 신뢰구간?

2) $H_0: \beta_1 = 0, H_0: \beta_2 = 1$ 에 대하여 각각 유의수준 0.05로 가설검정?

```
> pred.x = data.frame(X1=10, X2=10)
> pc = predict(market2_lm, newdata=pred.x, interval = "confidence")
> pc
```

	fit	lwr	upr
1	20.70503	19.95796	21.45209

```
> pc99 = predict(market2_lm, newdata=pred.x, interval = "confidence", level=0.99)
> pc99
```

	fit	lwr	upr
1	20.70503	19.65769	21.75236

2

중회귀모형

● R을 이용한 추정과 검정

```
> summary(market2_lm)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	0.85041	0.84624	1.005	0.334770	
X1	1.55811	0.14793	10.532	<u>2.04e-07</u>	***
X2	0.42736	0.08431	5.069	0.000276	***

- $H_0: \beta_1 = 0$ 의 경우, 출력에 나오는 유의확률을 검정에 그대로 활용 가능

```
> p1 = 2*pt(abs(1.55811/0.14793), df=12, lower.tail = F)
```

```
> p1
```

```
[1] 2.038286e-07
```

2

중회귀모형

● R을 이용한 추정과 검정

```
> summary(market2_lm)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	0.85041	0.84624	1.005	0.334770	
X1	1.55811	0.14793	10.532	2.04e-07	***
X2	0.42736	0.08431	5.069	0.000276	***

- $H_0: \beta_2 = 1$ 의 경우, 검정통계량과 유의확률 직접 계산 가능

```
> p2 = 2*pt(abs((0.42736 - 1)/0.08431), df=12, lower.tail = F)
```

```
> p2
```

```
[1] 1.924551e-05
```

2 중회귀모형

● 두 모형 비교

예) 단순회귀모형 : $H_0: \beta_1 = 0$ $H_1: \beta_1 \neq 0$ 의 경우

1. 완전모형(Full Model)

$$Y_i = \beta_0 + \beta_1 X_i + \epsilon_i$$

- 데이터에 잘 적합된다고 가정하는 모형
- β_1 계수가 포함된 **일반(또는 복잡) 모형**

2. 축소모형(Reduced Model)

$$Y_i = \beta_0 + \epsilon_i$$

- 귀무가설($\beta_1 = 0$)이 **참**이라고 가정했을 때 얻어지는 모형
- β_1 항이 빠져 있으므로 **단순(또는 제한) 모형**

2 중회귀모형

● 두 모형 비교

두 모형을 비교할 때는 잔차제곱합(SSE)의 차이를 활용

1. 완전모형의 $SSE(SSE(F))$

$$SSE(F) = \sum_{i=1}^n [Y_i - (\hat{b}_0 + \hat{b}_1 X_i)]^2 = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

2. 축소모형의 $SSE(SSE(R))$

$$SSE(R) = \sum_{i=1}^n [Y_i - \hat{b}_0]^2 = \sum_{i=1}^n (Y_i - \bar{Y})^2 = SST$$

- 단순회귀에서 $\hat{b}_0$ 는 $\bar{Y}$ (평균)과 동일하게 추정된다고 가정했을 때, 축소모형의 잔차제곱합은 총제곱합(SST)과 동일해짐

2

중회귀모형

● 두 모형 비교를 위한 F -검정통계량

두 모형 간의 적합도 차이가 통계적으로 유의한지 검정하기 위해 다음과 같은 F -통계량을 이용

$$F_0 = \frac{\frac{SSE(R) - SSE(F)}{df_R - df_F}}{\frac{SSE(F)}{df_F}}$$

- $SSE(R)$: 축소모형의 잔차제곱합
- $SSE(F)$: 완전모형의 잔차제곱합
- df_R : 축소모형의 자유도(잔차에 대한 자유도)
- df_F : 완전모형의 자유도(잔차에 대한 자유도)

2

중회귀모형

● 두 모형 비교를 위한 F -검정통계량

단순회귀모형의 경우,

$$F_0 = \frac{(SST - SSE)/1}{SSE/(n-2)} = \frac{SSR/1}{MSE} = \frac{MSR}{MSE},$$

- $SSR = SST - SSE$ (회귀제곱합)
- $MSE = SSE/(n-2)$ (오차제곱평균)
- $MSR = SSR/1$ (회귀제곱평균)

결국 F -통계량이 의미하는 것은

" β_1 이 0이 아닐 때(완전모형)와 0일 때(축소모형)의 오차 크기 차이가 유의한가?"

2

중회귀모형

- 추가제곱합

- 새로운변수를 모델에 포함했을때 회귀제곱합(SSR)의 증가량

- 예를 들어,

$$\begin{aligned} SSR(X_4 \mid X_1) &= SSR(X_1, X_4) - SSR(X_1) \\ &= SSE(X_1) - SSE(X_1, X_4) \end{aligned}$$

- $SSR(X_1)$: X_1 만 포함했을 때의 모형(축소모형)에서의 회귀제곱합
 - $SSR(X_1, X_4)$: X_1 과 X_4 를 포함했을 때의 모형(완전모형)에서의 회귀제곱합
 - $SSE(X_1)$: X_1 만 포함했을 때의 모형(축소모형)에서의 잔차제곱합
 - $SSE(X_1, X_4)$: X_1 과 X_4 를 포함했을 때의 모형(완전모형)에서의 잔차제곱합

즉, **추가제곱합**은 새로 포함된 X_4 변수가 **얼마나 회귀제곱합을 늘렸는지** ($\rightarrow$ 모델 설명력 향상), 또는 **얼마나 잔차제곱합을 줄였는지**를 의미

$$SSR = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2$$

$$SSE = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

2 중회귀모형

● 추가제곱합

- 추가제곱합의 유의성판단을 위한 F -검정

$$F_0 = \frac{\frac{SSE(R) - SSE(F)}{df_R - df_F}}{\frac{SSE(F)}{df_F}}$$

- $SSE(R)$: 축소모형(변수 추가 전)의 잔차제곱합
- $SSE(F)$: 완전모형(변수 추가 후)의 잔차제곱합
- df_R, df_F : 각각 축소모형, 완전모형의 잔차 자유도

2

중회귀모형

● 추가제곱합 : R 코드 예시

```
# 추가제곱합
health = read.csv("health.csv")

h1.lm = lm(Y ~ X1, data=health)
h2.lm = lm(Y ~ X1+X4, data=health)
h3.lm = lm(Y ~ X1+X3+X4, data=health)
h4.lm = lm(Y ~ X1+X2+X3+X4, data=health)

anova(h1.lm, h2.lm)
anova(h2.lm, h3.lm)
anova(h3.lm, h4.lm)
```

2 중회귀모형

● 추가제곱합 : R 코드 예시

```
# 추가제곱합
```

```
health = read.csv("health.csv")
```

```
h1.lm = lm(Y ~ X1, data=health)
```

```
h2.lm = lm(Y ~ X1+X4, data=health)
```

```
h3.lm = lm(Y ~ X1+X3+X4, data=health)
```

```
h4.lm = lm(Y ~ X1+X2+X3+X4, data=health)
```

```
> anova(h1.lm, h2.lm)
```

```
Analysis of Variance Table
```

```
Model 1: Y ~ X1
```

```
Model 2: Y ~ X1 + X4
```

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	28	50795				
2	27	24049	1	26746	30.027	8.419e-06 ***

$$F_0 = \frac{\frac{50795 - 24046}{28 - 27}}{\frac{24049}{27}} = 30.027$$

```
> pf(30.027, 1, 27, lower.tail = F)
[1] 8.418493e-06
```

2

중회귀모형

● 추가제곱합 : R 코드 예시

추가제곱합

health = read.csv("health.csv")

h1.lm = lm(Y ~ X1, data=health)

h2.lm = lm(Y ~ X1+X4, data=health)

h3.lm = lm(Y ~ X1+X3+X4, data=health)

h4.lm = lm(Y ~ X1+X2+X3+X4, data=health)

> anova(h2.lm, h3.lm)

Analysis of Variance Table

Model 1: Y ~ X1 + X4

Model 2: Y ~ X1 + X3 + X4

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	27	24050				
2	26	20856	1	3193.5	3.9812	0.05659 .

2 중회귀모형

● 추가제곱합 : R 코드 예시

```
# 추가제곱합
health = read.csv("health.csv")

h1.lm = lm(Y ~ X1, data=health)
h2.lm = lm(Y ~ X1+X4, data=health)
h3.lm = lm(Y ~ X1+X3+X4, data=health)
h4.lm = lm(Y ~ X1+X2+X3+X4, data=health)
> anova(h3.lm, h4.lm)
Analysis of Variance Table

Model 1: Y ~ X1 + X3 + X4
Model 2: Y ~ X1 + X2 + X3 + X4
  Res.Df  RSS Df Sum of Sq    F Pr(>F)
1      26 20856
2      25 20551  1   304.62 0.3706 0.5482
```

감사합니다