

2026 학년도 1학기 중간과제물(온라인 제출용)

교 과 목 명	회귀모형
학 번	202334-153257
성 명	양희석
연 락 처	010-4340-2326
과 제 유 형 (공통형/지정형)	공통형

목차

- 문제1. 갈톤(Galton)의 '회귀' 개념과 현대 통계학의 회귀 용어 비교
 - 1.1 갈톤(Francis Galton)의 '회귀' 개념
 - 1.2 현대 통계학에서의 '회귀(regression)' 용어
 - 1.3 갈톤의 회귀와 현대 회귀의 차이
- 문제2. mtcars 자료를 이용한 단순회귀모형 분석
 - 2.1 연비를 가장 잘 예측하는 단순회귀모형 (6점)
 - 2.2 중회귀모형으로 확장 — 추가 변수 1개 선정 (7점)
 - 2.3 회귀계수 해석 — 원래 모형과 표준화 모형 (7점)

문제1. 갈톤(Galton)의 '회귀' 개념과 현대 통계학의 회귀 용어 비교

1.1 갈톤(Francis Galton)의 '회귀' 개념

프랜시스 갈톤(Francis Galton, 1822–1911)은 찰스 다윈의 사촌으로, 유전(heredity)과 인간 변이(human variation) 연구에 평생을 바친 영국의 학자이다. 그는 1885년 영국학술협회(British Association for the Advancement of Science) 인류학 분과 회장 취임 강연을 정리하여, 1886년 *Journal of the Anthropological Institute of Great Britain and Ireland*(15권)에 발표한 논문 *"Regression towards Mediocrity in Hereditary Stature"*에서 처음으로 '회귀(regression)'라는 용어를 통계학적 의미로 도입하였다. 갈톤은 205쌍의 부모와 그 자녀 930명의 신장(키) 자료를 수집·분석하여, 부(父)와 모(母)의 키를 평균낸 '중부모(mid-parent)' 키와 자녀의 키 사이의 관계를 산점도에 그려 보았다.

그 결과 그는 다음과 같은 현상을 관찰하였다. "키가 매우 큰 부모의 자녀는 평균적으로 부모보다 작고, 키가 매우 작은 부모의 자녀는 평균적으로 부모보다 크다. 즉 자녀 세대의 키는 부모 세대의 극단성을 그대로 물려받지 않고 모집단 평균(mediocrity) 쪽으로 되돌아가려는 경향을 보인다." 갈톤은 자녀의 평균 편차가 중부모 편차의 약 $\frac{2}{3}$ 수준이라는 사실을 수치적으로 제시하였고, 이를 *"regression towards mediocrity"*(평범으로의 회귀) 또는 오늘날 흔히 부르는 '평균으로의 회귀(regression toward the mean)'로 일반화하였다. 따라서 갈톤이 사용한 회귀는 본질적으로 유전 형질이 세대를 거치며 극단치에서 모집단 평균으로 수렴해 가는 생물학적·자연적 현상을 기술하는 용어였다. 이때 갈톤은 산점도 위의 점들을 가로지르는 직선의 기울기를 통해 두 변수 간 관계의 강도를 시각적으로 파악하였고, 이는 오늘날 회귀직선(regression line)과 상관계수(correlation coefficient) 개념의 원형이 되었다.

1.2 현대 통계학에서의 '회귀(regression)' 용어

갈톤의 제자 칼 피어슨(Karl Pearson), 조지 윌(G. U. Yule), 그리고 후대의 R. A. 피셔(R. A. Fisher)를 거치며 회귀라는 용어는 그 의미가 크게 확장·전환되었다. 현대 통계학에서 회귀분석(regression analysis)은 더 이상 "평균으로 되돌아간다"는 현상 자체를 의미하지 않으며, **하나 또는 여러 개의 설명변수(독립변수, X)와 반응변수(종속변수, Y) 사이의 함수적 관계를 자료로부터 추정·검정하고 예측에 활용하는 일반적 통계 모형화 기법**을 가리킨다. 수학적으로는 조건부 기댓값 $E(Y \mid X)$ 를 모형화하는 것을 핵심 목표로 하며, 선형회귀(단순/다중), 다항회귀, 로지스틱회귀, 일반화선형모형(GLM), 비모수 회귀, 정규화 회귀(Ridge-Lasso-Elastic Net), 베이지안 회귀 등으로 광범위하게 발전하였다. 나아가 현대의 머신러닝·딥러닝 지도학습 알고리즘 상당수(신경망 회귀, 트리 기반 회귀 등) 역시 회귀의 큰 틀 안에서 해석된다.

1.3 갈톤의 회귀와 현대 회귀의 차이

구분	갈톤(1886)의 회귀	현대 통계학의 회귀
본질	형질이 평균으로 수렴하는 자연 현상 (phenomenon)	변수 간 함수관계를 추정하는 분석 방법론 (methodology)
목적	유전 현상의 기술적(descriptive) 설명	예측, 인과 추론, 변수의 영향력 평가

대상	신장(키)이라는 단일 형질의 세대 간 변화	임의의 X와 Y에 대한 일반적 조건부 기댓값 모형
수학적 도구	산점도, 회귀계수 $\approx 2/3$, 단순 평균 비교	최소제곱법(OLS), 최대우도추정(MLE), 정규화, GLM 등
적용 범위	인류 유전학에 한정	경제·의학·공학·사회과학·인공지능 등 거의 모든 분야
'회귀'의 어감	글자 그대로 '되돌아감(regress)'	어원만 남고, 실질적 의미는 함수관계 추정으로 이전

요컨대 갈톤이 발견한 '평균으로의 회귀'는 회귀분석이라는 학문의 **역사적 출발점이자 어원**으로서의 의미가 크며, 오늘날의 회귀분석은 "평균으로 되돌아간다"는 본래 의미를 사실상 잃고 **변수 간의 관계를 자료로부터 모형화하는 일반적 통계 기법**으로 외연을 크게 넓혔다. 다만 두 개념을 관통하는 공통의 사고는, 자료에 내재한 변동성으로부터 평균적 경향(체계적 신호)을 분리·추출한다는 통계학의 근본 원리에 있다고 할 수 있다.

참고문헌

1. Galton, F. (1886). "Regression towards Mediocrity in Hereditary Stature." *Journal of the Anthropological Institute of Great Britain and Ireland*, 15, 246–263.

2. Senn, S. (2011). "Francis Galton and regression to the mean." *Significance*, 8(3), 124–126. doi:10.1111/j.1740-9713.2011.00509.x

3. Stigler, S. M. (1997). "Regression towards the mean, historically considered." *Statistical Methods in Medical Research*, 6(2), 103–114.

4. Koenker, R. (1998). "Galton's Regression to the Mean." University of Illinois Working Paper.

5. "Regression toward the mean." *Wikipedia*. (검색일: 2026-04-29)

문제2. mtcars 자료를 이용한 단순회귀모형 분석

`data(mtcars)` 명령으로 1973–1974년형 자동차 32종의 연비(`mpg` , 결과변수)와 10가지 특성(`cyl` , `disp` , `hp` , `drat` , `wt` , `qsec` , `vs` , `am` , `gear` , `carb`)을 불러왔다. 본 과제 지시에 따라 모든 설명변수는 연속형 숫자형으로 가정하였다.

2.1) 연비를 가장 잘 예측하는 단순회귀모형 (6점)


(1) 분석 절차

연비(`mpg`)를 가장 잘 예측하는 **단일** 설명변수를 선택하기 위해 다음 절차를 따랐다.

- `mpg` 와 10개 설명변수 사이의 **Pearson 상관계수**로 1차 스크리닝
- 10개 설명변수 각각으로 **단순회귀모형**($\widehat{mpg} = \beta_0 + \beta_1 X$)을 적합하고, **R^2 -adj. R^2 -F-p-잔차표준오차(σ)-AIC-BIC** 등 비교지표를 일괄 산출
- 모든 지표에서 우위인 변수를 잠정 선정한 뒤, **회귀계수의 유의성과 잔차 가정**(정규성·등분산성)을 검정하여 최종 확정

(2) 1차 스크리닝 — 상관계수 분석

`cor(mtcars)` 로 산출한 상관행렬은 다음과 같다(상삼각, `corrplot::corrplot(..., method="number", type="upper")`).



mpg 행에서 절댓값 기준 상관 순위는 다음과 같다.

순위	변수	$r(mpg, X)$	$ r(mpg, X) $
1	wt	-0.868	0.868
2	cyl	-0.852	0.852
3	disp	-0.848	0.848
4	hp	-0.776	0.776
5	drat	+0.681	0.681
6	vs	+0.664	0.664
7	am	+0.600	0.600
8	carb	-0.551	0.551
9	gear	+0.480	0.480
10	qsec	+0.419	0.419

wt (차량 무게)가 절댓값 0.868로 1위이며, 단순회귀에서 결정계수 $R^2 = r^2$ 관계가 성립하므로 이미 1차적으로 wt가 가장 강력한 후보임을 시사한다. 또한 설명변수들 사이의 상관(예: $\text{cyl} - \text{disp} = 0.90$, $\text{disp} - \text{wt} = 0.89$)이 매우 높아, 무게 정보가 실린더 수·배기량 정보를 상당 부분 포함하고 있음을 알 수 있다.

(3) 10개 단순회귀의 일괄 적합 및 비교

각 후보 변수에 대해 단순회귀를 적합한 결과는 아래와 같다(R^2 내림차순 정렬).

```
> xvars <- setdiff(names(mtcars), "mpg")
>
> fit_one <- function(v) {
+   f <- as.formula(paste("mpg ~", v))
+   m <- lm(f, data = mtcars)
+   s <- summary(m)
+   data.frame(
+     var      = v,
+     beta     = unname(coef(m)[2]),
+     se       = unname(coef(s)[2, "Std. Error"]),
+     t_value  = unname(coef(s)[2, "t value"]),
+     p_value  = unname(coef(s)[2, "Pr(>|t|)"]),
+     R2       = s$r.squared,
+     adj_R2   = s$adj.r.squared,
+     F_stat   = unname(s$fstatistic[1]),
+     sigma    = s$sigma,           # 잔차 표준오차(RSE)
+     AIC      = AIC(m),
+     BIC      = BIC(m)
+   )
+ }
>
> res <- do.call(rbind, lapply(xvars, fit_one))
> res <- res[order(-res$R2), ] # R² 내림차순
> print(res, row.names = FALSE, digits = 4)
```

var	beta	se	t_value	p_value	R2	adj_R2	F_stat	sigma	AIC	BIC
wt	-5.34447	0.559101	-9.559	1.294e-10	0.7528	0.7446	91.375	3.046	166.0	170.4
cyl	-2.87579	0.322409	-8.920	6.113e-10	0.7262	0.7171	79.561	3.206	169.3	173.7
disp	-0.04122	0.004712	-8.747	9.380e-10	0.7183	0.7090	76.513	3.251	170.2	174.6
hp	-0.06823	0.010119	-6.742	1.788e-07	0.6024	0.5892	45.460	3.863	181.2	185.6
drat	7.67823	1.506705	5.096	1.776e-05	0.4640	0.4461	25.970	4.485	190.8	195.2
vs	7.94048	1.632370	4.864	3.416e-05	0.4409	0.4223	23.662	4.581	192.1	196.5
am	7.24494	1.764422	4.106	2.850e-04	0.3598	0.3385	16.860	4.902	196.5	200.9
carb	-2.05572	0.568546	-3.616	1.084e-03	0.3035	0.2803	13.074	5.113	199.2	203.6
gear	3.92333	1.308131	2.999	5.401e-03	0.2307	0.2050	8.995	5.374	202.4	206.8
qsec	1.41212	0.559210	2.525	1.708e-02	0.1753	0.1478	6.377	5.564	204.6	209.0

순위	변수	\$WhatWbeta_1\$	SE	\$t\$	\$p\$값	\$R^2\$	adj.\$R^2\$	\$F\$	\$WhatWsigma\$
1	wt	-5.344	0.559	-9.56	1.29e-10	0.7528	0.7446	91.38	3.046
2	cyl	-2.876	0.322	-8.92	6.11e-10	0.7262	0.7171	79.56	3.206
3	disp	-0.0412	0.0047	-8.75	9.38e-10	0.7183	0.7090	76.51	3.251
4	hp	-0.0682	0.0101	-6.74	1.79e-07	0.6024	0.5892	45.46	3.863
5	drat	+7.678	1.507	+5.10	1.78e-05	0.4640	0.4461	25.97	4.485
6	vs	+7.940	1.632	+4.86	3.42e-05	0.4409	0.4223	23.66	4.581
7	am	+7.245	1.764	+4.11	2.85e-04	0.3598	0.3385	16.86	4.902
8	carb	-2.056	0.569	-3.62	1.08e-03	0.3035	0.2803	13.07	5.113
9	gear	+3.923	1.308	+3.00	5.40e-03	0.2307	0.2050	8.99	5.374

10	qsec	+1.412	0.559	+2.53	1.71e-02	0.1753	0.1478	6.38	5.564
----	------	--------	-------	-------	----------	--------	--------	------	-------

판독 결과 `wt` 가 모든 비교지표에서 일관되게 1위이다.

- 설명력: $R^2 = 0.7528$ 로 `mpg` 총변동의 약 75%를 단일 변수로 설명. 2위 `cyl` (0.7262)·3위 `disp` (0.7183)와 약 2.6%p 이상의 격차.
- 모형 유의성: $F(1,30) = 91.38$, $p = 1.29 \times 10^{-10}$ 로 가장 큼.
- 예측 오차: 잔차 표준오차 $\hat{\sigma} = 3.046$ mpg로 가장 작음.
- 정보량 기준: AIC = 166.0, BIC = 170.4로 모두 최소 → 정보량 손실이 가장 적은 모형.

(4) 최종 모형 확정 및 잔차 가정 검증

위 비교에서 `wt` 를 단일 설명변수로 확정하고, $\hat{mpg} = \beta_0 + \beta_1 wt$ 모형을 최종 적합한 결과는 다음과 같다.

```
> fit_best <- lm(mpg ~ wt, data = mtcars)
> summary(fit_best)

Call:
lm(formula = mpg ~ wt, data = mtcars)

Residuals:
    Min       1Q   Median       3Q      Max
-4.5432 -2.3647 -0.1252  1.4096  6.8727

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  37.2851     1.8776   19.858 < 2e-16 ***
wt           -5.3445     0.5591   -9.559 1.29e-10 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.046 on 30 degrees of freedom
Multiple R-squared:  0.7528,    Adjusted R-squared:  0.7446
F-statistic: 91.38 on 1 and 30 DF,  p-value: 1.294e-10

> confint(fit_best)                # 회귀계수 95% 신뢰구간
              2.5 %      97.5 %
(Intercept) 33.450500 41.119753
wt          -6.486308 -4.202635
>
> par(mfrow = c(2, 2))
> plot(fit_best)                  # 4종 진단도표
> shapiro.test(resid(fit_best))   # 잔차 정규성

      Shapiro-Wilk normality test

data:  resid(fit_best)
W = 0.94508, p-value = 0.1044

> lmtest::bptest(fit_best)        # 등분산성(Breusch-Pagan)

      studentized Breusch-Pagan test

data:  fit_best
BP = 0.040438, df = 1, p-value = 0.8406

> |
```

추정 회귀식: $\hat{mpg} = 37.285 - 5.344 \cdot wt$

항	추정치	표준오차	t 값	p 값	95% 신뢰구간
절편 β_0	37.285	1.878	19.86	$< 2 \times 10^{-16}$	[33.45, 41.12]
기울기 β_1 (wt)	-5.344	0.559	-9.56	1.29×10^{-10}	[-6.486, -4.203]

계수 해석: 차량 무게가 1,000 lb 증가할 때 평균 연비는 약 **5.34 mpg** 감소한다. 95% 신뢰구간이 음수 영역에서만 형성되어 통계적으로 매우 유의하며, 무게가 커질수록 가속·관성 부담이 커져 연비가 떨어진다는 물리적 직관과도 부합한다.


잔차 가정 검증

가정	검정 방법	통계량	p 값	결론(유의수준 0.05)
정규성	Shapiro-Wilk	$W = 0.945$	0.104	정규성 가정 기각 못함 ☒
등분산성	Breusch-Pagan	$BP = 0.040$	0.841	등분산성 가정 기각 못함 ☒
선형성	산점도/잔차도	—	—	강한 음의 선형 추세 확인

→ 회귀모형의 핵심 가정이 모두 충족된다.

(5) 시각화

mpg 와 wt 의 산점도, 적합 회귀직선, 95% 신뢰띠는 다음과 같다(`ggplot2::geom_smooth(method="lm")`).



평균 무게 부근($wt \approx 3.2$)에서 신뢰띠가 매우 좁아 추정의 정밀도가 높음을 시각적으로 확인할 수 있다.

(6) 한계 및 추가 분석 여지

- 산점도에서 좌상단의 두 점(Fiat 128, Toyota Corolla)은 양의 큰 잔차(약 +6~+7 범위)를, 우하단의 Chrysler Imperial($wt \approx 5.34$)은 큰 leverage를 가지는 영향점으로 관측된다.
- 잔차 대 적합값 도표에서 약한 U자 곡률이 관찰되므로, 향후 wt^2 항을 추가하거나 다중회귀(예: `wt + qsec + am`)로 확장하면 예측 성능을 더 높일 여지가 있다.
- 본 문항은 **단일 변수** 단순회귀의 비교가 목적이므로 이러한 확장은 후속 문항에서 다룬다.

(7) 결론

10개 설명변수 각각으로 단순회귀를 적합한 결과, **wt (차량 무게, 단위 1,000 lb)** 가 결정계수($R^2 = 0.7528$), F 통계량(91.38), 잔차표준오차(3.046), AIC(166.0)-BIC(170.4) 등 **모든 비교 지표에서 1위**였다. 회귀계수 추정치 $\widehat{\beta}_1 = -5.344$ 는 95% 신뢰 구간 $[-6.486, -4.203]$, $p = 1.29 \times 10^{-10}$ 로 매우 유의하며, 잔차의 정규성(Shapiro-Wilk $p = 0.104$)과 등분산성(Breusch-Pagan $p = 0.841$)도 충족되었다. 따라서 연비를 가장 잘 예측하는 단순회귀모형으로 다음 식을 채택한다.

$$\widehat{mpg} = 37.285 - 5.344 \cdot wt$$

2.2) 중회귀모형으로 확장 — 추가 변수 1개 선정 (7점)

(1) 분석 절차

문항 2.1)에서 선정된 단순회귀모형 $\widehat{\text{mpg}} = \beta_0 + \beta_1 \text{wt}$ 에 나머지 9개 설명변수 $\{\text{cyl, disp, hp, drat, qsec, vs, am, gear, carb}\}$ 중 가장 도움이 되는 한 변수를 추가하여 중회귀모형 $\widehat{\text{mpg}} = \beta_0 + \beta_1 \text{wt} + \beta_2 X$ 를 만들고자 한다.

중회귀에서 R^2 의 의미: 단순회귀에서는 $R^2 = r^2$ (단변량 상관계수의 제곱)로 정의되지만, 중회귀에서는 R^2 가 다중상관계수(multiple correlation coefficient) R 의 제곱, 즉 적합값 $\widehat{Y}$ 와 관측값 Y 사이의 상관계수의 제곱이다. 또한 설명변수가 늘어나면 R^2 는 단조적으로 증가하므로, 변수의 진정한 기여도를 비교하려면 자유도 보정 결정계수 ($\text{adj. } R^2$)나 정보량 기준(AIC/BIC), 부분 F -검정을 함께 보아야 한다.

변수 선정의 수치적 근거로 다음 다섯 가지 지표를 동시에 사용하였다.

1. **adjusted R^2** — 자유도 보정 결정계수. 무가치한 변수 추가 시 오히려 감소하므로 중회귀의 1차 비교 기준
2. **부분 F -검정**(Partial F-test, $\text{anova}(\text{base}, m)$) — 추가 변수의 통계적 기여 유의성 직접 검정 ($H_0: \beta_2 = 0$)
3. **AIC / BIC** — 정보량 기준. 작을수록 좋음
4. **잔차 표준오차 $\widehat{\sigma}$** — 예측 오차의 절대 크기
5. **VIF**(Variance Inflation Factor) — 다중공선성 진단. wt와 강한 상관을 가진 후보(cyl, disp, hp)는 VIF 점검 필수

(2) 9개 후보 변수에 대한 일괄 적합 결과

$\text{mpg} \sim \text{wt} + X$ 형태의 중회귀모형 9개를 적합한 결과는 아래와 같다(adjusted R^2 내림차순 정렬). 단순회귀 기준선은 $\text{adj. } R^2 = 0.7446$, $\widehat{\sigma} = 3.046$, AIC = 166.0 이다.

```
> library(car) # vif() 함수
>
> base <- lm(mpg ~ wt, data = mtcars)
> xvars2 <- setdiff(names(mtcars), c("mpg", "wt")) # 9개 후보
>
> fit_two <- function(v) {
+   f <- as.formula(paste("mpg ~ wt +", v))
+   m <- lm(f, data = mtcars)
+   s <- summary(m)
+   a <- anova(base, m) # 부분 F-검정
+   vifs <- car::vif(m)
+   data.frame(
+     add_var      = v,
+     beta_new     = unname(coef(m)[v]),
+     se_new       = unname(coef(s)[v, "Std. Error"]),
+     p_new        = unname(coef(s)[v, "Pr(>|t|)"]),
+     R2           = s$r.squared,
+     adj_R2       = s$adj.r.squared,
+     sigma        = s$sigma,
+     AIC          = AIC(m),
+     BIC          = BIC(m),
+     partial_F    = a$F[2],
+     partial_p    = a$`Pr(>F)`[2],
+     VIF_wt       = unname(vifs["wt"]),
+     VIF_new      = unname(vifs[v])
+   )
+ }
>
> res2 <- do.call(rbind, lapply(xvars2, fit_two))
> res2 <- res2[order(-res2$adj_R2), ] # adj.R² 내림차순
> print(res2, row.names = FALSE, digits = 4)
```

	add_var	beta_new	se_new	p_new	R2	adj_R2	sigma	AIC	BIC	partial_F	partial_p	VIF_wt	VIF_new
cyl	-1.50779	0.41469	0.001064	0.8302	0.8185	2.568	156.0	161.9	1.322e+01	0.001064	2.579	2.579	
hp	-0.03177	0.00903	0.001451	0.8268	0.8148	2.593	156.7	162.5	1.238e+01	0.001451	1.767	1.767	
qsec	0.92920	0.26502	0.001500	0.8264	0.8144	2.596	156.7	162.6	1.229e+01	0.001500	1.031	1.031	
vs	3.15437	1.19074	0.012926	0.8010	0.7873	2.780	161.1	167.0	7.018e+00	0.012926	1.445	1.445	
carb	-0.82152	0.34921	0.025646	0.7924	0.7781	2.839	162.4	168.3	5.534e+00	0.025646	1.224	1.224	
disp	-0.01772	0.00919	0.063620	0.7809	0.7658	2.917	164.2	170.0	3.720e+00	0.063620	4.728	4.728	
drat	1.44249	1.45857	0.330854	0.7609	0.7444	3.047	167.0	172.8	9.781e-01	0.330854	2.031	2.031	
gear	-0.31955	0.92654	0.732668	0.7538	0.7369	3.092	167.9	173.8	1.189e-01	0.732668	1.516	1.516	
am	-0.02362	1.54565	0.987915	0.7528	0.7358	3.098	168.0	173.9	2.334e-04	0.987915	1.921	1.921	

순 위	추가 변수 X	β_X	p_X	R^2	adj. R^2	$\widehat{\sigma}$	AIC	BIC	부분 F	
1	cyl	-1.508	1.06e-03	0.8302	0.8185	2.568	156.0	161.9	13.22	1
2	hp	-0.0318	1.45e-03	0.8268	0.8148	2.593	156.7	162.5	12.38	1

3	qsec	+0.929	1.50e-03	0.8264	0.8144	2.596	156.7	162.5	12.29	1
4	vs	+3.154	1.29e-02	0.8010	0.7873	2.780	161.1	167.0	7.02	1
5	carb	-0.822	2.56e-02	0.7924	0.7781	2.839	162.4	168.3	5.53	2
6	disp	-0.0177	6.36e-02	0.7809	0.7658	2.917	164.2	170.0	3.72	6
7	drat	+1.442	0.331	0.7609	0.7444	3.047	167.0	172.8	0.98	0
8	gear	-0.320	0.733	0.7538	0.7369	3.092	167.9	173.8	0.12	0
9	am	-0.024	0.988	0.7528	0.7358	3.098	168.0	173.9	2.34e-04	0

(3) 결과 해석

- **adj. R^2 1위는** cyl (0.8185), 2위 hp (0.8148), 3위 qsec (0.8144). 상위 3변수는 모두 단순회귀(0.7446) 대비 약 **+0.07**의 개선을 보여 통계적으로도 의미 있는 향상이다.
- **부분 F -검정** 에서도 cyl 이 $F = 13.22$, $p = 1.06 \times 10^{-3}$ 로 가장 강한 유의성을 보였다(상위 3변수 모두 $p < 0.002$ 로 유의).
- **AIC:** cyl 추가 시 AIC = 156.0으로 단순회귀(166.0) 대비 $\Delta \text{AIC} = -10.0$. 통상 $|\Delta \text{AIC}| > 10$ 은 '매우 강한(decisive)' 모형 개선의 증거로 해석된다.
- **잔차 표준오차** σ 도 3.046 to 2.568 mpg 로 약 **15.7% 감소**하여 예측 정밀도가 향상되었다.
- **다중공선성:** cyl 추가 시 $VIF_{wt} = VIF_{cyl} = 2.58$ 로 통상 임계치(5 또는 10) 보다 낮아 다중공선성 위험은 수용 가능한 수준이다. (참고: 6위 disp 는 $VIF = 4.73$ 으로 wt 와의 상관이 매우 강해 추가의 의미가 적고, $p_X = 0.064$ 로 5% 수준에서 유의하지 않다.)
- **하위 3변수**(drat , gear , am)는 부분 F -검정의 p 값이 0.3 이상으로, wt 가 이미 모형에 들어 있을 때 **추가적 설명력이 없음**이 명확하다. 특히 am 은 단순회귀에서 $r=0.60$ 으로 비교적 강한 상관을 보였음에도, wt 가 am 이 담는 정보 (am - wt 상관 = -0.69)를 거의 흡수해 버려 partial F 가 거의 $0(2.34e-04)$ 으로 떨어졌다 — 이는 단변량 상관과 부분상관의 차이를 보여주는 좋은 예이다.

참고 — qsec 의 의미: adj. R^2 측면에서 3위지만, wt 와의 상관이 -0.17 에 불과해 **VIF가 1.03으로 가장 안전하다**. 정보가 거의 직교(orthogonal)하므로 qsec 추가는 "물리적으로 다른 정보"(가속 성능)를 보태는 깔끔한 선택이다. 다만 본 과제의 비교 기준(adj. R^2 , AIC, partial F , σ 4개)에서 모두 1위인 변수는 cyl 이므로 cyl 을 추가 변수로 확정한다.

(4) 최종 중회귀모형 적합 결과 — $\text{mpg} \sim \text{wt} + \text{cyl}$


```

> best2 <- lm(mpg ~ wt + cyl, data = mtcars)
> summary(best2)

Call:
lm(formula = mpg ~ wt + cyl, data = mtcars)

Residuals:
    Min       1Q   Median       3Q      Max
-4.2893 -1.5512 -0.4684  1.5743  6.1004

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  39.6863     1.7150   23.141 < 2e-16 ***
wt          -3.1910     0.7569   -4.216 0.000222 ***
cyl         -1.5078     0.4147   -3.636 0.001064 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.568 on 29 degrees of freedom
Multiple R-squared:  0.8302,    Adjusted R-squared:  0.8185
F-statistic: 70.91 on 2 and 29 DF,  p-value: 6.809e-12

> confint(best2)
                2.5 %      97.5 %
(Intercept) 36.178725 43.1937976
wt          -4.739020 -1.6429245
cyl         -2.355928 -0.6596622
> car::vif(best2)
      wt      cyl
2.579312 2.579312
> anova(base, best2) # 단순회귀 vs 중회귀 비교
Analysis of Variance Table

Model 1: mpg ~ wt
Model 2: mpg ~ wt + cyl
  Res.Df  RSS Df Sum of Sq  F  Pr(>F)
1     30 278.32
2     29 191.17  1     87.15 13.22 0.001064 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
>
> par(mfrow = c(2, 2))
> plot(best2) # 진단도표
> par(mfrow = c(1, 1))
>
> shapiro.test(resid(best2)) # 정규성

Shapiro-Wilk normality test

data:  resid(best2)
W = 0.93745, p-value = 0.06341

> lmtest::bptest(best2) # 등분산성

studentized Breusch-Pagan test

data:  best2
BP = 3.2548, df = 2, p-value = 0.1964
>

```

추정 회귀식: $\hat{mpg} = 39.686 - 3.191 \cdot wt - 1.508 \cdot cyl$

항	추정치	표준오차	\$t\$값	\$p\$값	95% 신뢰구간
절편 β_0	39.686	1.715	23.14	$< 2 \times 10^{-16}$	[36.18, 43.19]
β_{wt}	-3.191	0.757	-4.22	2.22×10^{-4}	[-4.74, -1.64]
β_{cyl}	-1.508	0.415	-3.64	1.06×10^{-3}	[-2.36, -0.66]

- 모형 전체: $F(2, 29) = 70.91$, $p = 6.81 \times 10^{-12}$, $R^2 = 0.8302$, $\text{adj. } R^2 = 0.8185$, $\hat{\sigma} = 2.568$.
- 단순회귀 vs 중회귀 비교(부분 F -검정, `anova(base, best2)`): RSS(잔차제곱합)이 278.32 → 191.17로 감소하여, `cyl` 추가에 의해 추가로 설명된 변동이 87.15이며 $F = 13.22$, $p = 1.06 \times 10^{-3}$ 으로 `cyl` 추가가 통계적으로 매우 유의하다.
- 다중공선성: $VIF_{wt} = VIF_{cyl} = 2.579$ (모두 $< 5 \rightarrow$ 수용 가능).
- 계수 해석:
 - `cyl` 고정 시 `wt` 가 1,000 lb 증가하면 평균 연비 약 3.19 mpg 감소 (단순회귀의 -5.34에서 절댓값 감소 → `wt` 가 단독으로 가지던 효과의 일부가 `cyl` 로 분산됨)
 - `wt` 고정 시 실린더 수가 1 증가하면 평균 연비 약 1.51 mpg 감소

잔차 가정 검증

가정	검정 방법	통계량	\$p\$값	결론(유의수준 0.05)
----	-------	-----	--------	---------------

정규성	Shapiro-Wilk	$\$W = 0.937\$$	0.063	정규성 가정 기각 못함
등분산성	Breusch-Pagan	$\$BP = 3.255, \text{df}=2\$$	0.196	등분산성 가정 기각 못함
다중공선성	VIF	2.579 / 2.579	—	임계치 5 미만, 안전

→ 회귀의 핵심 가정이 모두 충족되며, 단순회귀 대비 모든 비교 지표가 개선되었다.

(5) 결론

`mpg ~ wt` 단순회귀에 **9개 후보 변수**를 각각 추가하여 9개 중회귀모형을 적합한 결과, `cyl` (**실린더 수**) 이 다음과 같이 모든 핵심 비교 지표에서 1위였다.

- adjusted R^2 : **0.8185** (단순회귀 0.7446 → +0.074)
- 부분 F -검정: $F = 13.22, p = 1.06 \times 10^{-3}$ (가장 강한 유의성)
- AIC: **156.0** (단순회귀 166.0 → $\Delta\text{AIC} = -10.0$, 매우 강한 개선)
- 잔차 표준오차: 3.046 → **2.568** mpg (15.7% 감소)
- VIF: **2.579** (다중공선성 안전 임계치 5 미만)

회귀계수 $\hat{\beta}_{\text{cyl}} = -1.508$ 은 95% 신뢰구간 $[-2.36, -0.66]$, $p = 1.06 \times 10^{-3}$ 로 매우 유의하며, 잔차의 정규성(Shapiro $p = 0.063$), 등분산성(BP $p = 0.196$)도 모두 충족된다. 따라서 단순회귀모형에 추가할 가장 도움이 되는 변수로 `cyl` 을 선정하며, 최종 중회귀모형으로 다음을 채택한다.

$$\widehat{\text{mpg}} = 39.686 - 3.191 \cdot \text{wt} - 1.508 \cdot \text{cyl}$$

2.3) 회귀계수 해석 — 원래 모형과 표준화 모형 (7점)

문항 2.2)에서 채택한 중회귀모형 $\widehat{\text{mpg}} = 39.686 - 3.191 \cdot \text{wt} - 1.508 \cdot \text{cyl}$ 의 (i) 원래 단위 회귀계수, (ii) 표준화 회귀계수를 차례로 해석하고, 표준화 해석이 적절치 않은 경우의 사유를 논한다.

(1) 원래(unstandardized) 회귀계수의 해석

항	추정치 $\hat{\beta}_j$	단위	해석
절편 $\hat{\beta}_0$	39.686	mpg	$\text{wt} = 0, \text{cyl} = 0$ 일 때의 평균 연비. 그러나 데이터 범위($\text{wt} \in [1.51, 5.42], \text{cyl} \in \{4, 6, 8\}$)를 크게 벗어난 외삽 이므로 물리적 의미는 약하며, 회귀선의 위치를 결정하는 기준점에 불과하다.
$\hat{\beta}_{\text{wt}}$	-3.191	mpg / 1000 lb	실린더 수 <code>cyl</code> 을 고정한 상태에서 차량 무게가 1,000 lb 증가할 때 평균 연비는 약 3.19 mpg 감소 한다. (95% CI $[-4.74, -1.64]$)
$\hat{\beta}_{\text{cyl}}$	-1.508	mpg / 개	차량 무게 <code>wt</code> 를 고정한 상태에서 실린더 수가 1개 증가할 때 평균 연비는 약 1.51 mpg 감소 한다. (95% CI $[-2.36, -0.66]$)

관찰 1 — 단순회귀와의 비교: 단순회귀 $\hat{\beta}_{\text{wt}} = -5.344$ 가 중회귀에서는 -3.191 로 절댓값이 줄었다. 이는 단순회귀에서 `wt`가 단독으로 가지던 효과 중 일부가 본래 `cyl`이 설명하던 부분이었으며, **다른 변수가 통제되면 `wt`의 순(net) 효과는 더 작아짐**을 의미한다(다중공선성으로 인한 설명력 분산).

관찰 2 — 단위 비교 불가: $\$|-3.191|\$$ vs $\$|-1.508|\$$ 만으로 "`wt`가 `cyl`보다 두 배 더 영향력이 크다"고 말할 수 없다. `wt`(1000 lb)와 `cyl`(개)의 단위가 전혀 다르기 때문이며, 변수 단위에 따라 계수의 절댓값은 임의로 커지거나 작아질 수 있다. → 표준화 회귀계수가 필요한 본질적 이유.

(2) 표준화 중회귀모형의 적합

모든 변수(`mpg`, `wt`, `cyl`)를 Z -점수($z_i = (x_i - \bar{x})/s_x$)로 표준화한 뒤 중회귀를 적합하였다. 변환 공식은 다음과 같다.
 $\hat{\beta}_j^* = \hat{\beta}_j \cdot \frac{s_{(X_j)}}{s_{(Y)}}$, $s_{(\text{mpg})} = 6.0269$, $s_{(\text{wt})} = 0.9785$, $s_{(\text{cyl})} = 1.7859$

방법 1 — `scale()` 로 표준화 후 `lm` 적합

```

> # ===== 방법 1: scale()로 모든 변수 표준화 후 lm =====
> mtcars_std <- as.data.frame(scale(mtcars)) # Z-점수화
> best2_std <- lm(mpg ~ wt + cyl, data = mtcars_std)
> summary(best2_std)

Call:
lm(formula = mpg ~ wt + cyl, data = mtcars_std)

Residuals:
    Min       1Q   Median       3Q      Max
-0.71169 -0.25737 -0.07771  0.26120  1.01218

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  4.898e-17  7.531e-02   0.000 1.000000
wt          -5.180e-01  1.229e-01  -4.216 0.000222 ***
cyl         -4.468e-01  1.229e-01  -3.636 0.001064 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.426 on 29 degrees of freedom
Multiple R-squared:  0.8302,    Adjusted R-squared:  0.8185
F-statistic: 70.91 on 2 and 29 DF,  p-value: 6.809e-12

> confint(best2_std)
                2.5 %      97.5 %
(Intercept) -0.1540220  0.1540220
wt          -0.7693660 -0.2667240
cyl         -0.6981149 -0.1954729
>

```

방법 2 — lm.beta 패키지로 한 줄 산출 / 방법 3 — 손계산 검산

```

> # ===== 방법 2: lm.beta 패키지 (한 줄로 표준화 계수만) =====
> install.packages("lm.beta") # 처음이면 설치

WARNING: Rtools is required to build R packages but is not currently installed. Please download and install the appropriate
version of Rtools before proceeding:
https://cran.rstudio.com/bin/windows/Rtools/

'C:\Users\airto\AppData\Local\R\win-library\4.6'의 위치에 패키지(들)을 설치합니다.
(왜냐하면 'lib'가 지정되지 않았기 때문입니다)
'xtable'(들)을 또한 설치합니다.

URL 'https://cran.rstudio.com/bin/windows/contrib/4.6/xtable_1.8-8.zip'을 시도합니다
URL 'https://cran.rstudio.com/bin/windows/contrib/4.6/lm.beta_1.7-3.zip'을 시도합니다
package 'xtable' successfully unpacked and MD5 sums checked
package 'lm.beta' successfully unpacked and MD5 sums checked

다운로드된 바이너리 패키지들은 다음의 위치에 있습니다
C:\Users\airto\AppData\Local\Temp\RtmpSUM782\downloaded_packages
> library(lm.beta)
> lm.beta(best2) # best2는 2-2)의 lm(mpg ~ wt + cyl)

Call:
lm(formula = mpg ~ wt + cyl, data = mtcars)

Standardized Coefficients:
            wt          cyl
            NA    -0.5180450    -0.4467939
>

```

```

> # ===== 방법 3: 손계산으로 검산 =====
> sd_y <- sd(mtcars$mpg)
> sd_wt <- sd(mtcars$wt)
> sd_cyl <- sd(mtcars$cyl)
> beta_wt_std <- coef(best2)["wt"] * sd_wt / sd_y
> beta_cyl_std <- coef(best2)["cyl"] * sd_cyl / sd_y
> c(beta_wt_std = beta_wt_std, beta_cyl_std = beta_cyl_std)
      beta_wt_std beta_cyl_std
      -0.5180450      -0.4467939
>

```

세 방법 모두 다음의 동일한 결과를 산출하여 상호 검증되었다.

항	표준화 추정치 β	표준오차	t 값	p 값	95% 신뢰구간
절편	$4.898 \times 10^{-17} \approx 0$	0.0753	0.000	1.0000	[-0.154, 0.154]
β_{wt}	-0.5180	0.1229	-4.216	2.22×10^{-4}	[-0.769, -0.267]

β_{cyl}	-0.4468	0.1229	-3.636	1.06×10^{-3}	[-0.698, -0.195]
---------------	---------	--------	--------	-----------------------	------------------

검증 포인트 — 적합도/추론은 불변: $R^2 = 0.8302$, $\text{adj. } R^2 = 0.8185$, $F = 70.91$, 각 계수의 t -값 p -값 모두 원래 모형 best2와 완전히 동일하다. 표준화는 단지 변수의 척도 변환일 뿐 모형의 설명력과 통계적 유의성은 바뀌지 않음을 확인할 수 있다. 또한 절편이 부동소수 오차 범위 내($\sim 10^{-17}$)에서 정확히 0으로 추정된 것은, 모든 변수가 평균 중심화되어 회귀선이 원점을 지나기 때문이다.

(3) 표준화 회귀계수의 해석

- $\beta_{wt} \approx -0.518$: cyl을 고정한 상태에서 wt가 1 표준편차(약 978 lb) 증가할 때, mpg는 평균적으로 약 0.518 표준편차(≈ 3.12 mpg) 감소한다.
- $\beta_{cyl} \approx -0.447$: wt를 고정한 상태에서 cyl이 1 표준편차(약 1.79개) 증가할 때, mpg는 평균적으로 약 0.447 표준편차(≈ 2.69 mpg) 감소한다.
- 상대적 영향력 비교:** $|\beta_{wt}| = 0.518 > |\beta_{cyl}| = 0.447$. 즉 **단위에 무관한 척도에서는 wt가 cyl보다 mpg에 약간 더 큰 영향을 준다**(약 1.16배). 다만 두 표준화 계수가 비교적 비슷한 수준이라, 두 변수 모두 mpg 예측에 거의 비슷한 비중으로 기여한다고도 해석할 수 있다.

(4) 표준화 해석이 적절치 않은 경우 — cyl 의 이산성 문제

cyl (실린더 수)의 표준화 해석에는 본질적 문제가 있다.

- cyl 은 본질적으로 이산형(discrete)-범주형(categorical) 변수이다.
 - mtcars의 cyl은 단 세 값(4, 6, 8) 만 취한다.
 - "cyl이 1.79개(= 1 표준편차) 증가"는 물리적으로 존재할 수 없는 변화다 — 1.79개의 실린더를 가진 자동차는 만들 수 없다.
 - 이산 변수의 표준편차는 수학적으로는 계산되지만 그 값을 "한 단위 변화"로 삼는 표준화 해석의 전제가 깨진다.
- 본 과제 지시의 한계 노출:** 과제 지시문에서 "범주형 자료 분석을 학습하기 전이므로 모든 설명변수를 연속형으로 가정"한다고 했으나, 이 가정은 표준화 단계에서 더 두드러지게 부적합성을 드러낸다. cyl은 본래 4/6/8 세 수준의 요인(factor)으로 다뤄야 하며, 더미변수와 후의 계수가 진짜 의미를 가진다.
- 반면 wt 의 표준화 해석은 자연스럽다.** wt는 본질적으로 연속형이며, 1 표준편차(≈ 978 lb)의 변동은 차종 간에 흔히 관찰되는 실재 범위(예: 경차 vs 세단의 무게 차이)이므로 "1 SD 증가"가 실재적 의미를 가진다.
- 권고:**
 - 변수의 상대적 영향력 비교가 목적이라면 표준화 계수를 사용하되, cyl의 경우 "1 SD 증가" 대신 **"다른 변수와의 영향력 비교 척도"** 정도로 해석 강도를 약화하는 것이 안전하다.
 - 예측·실용적 해석**(특정 차량의 mpg 예측, 무게/실린더의 정량적 영향)이 목적이라면 **원래 단위 모형을 쓰는 것**이 cyl의 이산성을 직관적으로 다룰 수 있어 더 적절하다("실린더 1개 추가 시 -1.51 mpg"는 직접적이고 실측 가능한 변화).
 - 이상적 해법은 cyl을 factor(cyl) 로 처리하여 더미변수 회귀를 수행하는 것이며, 이는 후속 차시 학습 후 다룰 영역이다.

(5) 종합 비교표 및 결론

모형	절편	β_{wt} (또는 β_{wt})	β_{cyl} (또는 β_{cyl})	단위	해석의 적합성
원래 모형	39.686	-3.191 mpg/1000lb	-1.508 mpg/개	원 단위	예측·실용 해석에 적합 ✅
표준화 모형	≈ 0	-0.518 SD	-0.447 SD	표준편차	wt는 적합, cyl은 부적절 ⚠️

결론:

- 원래 모형**에서 wt는 cyl을 통제하였을 때 1,000 lb당 평균 연비 3.19 mpg 감소, cyl은 wt를 통제하였을 때 1개당 평균 연비 1.51 mpg 감소시킨다. 둘 다 통계적으로 매우 유의하다.
- 표준화 모형**에서 두 계수의 절댓값은 $|\beta_{wt}| = 0.518 > |\beta_{cyl}| = 0.447$ 로 **wt가 cyl보다 약간 큰 상대적 영향력**을 가지지만, 표준화 후에도 적합도(R^2 , F , p -값)는 원래 모형과 완전히 동일하다.
- cyl 의 표준화 해석은 부적절하다.** cyl이 4-6-8 세 값만을 갖는 본질적 이산변수이기 때문이며, "1 표준편차(≈ 1.79 개) 증가"라는 표현이 물리적으로 성립하지 않는다. 이런 변수는 원래 단위 모형으로 해석하거나, 적절한 처리(요인화·더미변수화)를 거친 후 해석해야 한다.